Dissertação apresentada à Pró-Reitoria de Pós-Graduação e Pesquisa do Instituto Tecnológico de Aeronáutica, como parte dos requisitos para obtenção do título de Mestre em Ciências no Programa de Pós-Graduação em Engenharia Eletrônica e Computação, Área de Sistemas e Controle.

João Paulo de Andrade Dantas

APOIO À DECISÃO PARA O COMBATE AÉREO ALÉM DO ALCANCE VISUAL: UMA ABORDAGEM POR REDES NEURAIS ARTIFICIAIS

Dissertação aprovada em sua versão final pelos abaixo assinados:

Prof. Dr. Takashi Yoneyama
Orientador

Prof. Dr. Pedro Teixeira Lacava
Pró-Reitor de Pós-Graduação e Pesquisa

Campo Montenegro
São José dos Campos, SP - Brasil
2018

Dados Internacionais de Catalogação-na-Publicação (CIP)
Divisão de Informação e Documentação

Dantas, João Paulo de Andrade
Apoio à decisão para o combate aéreo além do alcance visual: uma abordagem por redes neurais artificiais / João Paulo de Andrade Dantas.
São José dos Campos, 2018.
144f.

Dissertação de Mestrado – Curso de Engenharia Eletrônica e Computação. Área de Sistemas e Controle – Instituto Tecnológico de Aeronáutica, 2018. Orientador: Prof. Dr. Takashi Yoneyama.

1. Combate BVR. 2. Consciência situacional. 3. Redes neurais. 4. Sistemas de apoio à decisão. 5. Computação. I. Instituto Tecnológico de Aeronáutica. II. Título.

REFERÊNCIA BIBLIOGRÁFICA

DANTAS, João Paulo de Andrade. **Apoio à decisão para o combate aéreo além do alcance visual: uma abordagem por redes neurais artificiais**. 2018. 144f. Dissertação de Mestrado – Instituto Tecnológico de Aeronáutica, São José dos Campos.

CESSÃO DE DIREITOS

NOME DO AUTOR: João Paulo de Andrade Dantas
TITULO DO TRABALHO: Apoio à decisão para o combate aéreo além do alcance visual: uma abordagem por redes neurais artificiais.
TIPO DO TRABALHO/ANO: Dissertação / 2018

É concedida ao Instituto Tecnológico de Aeronáutica permissão para reproduzir cópias desta dissertação e para emprestar ou vender cópias somente para propósitos acadêmicos e científicos. O autor reserva outros direitos de publicação e nenhuma parte desta dissertação pode ser reproduzida sem a autorização do autor.

João Dantas

João Paulo de Andrade Dantas
Avenida Doutor Eduardo Cury, 350, Ap. 156. Jardim das Colinas
12.242-001 – São José dos Campos–SP

APOIO À DECISÃO PARA O COMBATE AÉREO ALÉM DO ALCANCE VISUAL: UMA ABORDAGEM POR REDES NEURAIS ARTIFICIAIS

João Paulo de Andrade Dantas

Composição da Banca Examinadora:

Prof. Dr.	Roberto Kawakami Harrop Galvão	Presidente	-	ITA
Prof. Dr.	Takashi Yoneyama	Orientador	-	ITA
Prof. Dr.	Henrique Costa Marques	Membro Interno	-	ITA
Dr.	Hélcio Vieira Júnior	Membro Externo	-	Telebras

ITA

À minha família pelo apoio incondicional e aos meus orientadores por todos os ensinamentos que tornaram esse trabalho possível.

Agradecimentos

Primeiramente à Deus por permitir vitórias sobrenaturais na minha vida.

Em especial aos meus pais, por terem sempre me apoiado durante toda minha formação e na conclusão desse trabalho.

À Força Aérea Brasileira por permitir essa capacitação fantástica na minha carreira.

Ao meu orientador, Prof. Dr. Takashi Yoneyama, pelos ensinamentos, e ainda, pela confiança e paciência que permitiram o desenvolvimento intelectual de todos os envolvidos.

Ao Major Diego Geraldo, que com seu comprometimento para com a missão e operacionalidade da Força Aérea Brasileira, não mediu esforços em me ajudar na busca pela solução do problema apresentado neste estudo.

Aos professores do Instituto Tecnológico de Aeronáutica, os quais muito se dedicaram na transferência de tão valioso conhecimento.

Aos meus companheiros do Instituto de Estudos Avançados, em especial da Divisão de C4ISR, os quais me apoiaram e incentivaram durante todo o meu Mestrado, estando sempre dispostos a ajudar.

"As máquinas me surpreendem muito frequentemente."
— ALAN TURING

Resumo

A presente dissertação apresenta o desenvolvimento de um modelo de inteligência artificial baseado em redes neurais artificiais que permite fornecer parâmetros de melhoria da consciência situacional de um piloto de combate aéreo além do alcance visual. Tal modalidade de combate tem como característica a necessidade de se tomar decisões baseando-se em informações oriundas de sensores, principalmente radares. Além disso, como as informações relativas aos sistemas da aeronave inimiga são, por vezes, desconhecidas, muitas das atitudes tomadas pelos pilotos se baseiam em crenças e estimativas com relação ao oponente. O modelo apresentado se propõe a lidar com tais características, gerando comportamentos para entidades representadas num ambiente de simulação construtiva. Um simulador de combate aéreo além do alcance visual foi utilizado para criação de cenários de combate entre duas aeronaves, com apenas um míssil cada uma, que possuem comportamentos semelhantes que podem ser diferenciados com mudanças nos parâmetros de entrada da simulação. A partir da variação de trinta e seis informações de entradas foram geradas cem, mil e dez mil simulações de combate para realização das análises. Com esses dados foi possível criar um modelo de aprendizado de máquina supervisionado por meio das redes neurais artificiais que permitiram uma pronta resposta da situação do piloto em um combate aéreo além do alcance visual no que diz respeito a ofensividade e defensividade por meio de um dispositivo embarcado de melhoria da consciência situacional do piloto que auxilia o processo de tomada de decisão em voo.

Abstract

This dissertation presents the development of an artificial intelligence model based on artificial neural networks. The model provides parameters to improve the situational awareness of a beyond visual range combat pilot. Such combat modality is characterized by the need to make decisions based on information from sensors, mainly radars. Furthermore, since information regarding enemy aircraft systems is sometimes unknown, many of the decisions taken by pilots are based on beliefs regarding the opponent. The presented model proposes to deal with such characteristics, generating behaviors for entities represented in a constructive simulation environment. A beyond visual range air combat simulator was used to create scenarios of combat between two aircraft, with only one missile each. The aircraft have similar behaviors that can be differentiated with changes in the input parameters of the simulation. From the variation of thirty-six input information, one hundred, one thousand, and ten thousand combat simulations were generated for the analysis. With this data, it was possible to create a supervised machine learning model based on artificial neural networks that allowed for a prompt improvement on the situational awareness of the pilot in an BVR combat, regarding either offensiveness or defensiveness. This was made by means of an embedded device of situational awareness for the pilot that assists in the in-flight decision-making process.

Lista de Figuras

FIGURA 1.1 – Custo por hora de operação das seis aeronaves mais representativas do combate aéreo além do alcance visual. 21

FIGURA 2.1 – Fases de engajamento do combate aéreo além do alcance visual. . . 25

FIGURA 2.2 – Fluxograma representativo do modelo comportamental com combate aéreo além do alcance visual. 28

FIGURA 2.3 – Modelo de um neurônio artificial. 34

FIGURA 2.4 – Analogia entre os neurônios biológicos e artificiais 35

FIGURA 2.5 – Função sigmoide e sua derivada. 37

FIGURA 2.6 – Função tangente hiperbólica e sua derivada. 38

FIGURA 2.7 – Função unidade linear retificada e sua derivada. 39

FIGURA 2.8 – Rede alimentada adiante com camada única. 41

FIGURA 2.9 – Rede alimentada adiante com múltiplas camadas. 41

FIGURA 2.10 –Propagação direta de sinais de função e retropropagação de sinais de erro. 43

FIGURA 2.11 –Combate aéreo um contra um com as trajetórias extrapoladas dos alvos. 47

FIGURA 2.12 –Modelagem do agente do piloto de combate. 48

FIGURA 2.13 –Um diagrama esquemático geral da rede neural fuzzy híbrida. 49

FIGURA 2.14 –Trajetórias ótimas no combate aéreo com diferentes medidas de desempenho. 50

FIGURA 2.15 –O diagrama de fases descrevendo a tomada de decisão do piloto. . . 51

FIGURA 2.16 –Estrutura de conhecimento do sistema de apoio à decisão em tempo real para um combate aéreo um contra um. 52

FIGURA 3.1 – Indicador de WEZ. 57
FIGURA 3.2 – Modelo para filosofia de tiro da aeronave inimiga. 58
FIGURA 3.3 – Modelo para efetividade do disparo da aeronave inimiga. 59
FIGURA 3.4 – Parâmetros de simulação do simulador de combate aéreo além do alcance visual. 60
FIGURA 3.5 – Parâmetros de entidades do simulador de combate aéreo além do alcance visual. 61
FIGURA 3.6 – Classificação das simulações de operações militares. 63
FIGURA 3.7 – Aeronaves adentrando os envelopes radar. 65
FIGURA 3.8 – Representação das trajetórias calculadas. 65
FIGURA 3.9 – Disparo do míssil azul. 66
FIGURA 3.10 –Ativação do míssil azul (*seeker*). 66
FIGURA 3.11 –Curva de alta performance vermelha e míssil azul neutralizado. . . . 67
FIGURA 3.12 –Posição relativa de 30° entre as aeronaves azul e vermelha. 68
FIGURA 3.13 –Distância de 40 nm entre as aeronaves azul e vermelha. 68
FIGURA 3.14 –Seleção do tipo de míssil no simulador BVR. 70
FIGURA 3.15 –Raio limite para alcançar o alvo (r_{cap}) do míssil AIM-120 AMRAAM. 73
FIGURA 3.16 –Conjunto de dados de entrada das simulações BVR. 80
FIGURA 3.17 –Conjunto de dados de saídas das simulações BVR. 80
FIGURA 3.18 –Métricas de desempenho para aprendizagem de máquina por classificação e regressão. 83
FIGURA 3.19 –Matriz de confusão para sistemas preditivos. 84
FIGURA 3.20 –Validação cruzada *k-fold*. 89
FIGURA 3.21 –Gradiente descendente com baixas e altas taxa de aprendizagem. . . 96
FIGURA 3.22 –Comportamento do erro por número de épocas de acordo com a taxa de aprendizagem escolhida. 97
FIGURA 3.23 –Análise de fatores atrelados à Consciência Situacional causadores de erros na aviação geral. 100

FIGURA 4.1 – Histogramas das variáveis de saída para 100 simulações. 105
FIGURA 4.2 – Histogramas das variáveis de saída para 1.000 simulações. 106

FIGURA 4.3 – Histogramas das variáveis de saída para 10.000 simulações. 106

FIGURA 4.4 – Matrizes de confusão de redes neurais artificiais de ataque chegando a 10 metros. 115

FIGURA 4.5 – Matrizes de confusão de redes neurais artificiais de defesa chegando a 10 metros. 116

FIGURA 4.6 – Matrizes de confusão de redes neurais artificiais de ataque chegando a 10.000 metros. 119

FIGURA 4.7 – Matrizes de confusão de redes neurais artificiais de defesa chegando a 10.000 metros. 120

FIGURA 4.8 – Relação entre os valores previstos e reais para redes neurais artificiais de regressão para análises de modelos ofensivos. 123

FIGURA 4.9 – Gráficos *boxplot* dos valores previstos e reais para redes neurais artificiais de regressão para análises de modelos ofensivos. 123

FIGURA 4.10 –Relação entre os valores previstos e reais para redes neurais artificiais de regressão para análises de modelos defensivos. 124

FIGURA 4.11 –Gráficos *boxplot* dos valores previstos e reais para redes neurais artificiais de regressão para análises de modelos defensivos. 124

FIGURA 4.12 –Dispositivo de melhoria da consciência situacional do piloto de combate aéreo além do alcance visual. 125

Lista de Tabelas

TABELA 3.1 – Resumo das dimensões do míssil utilizado na modelagem do simulador de combate aéreo além do alcance visual. 71

TABELA 3.2 – Significado das variáveis de entrada e saída utilizadas no modelo de aprendizagem. 79

TABELA 3.3 – Determinando o número de camadas ocultas em redes neurais artificiais. 91

TABELA 4.1 – Estatísticas descritivas: variáveis de saída do modelo de simulação do combate aéreo além do alcance visual. 104

TABELA 4.2 – Covariância entre as variáveis de entrada e as variáveis de saída das simulações BVR. 107

TABELA 4.3 – Correlação entre as variáveis de entrada e as variáveis de saída das simulações BVR. 109

TABELA 4.4 – Resultados do modelo de regressão logística para o caso do míssil atingindo a distância máxima de 10 metros. 111

TABELA 4.5 – Resultados do modelo de regressão logística para o caso do míssil atingindo a distância de 10.000 metros. 111

TABELA 4.6 – Descrição das saídas no estudo de caso do míssil atingindo 10 metros.113

TABELA 4.7 – Otimização das redes neurais artificiais de ataque para o estudo de caso do míssil atingindo distância mínima de 10 metros do alvo. . . 113

TABELA 4.8 – Otimização das redes neurais artificiais de defesa para o estudo de caso do míssil atingindo distância mínima de 10 metros do alvo. . . 113

TABELA 4.9 – Descrição das saídas no estudo de caso do míssil atingindo 10.000 metros. 117

TABELA 4.10 –Otimização das redes neurais artificiais de ataque para o estudo de caso do míssil atingindo distância mínima de 10.000 metros do alvo. 118

TABELA 4.11 –Otimização das redes neurais artificiais de defesa para o estudo de caso do míssil atingindo distância mínima de 10.000 metros do alvo. 118

TABELA 4.12 –Otimização das redes neurais artificiais de regressão de ataque. . . . 121

TABELA 4.13 –Otimização das redes neurais artificiais de regressão de defesa. . . . 121

Lista de Abreviaturas e Siglas

ADAM	*Adaptive Moment Estimation*
AGA	*Adaptive Genetic Algorithm*
AGs	Algoritmos Genéticos
AMRAAM	*Advanced Medium-Range Air-to Air Missile*
ANN	*Artificial Neural Network*
ART	*Adaptive Resonance Theory*
ASA	Ambiente de Simulação Aeroespacial
BFGS	*Broyden-Fletcher-Goldfarb-Shanno*
BVR	*Beyond Visual Range*
BVRAAM	*Beyond Visual Range Air-to-Air Missile*
CGF	*Computer Generated Forces*
CSV	*Comma-Separated Values*
CV	*Cross Validation*
DBN	*Dynamic Bayesian Networks*
DLZ	*Dynamic Launch Zone*
DNN	*Deep Neural Networks*
DOE	*Design of Experiments*
ELU	*Exponential Linear Unit*
FAB	Força Aérea Brasileira
FL	(*Flight Level*)
FN	Falso Negativo
FP	Falso Positivo
GPS	*Global Positioning System*
HAGA	*Heuristic Adaptive Genetic Algorithm*
IA	Inteligência Artificial
IEAV	Instituto de Estudos Avançados
LAR	*Launch Acceptability Region*
L-BFGS	*Limited-memory Broyden-Fletcher-Goldfarb-Shanno*
LHS	*Latin Hypercube Sampling*
LVC	*Live, Virtual and Constructive*

MLP	*Multilayer Perceptron*
MR	*Maximum Range*
NEZ	*No Escape Zone*
PMA	Planejador de Missões Aéreas
PMC	Perceptron de Múltiplas Camadas
PO	Pesquisa Operacional
R^2	Coeficiente de Determinação
RBF	*Radial Basis Function*
ReLU	*Rectified Linear Unit*
RMSE	*Root Mean Square Error*
RNA	Redes Neurais Artificiais
RWR	*Radar Warning Receiver*
SA	*Situation Awareness*
SIG	Sistema de Informações Geográficas
SGD	*Stochastic Gradient Descent*
SVM	*Support Vector Machine*
TACDSS	*Tactical Air Combat Decision Support System*
TanH	Tangente Hiperbólica
TBM	*Tactical Battle Manager*
VANT	Veículos Aéreos Não Tripulados
VN	Verdadeiro Negativo
VP	Verdadeiro Positivo
WTA	*Weapon-Target Assignment*
WVR	*Within Visual Range*

Sumário

1 Introdução 19

1.1 Apresentação do tema 19

1.2 Objetivos da pesquisa 20

1.3 Conteúdo dos capítulos 22

2 Fundamentação teórica 24

2.1 Combate aéreo além do alcance visual 24

2.2 Ciência de dados 29

2.3 Inteligência artificial 29

2.4 Aprendizado de máquina 30

2.5 Redes neurais artificiais 32

2.5.1 Definição e histórico 32

2.5.2 Neurônio artificial 34

2.5.3 Funções de ativação 36

2.5.4 Arquitetura 40

2.5.5 Treinamento 42

2.5.6 *Overfitting* 44

2.5.7 Aplicações 45

2.6 Revisão da literatura 46

3 Metodologia 54

3.1 Simulador de combate aéreo além do alcance visual 54

3.1.1 AEROGRAF 55

3.1.2 Ambiente de Simulação Aeroespacial 55

3.1.3 Modelagem comportamental 56
3.1.4 Tipo de simulação 62
3.2 Estudo de caso 64
3.2.1 Descrição 64
3.2.2 Variáveis de entrada das simulações 67
3.2.3 Design de experimentos 74
3.2.4 Variáveis de saída das simulações 76
3.3 Desenvolvimento do modelo de aprendizagem 77
3.3.1 Exploração dos dados 78
3.3.2 Ajuste das variáveis de entrada 81
3.3.3 Normalização 82
3.3.4 Métricas de desempenho 82
3.3.5 Análise inicial utilizando regressão logística 87
3.3.6 Validação cruzada 88
3.3.7 Funções de ativação propostas 90
3.3.8 Número de camadas ocultas 91
3.3.9 Número de neurônios 92
3.3.10 Algoritmo de otimização 93
3.3.11 Taxa de aprendizagem 95
3.3.12 Treinamento e testes 97
3.3.13 Previsão 98
3.4 Sistema de melhoria da consciência situacional 99

4 Resultados e discussões 103
4.1 Análise das variáveis 104
4.1.1 Estatística descritiva das variáveis de saída 104
4.1.2 Ferramentas de qualidade 105
4.2 Aplicabilidade 110
4.2.1 Modelo de regressão logística 110
4.2.2 Modelo de redes neurais artificiais de classificação 112

4.2.3 Modelo de redes neurais artificiais de regressão 121
4.2.4 Apoio à decisão para o combate aéreo além do alcance visual 125

5 Considerações finais 128
5.1 Síntese 128
5.2 Limitações e pesquisas futuras 130

Referências 134

1 Introdução

Neste capítulo inicial é feita a contextualização do presente trabalho, tendo como principais objetivos apresentar e delimitar claramente o tema estudado. Além disso, é esclarecida a motivação para a realização do trabalho proposto e o potencial impacto do estudo da dissertação.

Em seguida, descrevem-se as principais contribuições desse trabalho, com a indicação das lacunas da literatura científica a serem preenchidas. Os objetivos e limitações do estudo serão esclarecidos ao leitor assim como, ao final, é apresentada a forma de estruturação utilizada nesta dissertação, com a descrição resumida do conteúdo de cada um dos capítulos posteriores.

1.1 Apresentação do tema

O presente trabalho visa desenvolver um modelo de inteligência artificial baseado em redes neurais artificiais de um cenário de combate aéreo além do alcance visual com o objetivo de fornecer aos pilotos parâmetros que demonstrem a sua consciência situacional no combate aéreo.

Nesse contexto, esta dissertação é, portanto, desenvolvida em torno de três assuntos principais: *i*) concepção e modelagem de um simulador de combate além do alcance visual que permitirá a análise de diversos cenários possíveis de combate entre duas aeronaves, *ii*) a manipulação por meio de ferramentas de ciência de dados para realização das análises das variáveis de entrada e saída nas simulações propostas no modelo e *iii*) modelagem das redes neurais artificiais que forneceram informações importantíssimas em tempo real ao piloto cumprindo o papel de um sistema embarcado de apoio à decisão.

Com relação a modelagem do simulador de combate aéreo além do alcance visual, é proposta a construção de um conjunto de modelos matemáticos que representem as crenças do piloto simulado com relação ao seu oponente. Além disso, por meio de um modelo da zona de engajamento efetivo do armamento, também conhecida como *Weapon Engagement Zone* (WEZ), utilizado da mesma forma para as previsões das ações do oponente, é determinado

o momento de disparo do míssil da aeronave modelada. Toda a modelagem foi realizada na plataforma AEROGRAF (PETERSEN *et al.*, 2008) por meio de um *plugin*, sendo nela tanto simulada, quanto visualizada. Os parâmetros que definem os cenários para teste são disponibilizados para modificação pelo usuário, permitindo uma grande variabilidade nas simulações realizadas e diversas análises de interesse operacional. Apesar de dados relativos ao combate aéreo além do alcance visual não serem disponibilizados de forma ostensiva, não podendo estes ser apresentados neste trabalho, os modelos propostos se baseiam em conhecimentos operacionais de pilotos desta modalidade de combate, que participaram ativamente do processo de concepção do *plugin*. Vale também ressaltar que, apesar de formações com múltiplas aeronaves comporem os cenários mais comuns no contexto desse tipo de combate aéreo, conforme visto em Du e Liu (2010), este trabalho considera, por simplicidade, apenas o combate entre duas aeronaves. Contudo, no futuro, vislumbra-se efetuar a extensão dos modelos apresentados para que possam atuar satisfatoriamente em cenários de maior complexidade.

Referente a manipulação dos dados obtidos das simulações, é realizada uma adequação das informações adquiridas do simulador para uma melhor construção dos modelos de inteligência artificial que serão utilizados para a solução de problemas operacionais. Destaca-se, ainda, a importância da utilização da *Latin Hypercube Sampling* para a geração dos dados de entrada de forma aleatória, respeitando os intervalos das variáveis escolhidas para modelar o combate aéreo além do alcance visual.

Por fim, modelos de redes neurais artificiais são propostos para representação do tipo de combate analisado onde são verificados os números de neurônios, número de camadas escondidas, as funções de ativação propostas, algoritmos de otimização, dentre outros fatores. Após as análises desse modelo de aprendizagem supervisionada, um sistema embarcado de apoio à decisão é demonstrado baseado na melhoria da consciência situacional do piloto, termo este que será melhor definido no Capítulo 3.

1.2 Objetivos da pesquisa

Treinamentos reais de combate aéreo além do alcance visual são bastante custosos. Com uma estimativa de 4.700 dólares americanos por hora, a aeronave sueca JAS 39 Gripen tem uma comparação muito favorável em relação ao Block 40/50 F-16, que é o concorrente mais próximo, com uma valor por hora estimado em 7.000 dólares americanos (JANE'S, 2012). Outras aeronaves como o F-16, Rafale, Eurofighter e F-35 possuem custo ainda maiores. A Figura 1.1 demonstra o custo por hora de operação das seis aeronaves de combate aéreo além do alcance visual mais representativas atualmente baseado nas seguintes variáveis:

combustível de aviação, bens de consumo, operação e manutenção, mão de obra, melhorias do sistema, encargos de capital, depreciação e amortização.

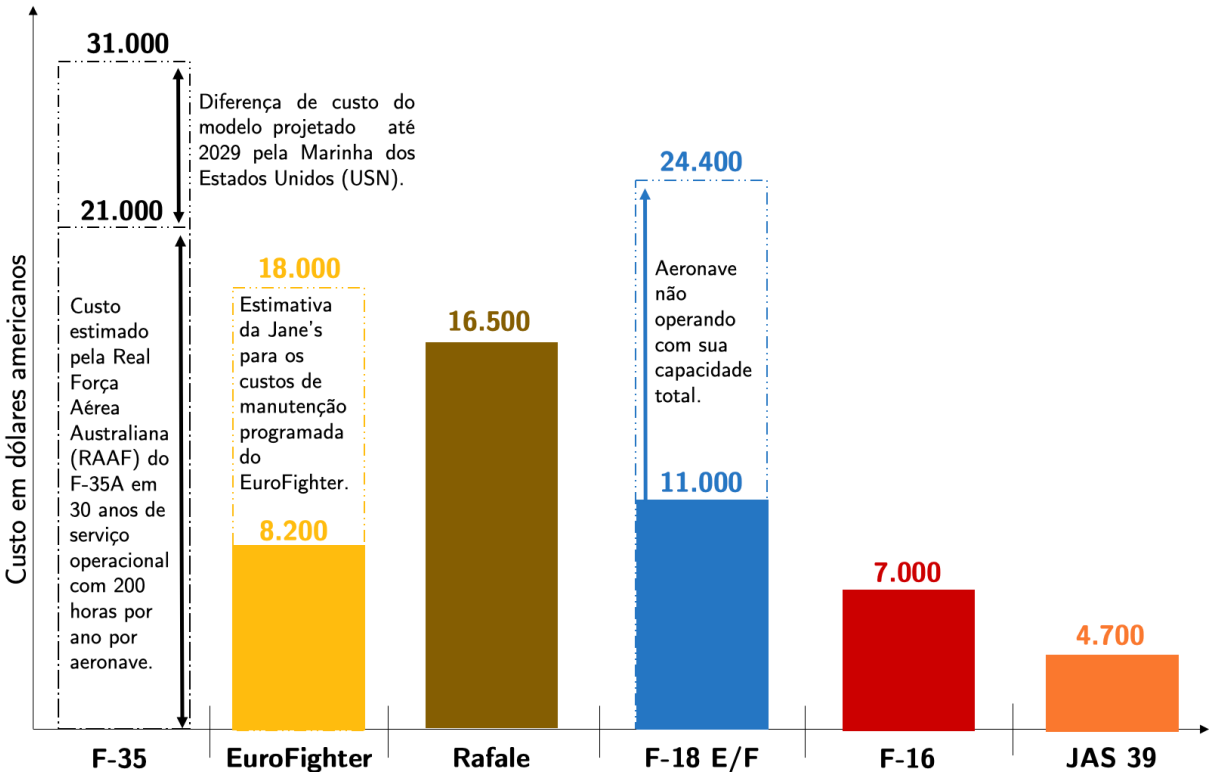


FIGURA 1.1 – Custo por hora de operação das seis aeronaves mais representativas do combate aéreo além do alcance visual.

Fonte: Jane's (2012)

Beyond Visual Range Air-to-Air Missile (BVRAAM) é o míssil utilizado no combate aéreo além do alcance visual. Orientado por radar, oferece uma capacidade de ataque contra alvos acima de 100 quilômetros (62 milhas náuticas) de distância. Hoyle (2008) demonstra o custo associado para cada míssil desse tipo como 2.600.000,00 dólares americanos. Esses mísseis são capazes de atingir distâncias de 20 milhas náuticas ou mais. Os AIM-120 *Advanced Medium-Range Air-to-Air Missile* (AMRAAM) são os mísseis dessa categoria mais utilizados no mundo para combate aéreo além do alcance visual. DTIC (2008) destaca que mais de 14.000 unidades do míssil AIM-120 AMRAAM foram produzidas para mais de 35 clientes internacionais no mundo inteiro.

Observa-se, dessa forma, que realizar treinamentos reais de combate desse tipo torna-se uma prática inviável, considerando a quantidade de pilotos de caça da Força Aérea Brasileira e a quantidade de recursos recebidos anualmente para tais fins. Portanto, o uso de simulações, principalmente do tipo construtiva, vem se tornando uma prática adotada pelas Força Armadas em diversos países. Em se tratando do combate aéreo além do alcance visual, o uso destes recursos computacionais, em que não há necessidade do uso

de aeronaves e mísseis reais, pode fornecer melhores parâmetros para o piloto durante o combate real através das análises dos dados coletados de diversos treinamentos simulados.

Em um combate aéreo além do alcance visual, o processo de determinação do momento exato de, após o lançamento de um míssil, realizar uma manobra defensiva, definida como (*cranking*), é baseado normalmente na avaliação da situação de combate por parte do piloto com base na sua intuição e experiência. Esse tempo diz respeito ao momento ideal de lançar um míssil e realizar uma manobra defensiva e assim determinar as melhores táticas para combates aéreos além do alcance visual que maximizem a probabilidade de abater as aeronaves inimigas e não sofrer danos. Com o uso das teorias de inteligência artificial é possível propor modelos que descrevam a situação do piloto em voo, com base em um processo de aprendizagem após um grande número de simulações realizadas em simulador específico para esse tipo de combate aéreo. Portanto, situações como a do momento ideal de lançamento de um míssil ou realizar uma manobra defensiva podem ser melhor avaliadas com um sistema embarcado de apoio à decisão. Tal sistema não tomaria decisões para o piloto, porém, por meio de análises quantitativas, forneceria ao piloto um panorama geral da sua situação a cada instante em um combate real, melhorando sua consciência situacional em voo permitindo uma melhor tomada de decisões.

Assim sendo, os objetivos principais da presente dissertação são: demonstrar o uso de um simulador de combate aéreo além do alcance visual para realizar treinamentos operacionais em estudos de caso específicos e a criação de um dispositivo embarcado de apoio à decisão para o piloto de combate aéreo além do alcance visual com respostas em tempo real.

1.3 Conteúdo dos capítulos

A presente dissertação é dividida em quatro capítulos: Fundamentação teórica, Metodologia, Resultados e discussões e Considerações finais. No início de cada capítulo, é feita uma breve descrição dos assuntos que serão abordados, que faz com o que o leitor se torne mais familiarizado com as ideias que serão apresentadas. Cada capítulo tem sua importância na construção de um método científico para apresentar, de forma clara e objetiva, o problema e sua solução proposta.

Inicialmente, o Capítulo 2 apresenta de forma detalhada os principais conceitos utilizados na construção da presente dissertação. Os temas combate aéreo além do alcance visual, ciência de dados, inteligência artificial, aprendizado de máquina e redes neurais artificiais serão explorados nesse capítulo e permitirão o entendimento dos conceitos importantes para compreensão da metodologia adotada na pesquisa. Além disso, discutem-se também

trabalhos relacionados cujos temas sejam correlatos a este, com o objetivo de comparar o presente trabalho ao estado da arte da literatura acadêmica concernente ao tema proposto.

Em seguida, o Capítulo 3, maior contribuição do trabalho, descreve de forma minuciosa a metodologia adotada para a solução do problema proposto. Primeiramente, é realizada uma explanação acerca do simulador de combate aéreo além do alcance visual utilizado para gerar as simulações dos cenários operacionais nesse estudo. Em seguida, discutem-se as particularidades da modelagem do combate aéreo, incluindo a descrição do estudo de caso utilizado para as análises realizadas na presente pesquisa e da estratégia adotada para realizar o procedimento de coleta e adequação das amostras da simulação. Então, a partir dos dados de entrada e saída obtidos das simulações de combate aéreo além do alcance visual, é descrito o processo de construção das redes neurais artificiais. As especificações e limitações do modelo são destacadas para mostrar o grau de generalização e aplicabilidade do estudo realizado na dissertação. Ao final do capítulo, define-se o termo consciência situacional, conceito muito importante para o sucesso em missões operacionais, e descreve-se a sua utilização no sistema de apoio à decisão para o combate aéreo descrito.

O Capítulo 4 apresenta os resultados obtidos e a avaliação apurada das implicações obtidas a partir da análise das redes neurais artificiais obtidas. Além disso, é feita também uma análise estatística descritiva preliminar, de forma a propiciar ao leitor uma visão global dos dados trabalhados nas análises. Ainda no mesmo Capítulo, é realizada uma verificação da robustez dos resultados por meio das métricas de desempenho adotadas previamente no Capítulo 3.

Por fim, o Capítulo 5 apresenta as considerações finais do trabalho. Nele o leitor é apresentado a uma síntese do procedimento metodológico utilizado e, principalmente, dos resultados fundamentais e suas implicações. Além disso, são destacadas as limitações inerentes a esta pesquisa, com o intuito de delimitar de maneira clara o estudo feito, bem como de estimular novos pesquisadores a dar continuidade a esse, aprimorando-o e expandindo-o. Sugestões de trabalhos futuros são feitas de acordo com as limitações consideradas na presente dissertação.

2 Fundamentação teórica

Neste capítulo são apresentados os principais conceitos teóricos sobre os quais se fundamenta o estudo de caso desenvolvido nesta dissertação. Inicialmente serão abordados definições e conceitos sobre o combate aéreo além do alcance visual (Seção 2.1), com o objetivo de introduzir o leitor acerca do conhecimento operacional necessário para compreensão do modelo que será abordado posteriormente nesse estudo.

Os conceitos básicos sobre *data science* ou ciência de dados são esclarecidos na Seção 2.2, que é um ramo moderno da computação aplicada que se tornou cada vez mais difundido na atualidade. Em seguida, é realizada uma exploração das definições, de forma sucinta, do conceito de inteligência artificial (Seção 2.3) e de aprendizado de máquina (Seção 2.4). Um levantamento histórico é realizado para entender a evolução dos temas ao longo dos anos. O objetivo é fazer o leitor entender a origem e importância do assunto e introduzir para o tema que será abordado na seção seguinte.

Posteriormente, na Seção 2.5, após a compreensão dos conceitos de inteligência artificial e aprendizado de máquina, é introduzida a definição do modelo computacional de redes neurais artificiais. A origem, conceitos, capacidades, aplicações e limitações serão compreendidos nesta seção.

Por fim, na Seção 2.6, é realizado um levantamento bibliográfico dos trabalhos acadêmicos com os temas discutidos nesse capítulo. Os principais estudos relacionados ao assunto são elucidados para destacar as diferenças do trabalho proposto aos demais, demonstrando os acréscimos da dissertação ao estado de conhecimento atual sobre o assunto.

2.1 Combate aéreo além do alcance visual

No combate aéreo moderno, mundialmente as Forças Aéreas têm aprimorado suas aeronaves e armamentos. O desenvolvimento de novas táticas de combate mais efetivas e o treinamento constante dos pilotos são de fato essenciais para garantir a soberania de uma nação. Os confrontos aéreos nos dias de hoje são divididos em combate por referências visuais, *Within Visual Range* (WVR), e combate além do alcance visual, *Beyond Visual*

Range (BVR). Esse último significa que os combatentes usam equipamentos de detecção aerotransportados para procurar o alvo inimigo e mísseis que fazem uso tanto do radar de bordo da aeronave lançadora quanto da parte interna do armamento. De acordo com Marques *et al.* (2015), o combate aéreo além do alcance visual, também conhecido como combate BVR, é caracterizado por sua dinamicidade devido às influências que as ações de uma aeronave têm nas outras.

Conforme Persing *et al.* (2003), as fases de engajamento do combate aéreo além do alcance visual podem ser divididas conforme ilustra a Figura 2.1.

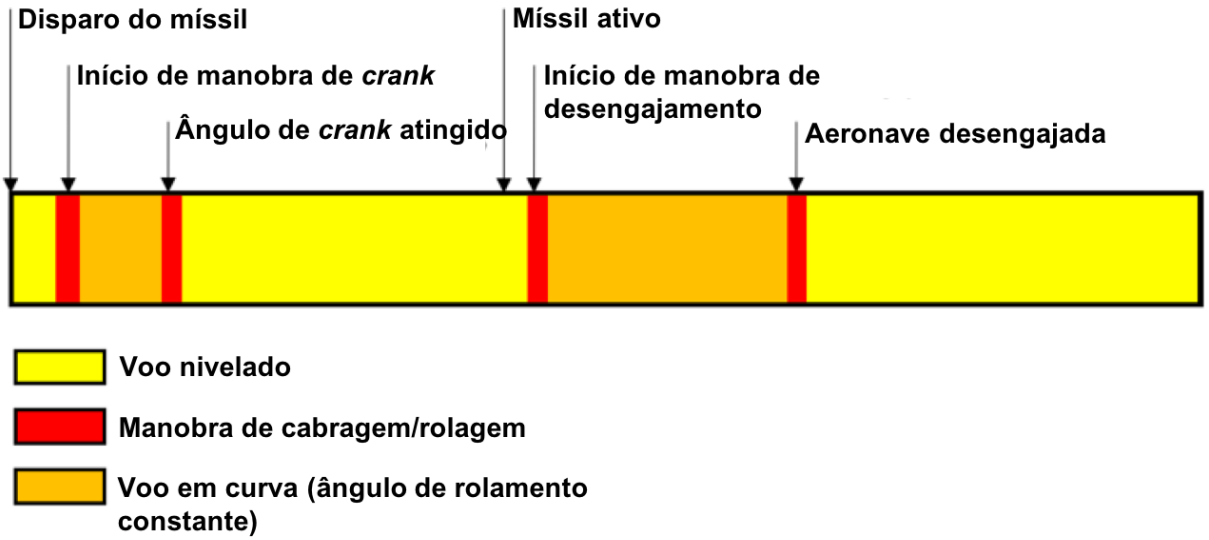


FIGURA 2.1 – Fases de engajamento do combate aéreo além do alcance visual.
Fonte: Persing *et al.* (2003)

Nota-se que tais fases se iniciam no momento do disparo do armamento, o que claramente indica que esta é uma decisão vital para qualquer modelo que se proponha a representar o comportamento de uma aeronave nesta modalidade de combate.

Antes disso, entretanto, a aeronave deve se direcionar ao alvo de maneira a colocá-lo em seu envelope de tiro. Ao fazê-lo, podem se realizar algumas manobras defensivas, tais como *cranking*, que é uma curva feita com o objetivo de se colocar a um *offset* angular com relação a outra aeronave. Geralmente, tais manobras são realizadas também logo após o disparo, conforme demonstrado na Figura 2.1, sendo o *offset* o ângulo máximo que mantém a aeronave inimiga dentro dos limites do *gimbal* radar.

É importante frisar que muitas das decisões de um piloto BVR se baseiam em informações de sensores, já que a distância impede qualquer identificação visual. Logo, o gerenciamento de tais sistemas é também de suma importância.

Entretanto, mesmo com o uso adequado dos sistemas disponíveis, informações relativas aos sistemas e armamentos do oponente não são necessariamente conhecidas. Sem tais

informações, fica comprometido o processo de engajamento, posto que não é possível saber o quanto o oponente está ameaçando a aeronave modelada.

Conforme Júnior (2011), inicialmente em um combate, a parte de engajamento é feita por navegação baseada em dados inerciais e do *Global Positioning System* (GPS) do qual se pode receber ou não atualizações por conexão de dados (*data-link*). Como o radar da aeronave tem um alcance muito maior do que o do míssil, caso não haja *data-link* entre a aeronave lançadora e o míssil em voo, haverá uma menor probabilidade de sucesso do que em um caso em que se tenha tal dispositivo. Entretanto, mesmo mísseis sem dispositivos de atualizações de dados são capazes de obter sucesso no abate da aeronave inimiga devido a sua habilidade de procurar pelo alvo dentro do envelope do seu próprio radar. Desta forma, quanto mais rápido um míssil chegar à posição prevista do alvo, maior será sua probabilidade de achar a aeronave inimiga. Isto é verdade porque mesmo mudanças bruscas de direção por parte da aeronave-alvo produzirão pequenos movimentos em relação a sua posição prevista devido ao grande diferencial de velocidade entre o míssil e o alvo (o míssil é até quatro vezes mais rápido do que a aeronave-alvo). Portanto, quanto maior a energia associada a determinado míssil, maior sua capacidade de alterar a sua rota de ataque e atingir o alvo. Uma maneira de se aumentar a probabilidade de sucesso é retardar o lançamento do míssil, pois ele voará uma distância menor e, consequentemente, dará menos tempo para a aeronave-alvo sair da posição prevista. A grande desvantagem desta tática é que a aeronave lançadora se expõe aos mísseis inimigos ao utilizá-la. Isto demonstra que o procedimento de combate empregado tem grande influência no sucesso de um engajamento BVR.

Uma vez que o míssil foi lançado, o piloto deseja diminuir as chances de o oponente também realizar o lançamento de um projétil. Para tal, é necessário a diminuição da proximidade em relação ao alvo. Dessa forma, inicialmente, o piloto muda a sua direção de voo em uma pequena angulação. Devido as relações de tempo e distância dos combates BVR, em geral, é necessário considerar a ação de muitas variáveis dinâmicas e buscar uma maior probabilidade de sucesso conhecida como probabilidade de abate. A partir do lançamento, o míssil estará se dirigindo à posição futura estimada do alvo. Este, por sua vez, provavelmente não irá para esta posição indesejável, realizando assim o comportamento que é dele esperado no combate aéreo, isto é, adaptará sua rota para fugir das ameaças do adversário.

Manter uma alta probabilidade de abate exigirá que se transmita a posição do alvo para o míssil e isso só é possível com a manutenção do rastreio do alvo pela aeronave até que o míssil possa tomar essa ação de forma autônoma, isto é, quando se torna ativo. Para a realização desse tipo de procedimento, é necessário manter a aeronave alvo dentro do alcance de atuação do radar da aeronave lançadora. O *cranking* é a manobra de disparar um míssil e realizar o seu guiamento enquanto se faz um procedimento defensivo para fugir

do ataque inimigo e não ser abatido. Em um combate aéreo BVR, não são apenas a área de detecção do radar e o alcance do míssil que limitam o ataque, mas também as direções adotadas por cada aeronave (DANTAS, 2017).

Como as aeronaves oponentes estão a uma distância que não permite sua identificação visual, o combate, em geral, baseia-se em informações dos sensores disponíveis, tais como radares e sistemas de *Radar Warning Receiver* (RWR). As informações oriundas de tais sistemas por vezes são incompletas, já que interferências eletromagnéticas podem gerar inconsistências na identificação dos alvos, que, dependendo de sua assinatura radar, podem nem mesmo ser identificáveis. Isso ocorre frequentemente com armamentos, o que faz com que, na maioria das vezes, os pilotos não possam precisar o momento de disparo de um míssil pela aeronave oponente, já que não o detectam. Dessa forma, as decisões, principalmente no que tange a manobras defensivas, são balizadas por crenças do piloto com relação ao seu oponente, relativas tanto à realização de um disparo, quanto às próprias características dos equipamentos e doutrinas utilizados. Tais crenças guiam o comportamento do piloto, juntamente com as informações disponibilizadas por seus sensores e as características dos armamentos que sua aeronave possui. Borck *et al.* (2015) relata que frequentemente se tem poucas informações com relação ao oponente e é em meio a incertezas e a longas distâncias que táticas precisas têm de ser executadas.

Conforme Costa *et al.* (2017) afirmam, a modelagem do comportamento de uma aeronave no contexto de simulação BVR é um desafio, apresentando uma série de decisões sob incerteza, que delineiam as reações das entidades simuladas às ameaças identificadas e estimadas no teatro de operações.

Em resumo, a fim de ilustrar o comportamento adotado pelos pilotos no combate aéreo além do alcance visual, apresenta-se, na Figura 2.2, o fluxograma das principais situações operacionais que ocorre nesse tipo de cenário operacional.

Os processos decisórios que ocorrem nos nós dependem intrinsecamente de fatores como filosofia de tiro, efetividade esperada dos disparos e dos *thresholds* de ameaça, que, por sua vez, dependem das crenças a respeito da aeronave inimiga. Todos esses fatores serão abordados no Capítulo 3.

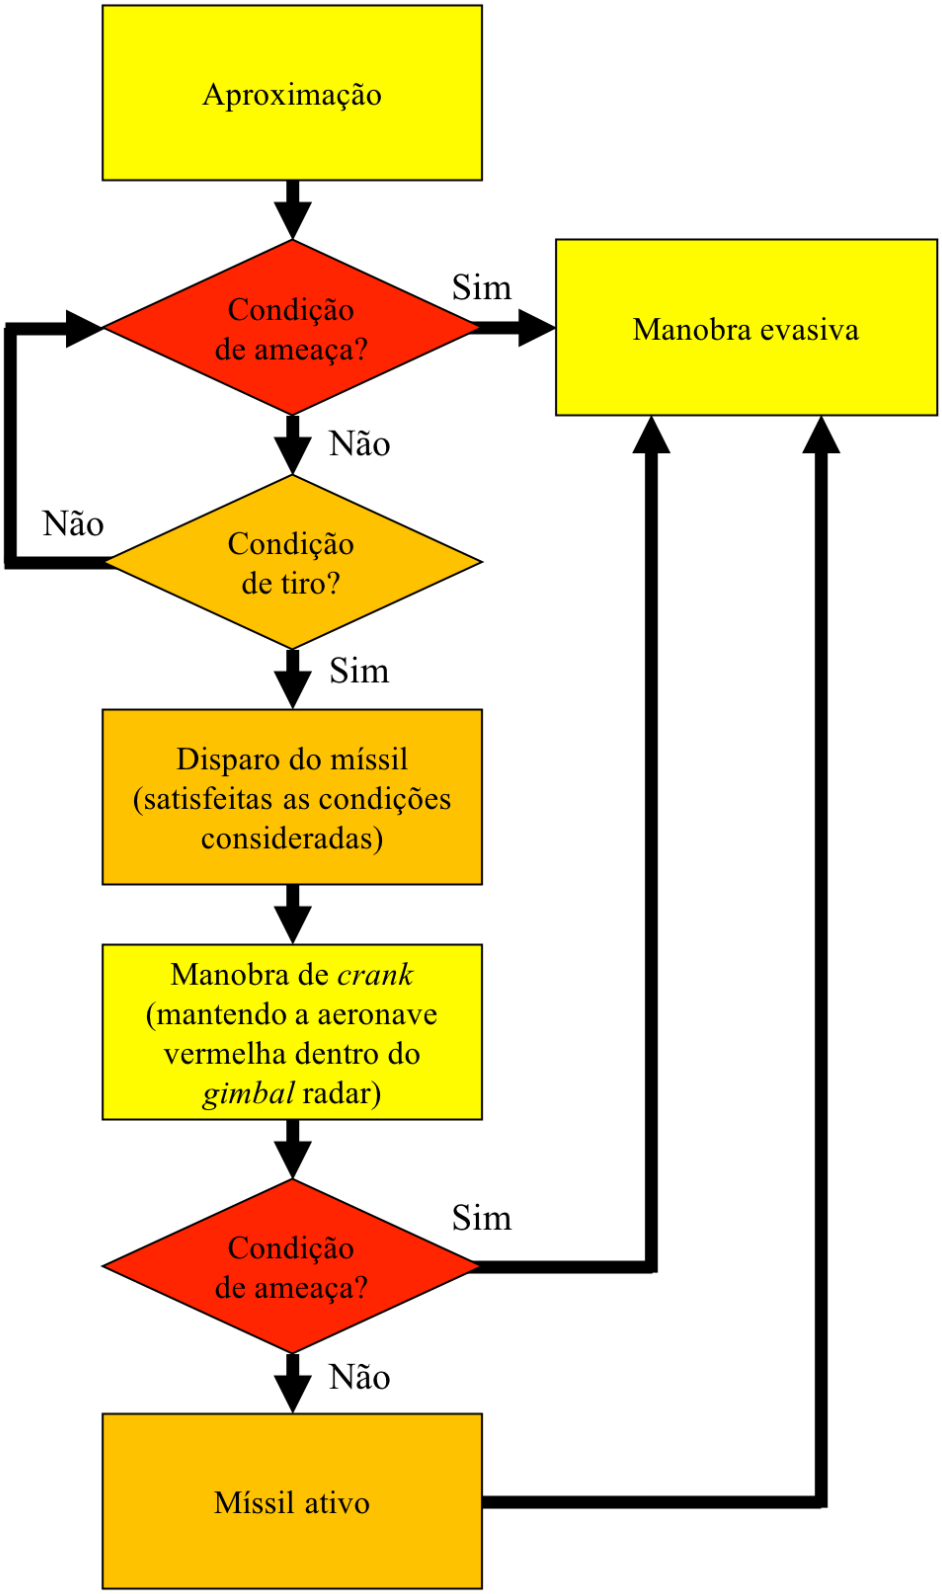


FIGURA 2.2 – Fluxograma representativo do modelo comportamental com combate aéreo além do alcance visual.

2.2 Ciência de dados

Nos últimos anos, a quantidade disponível de dados tem crescido devido a políticas públicas de disseminação de informação e pelos avanços tecnológicos em instrumentos de aquisição e sistemas computacionais de armazenamento e difusão (GRUS, 2015) (DIETRICH *et al.*, 2015).

A disponibilização dessas bases de dados tem grande valor para a compreensão de fenômenos naturais, sociais, econômicos e políticos. No entanto, a extração eficiente de informações desses dados não tem acompanhado o mesmo ritmo. Os desafios muitas vezes encontrados por usuários desses dados envolvem questões como capacidade computacional para armazenamento e processamento, ou a dificuldade em obter ou escolher ferramentas para a realização das análises. Frequentemente, o volume, a densidade, e a dimensionalidade também são fatores críticos que dificultam o processo de extração de informações pelo analista (CÂMARA *et al.*, 2016).

A Análise Exploratória de Dados, do inglês *Exploratory Data Analysis* (EDA), é uma abordagem para analisar conjuntos de dados para extrair suas principais características, muitas vezes por métodos visuais (DIETRICH *et al.*, 2015). O objetivo principal é fornecer ao cientista de dados uma primeira compreensão do conjunto de informações que está sendo analisado e, possivelmente, fornecer meios para formular hipóteses ou avaliar a necessidade de coletas de novos dados. Dada a diversidade de opções disponíveis, documentar a experiência na seleção de tecnologias, técnicas e métodos de visualização de dados ajuda pesquisadores a avaliar como diferentes propostas podem atender suas necessidades de análise de dados (CÂMARA *et al.*, 2016).

2.3 Inteligência artificial

Haykin (2001) define Inteligência Artificial (IA) como o estudo de agentes inteligentes que recebem percepções do ambiente e executem ações. A expectativa nesse estudo é que agentes inteligentes possam ser sistemas que podem decidir o que fazer e quando fazer de forma autônoma. O campo da inteligência artificial tenta não apenas compreender, mas também construir entidades inteligentes. Portanto, o objetivo central da IA inclui a criação de teorias e modelos para a capacidade cognitiva, e também a construção de sistemas computacionais baseados nestes modelos. Uma forma encontrada para impulsionar a pesquisa em IA é a proposta de problemas padrão, que permitem que diferentes soluções e enfoques sejam comparados.

A IA é uma das ciências mais recentes e começou logo após a Segunda Guerra Mundial por Turing (1950), e o próprio nome IA foi cunhado em 1956 para sistematizar e automatizar

tarefas intelectuais (MCCARTHY *et al.*, 1955). Ela foi construída a partir de ideias filosóficas, científicas e tecnológicas herdadas de outras ciências, algumas tão antigas quanto a lógica (BITTENCOURT, 1998). Desde seus primórdios, a IA gerou polêmica, a começar pelo seu próprio nome, considerado presunçoso por alguns, até a definição de seus objetivos e metodologias. O desconhecimento dos princípios que fundamentam a inteligência, por um lado, e dos limites práticos da capacidade de processamento dos computadores, por outro, levaram periodicamente a promessas exageradas e a correspondentes decepções (MARTINS, 2003).

Bittencourt (1998) afirma que o objetivo central da IA é simultaneamente teórico e prático: por um lado pela criação de teorias e modelos de capacidade cognitiva e por outro com a implantação de sistemas computacionais baseados nestes modelos.

Um conceito importante quando se trata de inteligência artificial é o de racionalidade que se trata de a máquina realizar a tarefa de maneira satisfatória com os dados que se tem disponíveis. Um agente agirá de forma a atingir os seus objetivos e não de forma a impedir que esses mesmos objetivos sejam atingidos. Em cada instante, face ao seu conhecimento e de acordo com as suas capacidades tentará executar a melhor ação para cumprir esses objetivos. Essa definição é muito importante, pois faz ligação com o próximo assunto que será analisado no presente capítulo, aprendizado de máquina, na Seção 2.4.

2.4 Aprendizado de máquina

Rätsch (2004) descreve o aprendizado de máquina como um sub-campo da inteligência artificial, um campo que surgiu dentro da ciência da computação, e aborda a questão sobre como tornar as máquinas aptas a aprender. No contexto em que se insere, o aprendizado se refere à inferência indutiva. O objetivo principal do aprendizado de máquina é generalizar além dos exemplos existentes no conjunto de treinamento, pois independente da quantidade de dados existentes é muito improvável que, durante os testes, exatamente os mesmos exemplos apareçam.

Mitchell (2006) afirma que ainda não é possível fazer computadores aprenderem tão bem quanto as pessoas, porém algoritmos criados são eficientes para várias tarefas de aprendizado, e os estudos teóricos sobre aprendizado estão permitindo que novas técnicas sejam desenvolvidas.

Domingos (2012) destaca que um dos aspectos que tornam esse um tema de importância é a dimensão dos problemas a serem resolvidos. A intuição humana é treinada em um universo tri-dimensional, logo existe uma dificuldade natural de se resolver problemas de dimensões maiores sem a utilização de ferramentas adequadas. Além disso, a capacidade de armazenamento dos computadores e a quantidade de dados disponíveis cresce vertigi-

nosamente e há muito o ser humano não consegue processar esse grande volume sem o auxílio de ferramentas de software.

Apesar da grande dimensão, inerente a certos problemas, ser uma das principais motivações de utilizar algoritmos de aprendizado de máquina, ela traz uma dificuldade para a avaliação dos resultados obtidos com os modelos gerados por esses algoritmos, já que muitas vezes a intuição não é suficiente para avaliar certos aspectos. Para tanto, técnicas para avaliação dos algoritmos e modelos gerados são muito estudadas e necessárias para permitir entender o grau de confiança que se pode empregar sobre os resultados obtidos (SCHMOELLER; CAMPONOGARA, 2016).

Os métodos de aprendizagem são convencionalmente divididos em aprendizado supervisionado, não supervisionado e de reforço. Quando se tenta prever uma variável dependente a partir de uma lista de variáveis independentes o método de aprendizado se classifica como supervisionado. A aprendizagem supervisionada é amplamente utilizada na classificação, aproximação, controle, modelagem e identificação, processamento de sinais e otimização. De uma forma geral, com aprendizado não supervisionado deseja-se encontrar uma representação mais informativa dos dados que estão disponíveis. Geralmente, essa representação mais informativa é também mais simples, condensando a informação em pontos mais relevantes. Problemas de aprendizado não supervisionados são usados principalmente para clusterização, quantização vetorial, extração de características, codificação de sinais e análise de dados. A terceira abordagem de aprendizagem de máquinas é a chamada aprendizagem por reforço, em que a máquina tenta aprender qual é a melhor ação a ser tomada, dependendo das circunstâncias na qual essa ação será executada. O aprendizado de reforço é geralmente usado em controle e inteligência artificial.

Não existe uma melhor ou pior abordagem de aprendizado de máquina. A escolha do tipo de método vai depender do que está sendo analisado. Cada problema possui suas peculiaridades, e uma maneira de resolução que funcionou bem para um tipo de problema pode ser não tão eficiente para outro tipo. Cabe ao cientista de dados tomar a decisão para a escolha do método a ser adotado para a solução do problema a ser analisado.

Para a modelagem de aprendizado de máquina do combate aéreo além do alcance visual será utilizado, no escopo do presente trabalho, o aprendizado de máquina supervisionado por meio do uso de Redes Neurais Artificiais (RNA), pois a utilização do simulador BVR fornece determinados valores para as variáveis de saída a partir de uma certa configuração das variáveis de entrada. As regras de aprendizado de máquina são algoritmos para encontrar pesos adequados ou outros parâmetros de rede. A aprendizagem é uma capacidade fundamental das redes neurais e pode ser vista como um problema de otimização não-linear para encontrar um conjunto de parâmetros de rede que minimiza a função de custo para determinados exemplos. Esse tipo de estimativa de parâmetro também é chamado de algoritmo de aprendizado ou treinamento (DU; SWAMY, 2014).

2.5 Redes neurais artificiais

Nesta seção serão discutidos os conceitos mais importantes acerca das redes neurais artificiais. Inicialmente serão descritas algumas definições e será realizado um levantamento histórico dos algoritmos de redes neurais. Em seguida, serão demonstrados os conceitos e a estrutura do neurônio artificial, que será comparado com um neurônio biológico. O termo *perceptron* também será definido. Assuntos como funções de ativação, arquitetura, treinamento e *overfitting* também serão abordados nesta seção. Por fim, será explicado o fato das redes neurais se comportarem como um aproximador universal de funções, que será um conceito muito importante para explicar a escolha de sua aplicação no presente estudo.

2.5.1 Definição e histórico

Redes neurais artificiais tiveram seu advento na década de 40, mas, até pouco tempo atrás, elas eram extremamente difíceis de treinar. Com um artigo Glorot e Bengio (2010) o assunto, que já era estudado desde os anos 90, começou um processo de maior entendimento das dificuldades em se treinar redes neurais.

As redes neurais artificiais são modelos cuja estrutura procurou representar a organização de um cérebro humano (BRAGA, 2007). Com o desenvolvimento da Inteligência Artificial surgiu a ideia de representar por meio de determinados programas o funcionamento do processo de aprendizagem do cérebro humano.

McCulloch e Pitts (1943) descreve o primeiro modelo de neurônio artificial em um trabalho que discute uma analogia entre o processo de comunicação das células nervosas vivas e o processo de comunicação por transmissão elétrica. Dessa forma, demonstrar-se que é possível conectar os neurônios formais e formar uma rede capaz de executar funções complexas.

Hebb (1949) desenvolve a Regra de Hebb que explica o aprendizado em nós biológicos com base no esforço das ligações sinápticas entre nós excitados e foi o início do desenvolvimento dos algoritmos de aprendizado das RNAs. Demonstrou-se que a aprendizagem de redes neurais é conseguida através da variação dos pesos de entrada dos nodos. A teoria proposta é baseada no reforço das ligações sinápticas entre nodos excitados.

Alguns anos depois, Widrow e Hoff (1960) demonstrou uma nova regra de aprendizado, a Regra Delta ou regra de Widrow-Hoff, baseado no método do gradiente para minimização do erro na saída de um neurônio com resposta linear que ainda hoje é bastante utilizada.

Rosenblatt (1962) apresenta o modelo do *Perceptron*, onde os neurônios se encontravam organizados em uma única camada, conectados diretamente aos nós de entrada e aos de

saída e propôs um algoritmo para treinar a rede. O *perceptron* mais simples proposto atua como classificador, reconhecendo padrões e dividindo o espaço de entrada em regiões distintas para cada uma das classes existentes. No modelo do neurônio artificial, as variáveis de entrada são combinadas linearmente, por meio dos pesos sinápticos. O resultado desta combinação é usado como argumento de uma função, chamada de função de ativação, que pode ser linear ou não e será melhor descrita nas próximas seções.

Em Minsky e Papert (1969), são abordadas algumas falhas das redes neurais artificiais e algumas tarefas que o *perceptron* não podia desempenhar com problemas não-linearmente separáveis como: detecção de paridade, conectividade e simetria. O mais importante está relacionado ao cálculo de alguns problemas sem solução pelo *perceptron* simples, como a função XOR.

A década de 1970 foi um período em que os estudos feitos de redes neurais artificiais estagnaram principalmente devidos aos trabalhos do final da década de 60. Costuma-se dizer que foi uma década perdida, pois os trabalhos relevantes na área paralisaram e retornaram apenas na década seguinte com Kohonen *et al.* (1977) que destacou estudos sobre as memórias associativas.

Hopfield (1982) mostrou a relação entre as redes recorrentes auto-associativas e sistemas físicos e gerou um grande repercurssão no meio acadêmico. Kohonen (1982) publicou sobre os mapas auto-organizáveis que propõe um novo tipo de rede baseado em uma rede unidimensional ou bidimensional.

Cohen e Grossberg (1983) desenvolveram a teoria da ressonância adaptativa ou *Adaptive Resonance Theory* (ART) que é uma teoria cognitiva e neural de como o cérebro pode aprender rapidamente, e lembrar e reconhecer, estavelmente, objetos e eventos em um mundo em mudança. Foi proposto, portanto, que um cérebro ou uma máquina pode aprender rapidamente sobre novos objetos e eventos sem ser forçado a esquecer memórias previamente aprendidas, mas ainda assim úteis.

Rumelhart *et al.* (1988) divulgam o desenvolvimento do algoritmo de retropropagação ou ainda *back-propagation*, utilizado para a aprendizagem por retropropagação. Tal algoritmo tornou-se rapidamente o mais utilizado para o treinamento de *perceptrons* de múltiplas camadas (HAYKIN, 2001). Contudo, futuramente se descobriu que Werbos (1974), na sua tese de doutorado na Universidade de Harvard, já tinha proposto o algoritmo da retropropagação anteriormente.

Broomhead e Lowe (1988) descreveram um novo tipo de redes *feedforward* utilizando funções de base radial ou ainda *Radial Basis Function* (RBF). Essas funções são utilizadas ainda hoje para aplicações com aprendizado de tipo supervisionado.

Vapnik (1995) propôs um novo tipo de redes neurais de aprendizado supervisionado, chamado de máquina de vetor de suporte ou *Support Vector Machine* (SVM) adequado

para utilização em reconhecimento de padrões, regressão e problemas de estimação de densidade (HAYKIN, 2001). De forma resumida, uma SVM encontra uma linha de separação, mais comumente chamada de hiperplano entre dados de duas classes. Essa linha busca maximizar a distância entre os pontos mais próximos em relação a cada uma das classes.

Hinton *et al.* (2006) apresentam as *Deep Belief Networks*, redes neurais profundas que podem ser treinadas camada por camada gradativamente (BENGIO, 2009). Foi demonstrado como eliminar os efeitos explicativos que tornam a inferência difícil em redes profundas densamente conectadas que possuem muitas camadas ocultas.

Por fim, Glorot e Bengio (2010) destaca um dos maiores avanços realizados nos últimos anos em entender e combater as dificuldades de treinar redes neurais artificiais *deep feedforward*.

2.5.2 Neurônio artificial

O neurônio artificial é o elemento básico de construção das redes neurais artificiais e seu funcionamento, conforme proposto por McCulloch e Pitts (1943), era baseado nos estudos da época sobre os neurônios biológicos. Há vários tipos de redes neurais artificiais, mas todos eles compõem-se de unidades de processamento simples que são chamadas de neurônios organizadas em camadas e interligadas por conexões geralmente associadas a pesos que possuem a finalidade de ponderar cada variável de entrada. A Figura 2.3 mostra um modelo de neurônio artificial e evidencia as suas unidades constituintes.

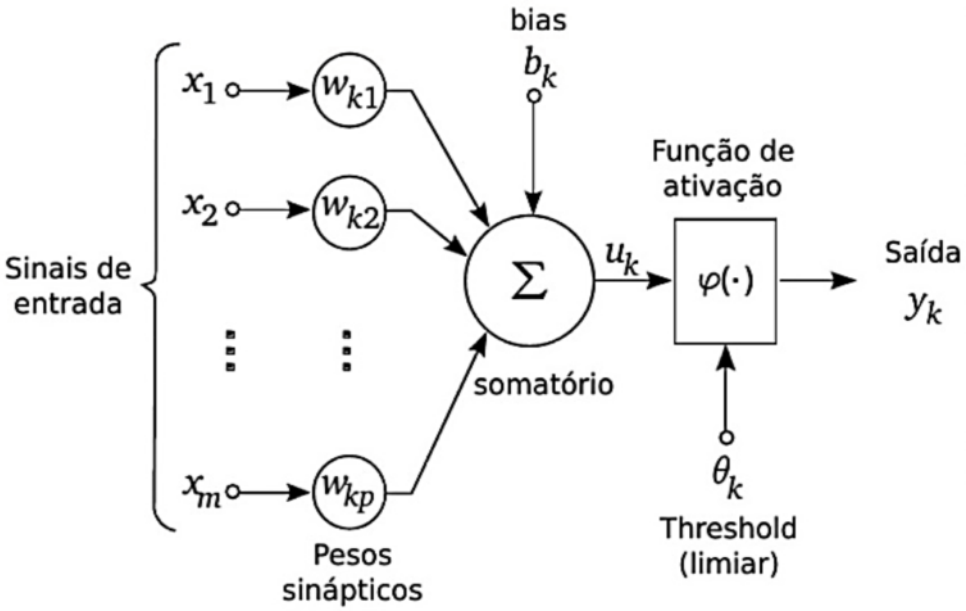
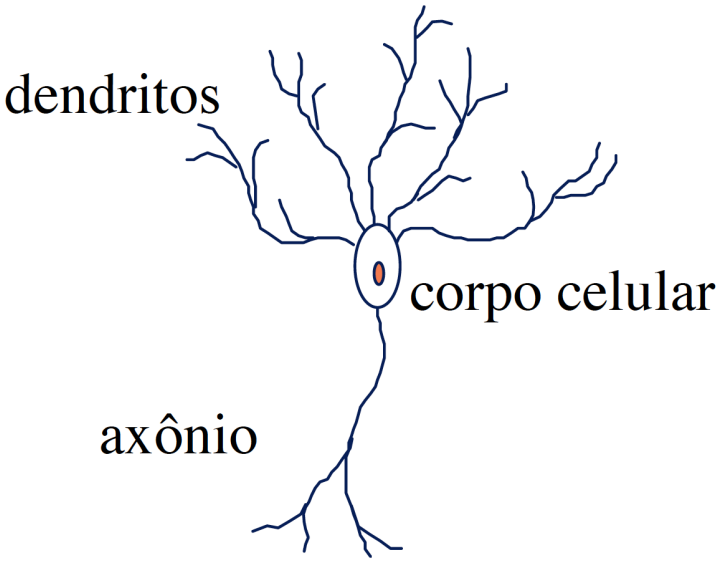
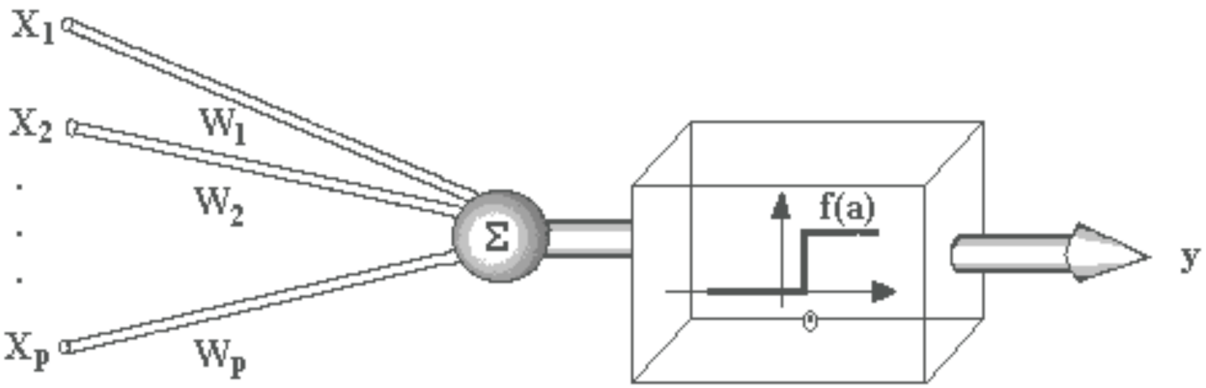


FIGURA 2.3 – Modelo de um neurônio artificial.
Fonte: McCulloch e Pitts (1943)

A funcionalidade do neurônio artificial é formada pela camada de entrada que têm a função dos dendritos do neurônio biológico, x_1, x_2,..., x_m, que é ponderada pelos pesos sinápticos cujos valores podem ser positivos ou negativos , w_{k1}, w_{k2},..., w_{kp}, onde é realizada uma combinação linear, adicionada pelo valor de *bias* cuja função é aumentar ou diminuir a entrada da função de saída do neurônio, b_k. Observa-se que valores negativos do *bias* têm como efeito de reduzir o potencial de ativação do neurônio, assim como valores positivos tendem a aumentá-lo. O resultado gerado pela combinação linear é dado por u_k, que é limitado por uma função de ativação, $\varphi(.)$, podendo ela ser linear ou não, para então adicionar um limiar θ_k para gerar a saída estimada pela rede neural artificial dado por y_k, que é semelhante ao axônio do neurônio biológico. O corpo celular do neurônio é composto pelo somador central descrito anteriormente. A Figura 2.4 demonstra uma analogia entre os neurônios biológicos e artificiais.



(a) Neurônio biológico.



(b) Neurônio artificial.

FIGURA 2.4 – Analogia entre os neurônios biológicos e artificiais
Fonte: Cerqueira *et al.* (2001)

Observa-se que o efeito de cada uma das sinapses é calculado pelo produto x_i por w_i. O corpo do neurônio artificial é constituído por um dispositivo que soma os diferentes produtos através de uma soma ponderada que é comparada com o limiar θ do neurônio. Quando a soma é superior ou igual a esse valor, o neurônio é ativado por meio de uma função de ativação que ativa a saída. Caso a soma não atinja o valor esperado, o neurônio permanece desativo (BRAGA, 2007). Portanto, Haykin (2001) descreve a propriedade "tudo ou nada" como a que o neurônio terá sua saída ativa somente quando o somatório dos produtos x_i por w_i for igual ou maior do que o o limiar θ.

Haykin (2001) define os três elementos básicos de um neurônio artificial como sendo um conjunto de sinapses ou elos de conexão, um somador e uma função de ativação que também pode ser chamada de função restritiva, já que limita o intervalo do sinal de saída do neurônio. A seguir será feita uma análise mais aprofundada das funções mais importantes nos estudos de redes neurais artificiais.

2.5.3 Funções de ativação

Foi visto na subção 2.5.2 a importância das funções de ativação na construção das redes neurais artificiais. O uso de algumas ferramentas como por exemplo o uso de funções de ativação mais inteligentes permite acelerar os treinamentos das RNA's. Nesta subseção serão abordadas as mais utilizadas funções em RNA, entender como elas se relacionam com o problema dos gradientes e será discutido como é possível alterar as não-linearidades. Em especial na presente dissertação, serão analisadas as funções sigmoide ou logística e tangente hiperbólica (TanH) e unidade linear retificada ou *Rectified Linear Unit* (ReLU). Existem ainda as funções linear, função de limiar ou degrau, Unidade Linear Exponencial ou *Exponential Linear Unit* (ELU) (CLEVERT *et al.*, 2015; XU *et al.*, 2015) e Unidade Linear Retificada com Vazamento (MAAS *et al.*, 2013).

2.5.3.1 Sigmoide

Funções de ativação sigmoidais podem ser usadas nos neurônios da camada de saída, em problemas de reconhecimento de padrões onde, em geral, a saída da rede é geralmente binária (DEMUTH, 2000). Funções lineares são geralmente utilizadas em problemas de aproximação de funções (CERQUEIRA *et al.*, 2001). A função sigmoide ou logística e sua derivada são dadas nas equações abaixo.

$$\sigma(x) = \frac{1}{1 + e^x} \tag{2.1}$$

$$\sigma'(x) = \sigma(x)(1 - \sigma(x)) \tag{2.2}$$

Até pouco tempo atrás, a função sigmoide era a mais utilizada em redes neurais, por serem biologicamente mais aceitáveis por terem um comportamento análogo. Como neurônios biológicos funcionam de forma binária ora sendo ativado ou não, a função sigmoide é uma boa forma de modelar esse comportamento, já que assume valores apenas entre 0, quando se tem a não ativação e 1, quando ocorrer a ativação. No entanto, se olharmos sua derivada, podemos ver que ela satura para valores acima de 5 e abaixo de -5. Com essas derivadas tendendo a zero, a propagação do gradiente desvanece nessas regiões, causando dificuldades no treinamento. A Figura 2.5 ilustra a função sigmoide e sua derivada.

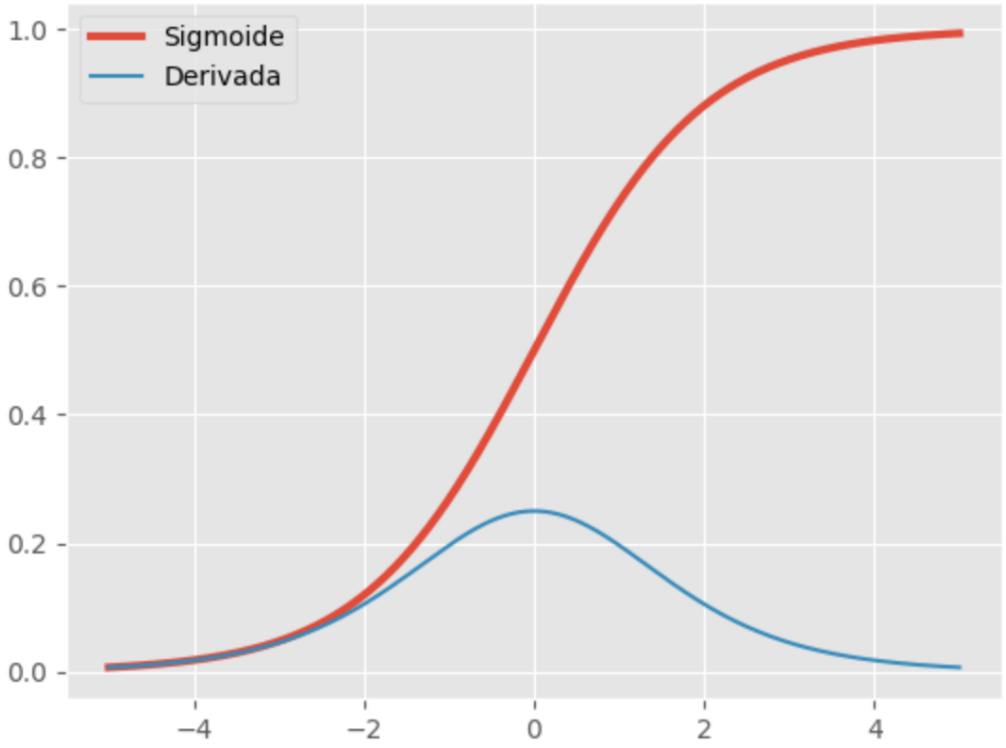


FIGURA 2.5 – Função sigmoide e sua derivada.

Segundo Haykin (2001), a função mais utilizada no projeto de redes neurais é a função sigmoide, que mantém um balanceamento adequado entre comportamento linear e não-linear. Mais ainda, observa-se que a derivada da função sigmoide é sempre menor que 1. Isso pode gerar problemas, fazendo com que desvaneça o produto dado pela regra da cadeia na propagação dos gradientes.

Ela ainda pode ser utilizada na saída da RNA, para modelar variáveis binárias. Além disso, alguns modelos probabilísticos, redes neurais recorrentes e alguns modelos não supervisionados têm restrições que tornam uma função sigmoidal necessária. No geral, a

função logística praticamente desapareceu dos modelos modernos de redes neurais mais convencionais.

2.5.3.2 Tangente hiperbólica

Similar a função sigmoide, a função Tangente Hiperbólica (TanH) também tem um formato semelhante, mas varia de -1 a 1, em vez de 0 a 1 como na sigmoide. A TanH se aproxima mais da identidade, sendo assim uma alternativa mais atraente do que a sigmoide para servir de ativação às camadas ocultas das RNAs. A TanH e sua derivada são dadas, respectivamente, por:

$$tanh(x) = 2\sigma(2x) - 1 \tag{2.3}$$

$$tanh'(x) = 1 - tanh^2(x) \tag{2.4}$$

Podemos ver que as saturações ainda estão presentes, mas o valor da derivada é maior, chegando ao máximo de 1 quando $x = 0$. Por esse motivo, quando uma função sigmoidal precisa ser utilizada, recomenda-se a TanH no lugar da sigmoide. A Figura 2.6 demonstra a função sigmoide e sua derivada.

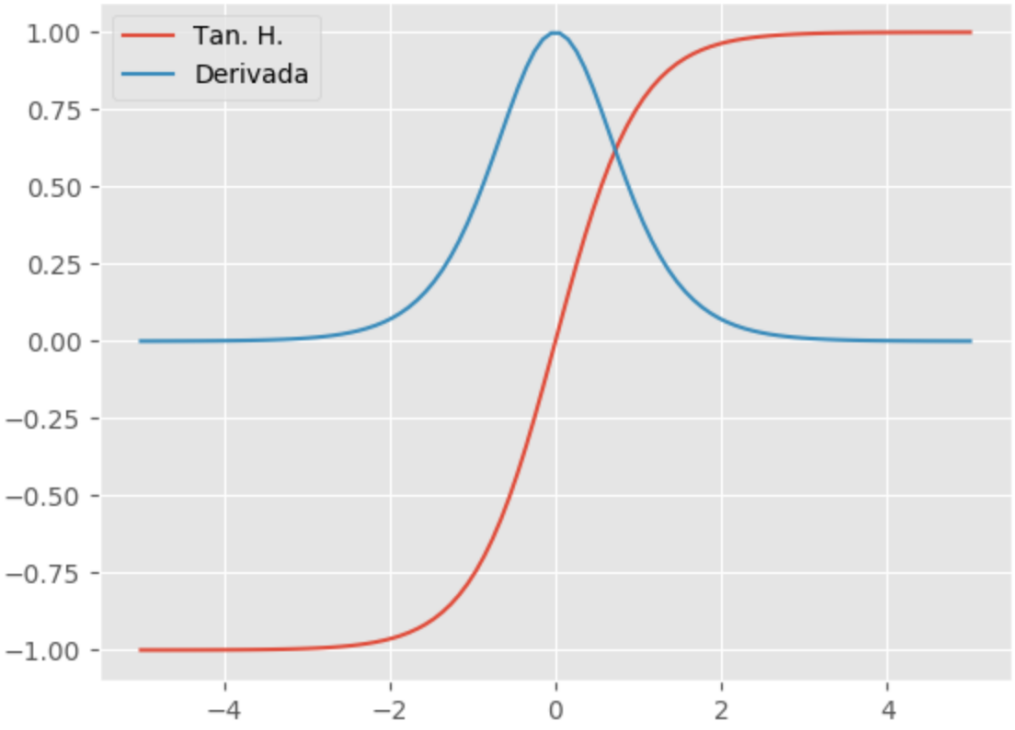


FIGURA 2.6 – Função tangente hiperbólica e sua derivada.

2.5.3.3 Unidade linear retificada

Unidade linear retificada ou ainda *Rectified Linear Unit* (ReLU) é a função de ativação mais amplamente utilizada ao projetar redes neurais atualmente. A ativação linear retificada e sua derivada são dadas nas equações abaixo.

$$ReLU(x) = max\{0, x\} \tag{2.5}$$

$$ReLU'(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases} \tag{2.6}$$

Redes com a função ReLU são fáceis de otimizar, já que a ReLU é extremamente parecida com a função identidade. A única diferença é que a ReLU produz zero em metade do seu domínio. Como consequência, as derivadas se mantêm grandes enquanto a unidade estiver ativa. A Figura 2.7 mostra o comportamento das curvas da função ReLU e sua derivada.

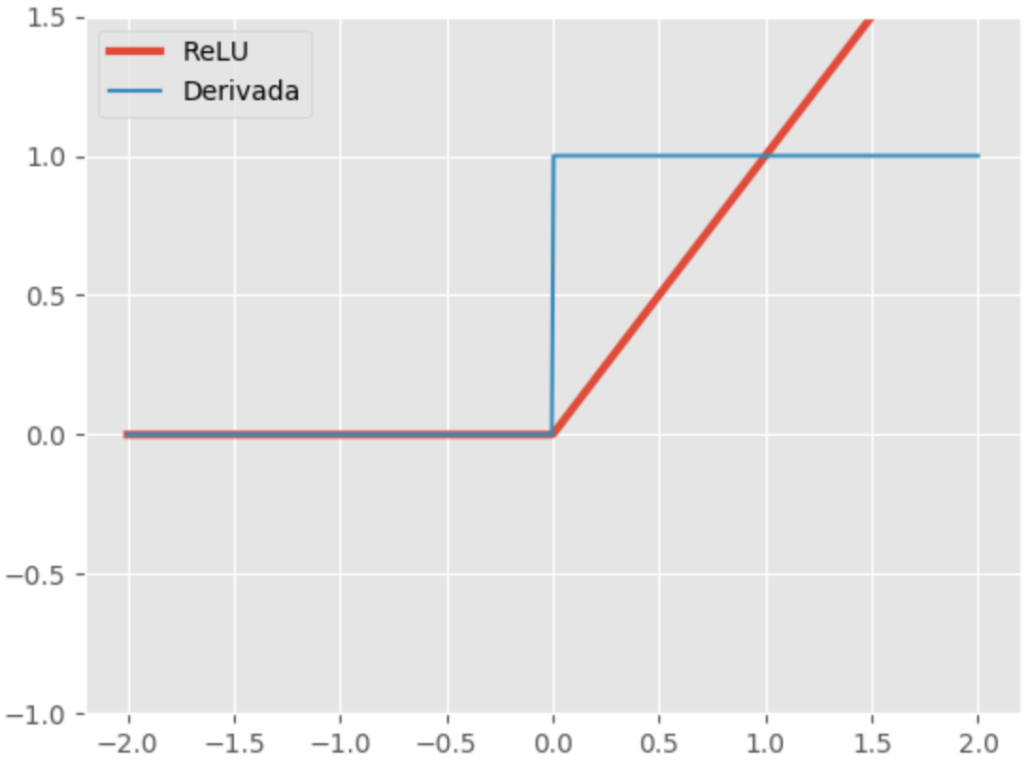


FIGURA 2.7 – Função unidade linear retificada e sua derivada.

A principal vantagem de usar a função ReLU sobre outras funções de ativação é que ela não ativa todos os neurônios ao mesmo tempo. Isso significa que caso se tenha uma entrada negativa na rede, ela será convertida em zero e o neurônio não será ativado. Isso

significa que, ao mesmo tempo, apenas alguns neurônios são ativados, tornando a rede esparsa e eficiente e fácil para a computação.

A ativação ReLU é muito mais eficiente do que as funções sigmoidais vistas acima e é uma das descobertas que contribuiu de forma significante para a recente popularidade de *Deep Learning*. Essa não linearidade é um ótimo exemplo de como a simplicidade pode ser extremamente poderosa.

Entretanto, ReLU também pode ter problemas com os gradientes que se deslocam em direção a zero. Uma desvantagem da ativação ReLU é que unidades tendem se estagnar durante o treinamento, um fenômeno que faz com que o neurônio passe a produzir apenas zeros. Isso acontece quando a soma ponderada antes da aplicação da ReLU se torna negativa, fazendo com que a unidade produza zero. Nessa região, a derivada também é zero, fazendo com que os parâmetros dos pesos sinápticos da rede deixem de ser atualizados com gradiente descendente.

2.5.4 Arquitetura

As redes neurais artificiais podem ser classificadas em função das seguintes características: número de camadas da rede, tipo de conexões entre os neurônios que as compõem e tipo de conectividade da rede. Em uma rede neural, os diferentes neurônios são dispostos em camadas.

No que diz respeito ao número de camadas as redes podem ser classificadas em redes de camada única e redes de camadas múltiplas ou *multilayer perceptron* (MLP). Essas últimas resolveriam com eficiência problemas mais complexos, não lineares (GOMES, 2012). *Perceptron* é um classificador linear (binário). Além disso, é usado na aprendizagem supervisionada e pode ser usado para classificar os dados de entrada fornecidos.

Para Haykin (2001), uma rede de camada única leva em consideração somente a saída da rede, não sendo computada a camada de entrada, em cujos nós não são realizadas operações computacionais. Braga (2007) define rede de camada única como redes que existe um nó entre qualquer entrada e qualquer saída. Nesta arquitetura os neurônios são dispostos em camadas, onde uma camada é composta de diversos neurônios realizando o processamento em paralelo dos sinais de entrada. Estes sinais são enviados aos neurônios, processados e, em seguida, propagados como sinais de saída da rede neural. Desta maneira, os sinais percorrem um único sentido, não havendo retorno dos sinais computados para etapas anteriores de processamento. A camada de entrada não realiza qualquer processamento de dados, por isso não é considerada (NASCIMENTO, 2015). Esquematicamente esse tipo de rede pode ser representada conforme mostrado na Figura 2.8.

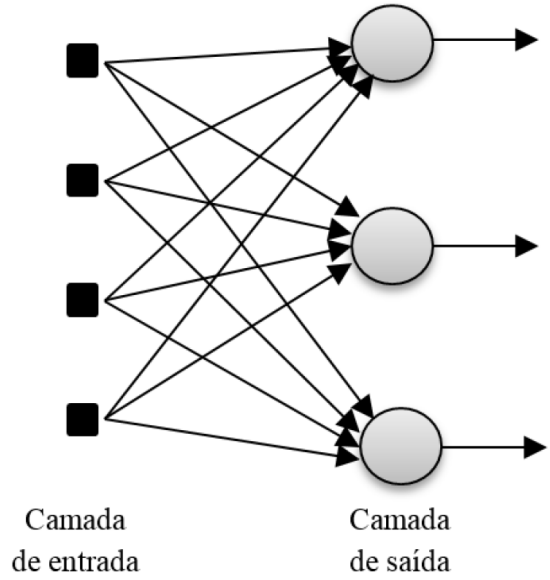


FIGURA 2.8 – Rede alimentada adiante com camada única.
Fonte: Nascimento (2015)

As redes neurais de múltiplas camadas possuem uma ou mais camadas ocultas de neurônios, em outras palavras entre a entrada e a saída há mais de uma camada de neurônios. A função das camadas ocultas é melhorar o desempenho da rede (BABINI, 2006). Adicionando-se uma ou mais camadas ocultas, a rede se torna capaz de extrair estatísticas de ordem elevada (HAYKIN, 2001). Nesta arquitetura, os sinais de entrada são ligados aos neurônios da camada oculta, que por sua vez, são conectados às camadas seguintes, de forma que os sinais das camadas posteriores nunca são enviados para as camadas precedentes. A Figura 2.9 mostra um tipo de rede com várias camadas. Nesta rede, entre a entrada e a saída, temos uma camada de neurônios ocultos.

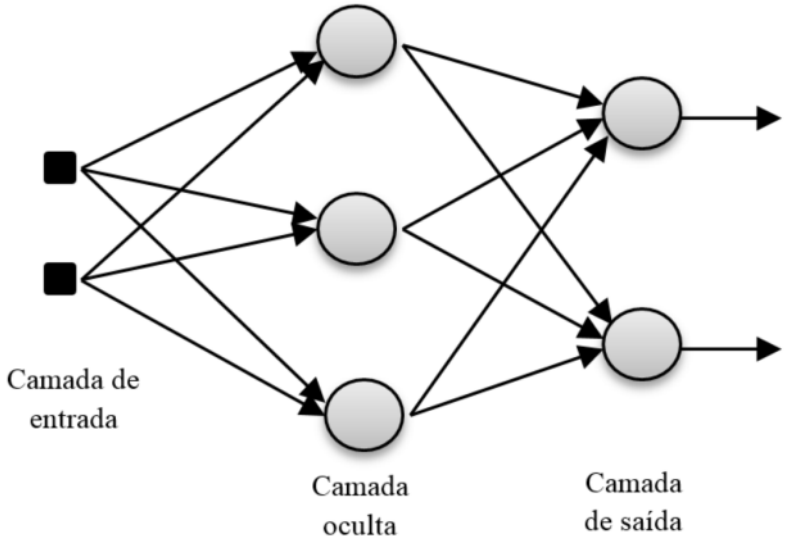


FIGURA 2.9 – Rede alimentada adiante com múltiplas camadas.
Fonte: Nascimento (2015)

Similarmente visando desenvolver uma generalização ao tipo de problema que uma RNA pode ser aplicado, desenvolveu-se o algoritmo de retro propagação de erros, que atua mediante um processo de otimização (RUMELHART *et al.*, 1988).

Em resumo, redes com um único neurônio eram responsáveis pelo mapeamento integral de todo processo. Já nas redes *Perceptron* de Múltiplas Camadas (PMC) o conhecimento relacionado ao comportamento entrada e saída do sistema será distribuído por todos os neurônios constituintes da rede. Os estímulos ou sinais são apresentados à rede em sua camada de entrada. As camadas intermediárias, por sua vez, extraem a maioria das informações referentes a seu comportamento e as codificam por meio dos pesos sinápticos e limiares de seus neurônios, formando assim uma representação própria do ambiente em que está inserido o referido sistema a ser tratado. Finalmente, os neurônios da camada de saída recebem os estímulos advindos dos neurônios da última camada intermediária, produzindo um padrão de resposta que será a saída disponibilizada pela rede (SILVA *et al.*, 2010).

Em geral, o número de neurônios da camada oculta é maior do que o número de sinais de entrada. A determinação da quantidade de neurônios a ser empregada varia de acordo com a complexidade da tarefa a ser desempenhada, assim como o número de camadas ocultas, pois não existe um procedimento que determine uma quantidade exata de neurônios para cada aplicação. O número de neurônios da camada de saída será igual ao número de resultados a serem apresentados pela rede neural.

No que diz respeito ao tipo de conexões, as redes se dividem em redes *feedforward*, que são acíclicas, alimentadas adiante ou não-recorrentes, e redes *feedback*, que são cíclicas ou recorrentes. Nas redes *feedforward*, a saída de um neurônio na i-ésima camada da rede não pode ser utilizada como entrada de nodos em camadas anteriores (BRAGA, 2007). Este tipo de arquitetura é classificado como *feedforward*, pois a propagação de sinal ocorre apenas no sentido positivo, ou seja, a saída da camada anterior é a entrada da camada seguinte.

2.5.5 Treinamento

As RNA do tipo *perceptron* têm, inicialmente, uma fase de aprendizado, em que são apresentados exemplos à rede e são retiradas as características que serão utilizadas na fase de geração de resultados, para a estimação dos parâmetros da rede que são os pesos que ligam os neurônios entre si e às variáveis de entrada. A dificuldade, contudo, foi a falta de um algoritmo de treinamento, que permitisse esta estimação o que em termos estatísticos significa a falta de um método para estimar os parâmetros da rede. Desenvolve-se, então, o algoritmo de treinamento *backpropagation* e a partir desse momento foi crescente o interesse por pesquisas na área de redes neurais artificiais (BRAGA, 2007). A introdução

do algoritmo de treinamento da retropropagação de erros constitui-se do algoritmo mais utilizado para a arquitetura MLP (RUMELHART *et al.*, 1988).

Portanto, para redes *perceptron* de múltiplas camadas é utilizado o algoritmo de retropropagação que se baseia em um processo de treinamento supervisionado, onde um conjunto de entradas e saídas é apresentado e o algoritmo realiza o ajuste dos pesos numa tentativa de minimizar o erro entre a resposta da rede e o valor de saída desejado. A Figura 2.10 ilustra as direções de dois fluxos básicos de sinal em um *perceptron* multicamadas: propagação direta de sinais de função e retropropagação de sinais de erro.

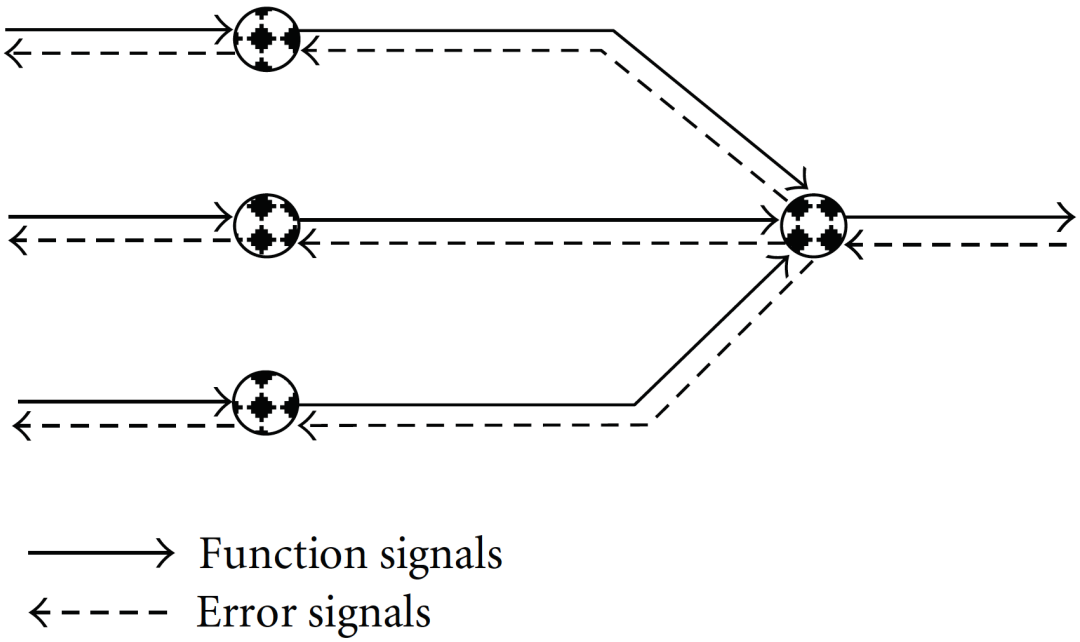


FIGURA 2.10 – Propagação direta de sinais de função e retropropagação de sinais de erro.
Fonte: Haykin (2001)

Inicialmente, as amostras são inseridas na camada de entrada da rede neural, a qual irá propagar os sinais para as camadas subsequentes, assim como demonstrado na arquitetura de redes neurais de alimentação adiante com múltiplas camadas. Este processo é representado na Figura 2.10 pelas setas contínuas. Neste momento, não são realizados os ajustes dos pesos sinápticos, apenas deseja-se identificar as respostas produzidas nas saídas da rede neural. Em seguida, os resultados provenientes da computação realizada pelos neurônios são comparados com as amostras de saída, que representam os valores desejados para a saída da rede neural. O erro entre os resultados da rede e o valor desejado é então utilizado para ajustar os pesos sinápticos e limiares de ativação de todos os neurônios. Este processo é iniciado na camada de saída e propagado para as camadas anteriores, como mostram as setas tracejadas da Figura 2.10. Este processo é repetido até que se obtenha um valor mínimo de erro aceitável ou outro critério de parada do treinamento seja atingindo. Nota-se que os neurônios da camada de saída são os únicos que permitem

calcular o erro diretamente, pois não existem amostras com valores desejáveis para os sinais de saída dos neurônios das camadas ocultas.

Especificamente, consideramos um método simples de treinamento no qual os pesos são atualizados de amostra em amostra até formar uma época, isto é, uma apresentação completa do conjunto de treinamento inteiro que está sendo processado. Os ajustes dos pesos são realizados de acordo com os respectivos erros calculados para cada amostra apresentada à rede (HAYKIN, 2001). Observando o conjunto de entradas de um neurônio na estrutura de múltiplas camadas, nota-se que o potencial de ativação deve ser descrito em função dos sinais de saídas dos neurônios das camadas anteriores. O resultado final da rede neural é a determinação dos pesos sinápticos da rede. A atualização desses valores, baseada em uma determinada métrica de desempenho, é o que determina a progressão do treinamento das RNAs. A taxa de aprendizagem determina a velocidade com que a rede irá realizar alterações dos seus pesos sinápticos.

2.5.6 *Overfitting*

Um dos problemas que ocorrem durante o treinamento da rede neural é chamado *overfitting*. O erro sobre o conjunto de treinamento é conduzido para um valor muito pequeno, mas quando novos dados são apresentados à rede o erro é grande. A rede memorizou os exemplos de treinamento, mas ainda não aprendeu a generalizar-se a novas situações.

Um método para melhorar a generalização da rede é usar uma que seja grande o suficiente para fornecer um ajuste adequado. Quanto maior a rede utilizada, maior a complexidade que as funções da rede podem criar. Se for usada uma rede pequena pode ser que ela não se ajuste satisfatoriamente aos dados. Infelizmente, é difícil saber de antemão quão grande uma rede deve ser para uma aplicação específica.

Observe que se o número de parâmetros na rede é muito menor do que o número total de pontos no conjunto de treino, então há pouca ou nenhuma chance de *overfitting*. Pode-se facilmente coletar mais dados e aumentar o tamanho do conjunto de treinamento, então não há necessidade de se preocupar com as técnicas para evitar *overfitting*. O restante desta seção aplica-se apenas às situações em que se quer aproveitar ao máximo uma quantidade limitada de dados.

Srivastava *et al.* (2014) reafirma que redes neurais profundas com um grande número de parâmetros são sistemas de aprendizado de máquina muito poderosos, mas que o *overfitting* é um problema sério em tais redes. As redes grandes também são lentas, dificultando o superajuste combinando as previsões de muitas redes neurais grandes diferentes no tempo de teste.

2.5.7 Aplicações

Uma rede neural artificial tem a capacidade de gerar aproximações de qualquer função computável, reconhecer, classificar, alocar padrões, realizar previsão de séries temporais dentre outras aplicações, e ainda como um aproximador universal das RNA (BARRON, 1993). Nota-se pelo exposto que uma rede neural não mantém qualquer relação de pertinência e subjunção se a função a ser aproximada é linear ou não. De fato, atualmente, as redes neurais artificiais têm sido cada vez mais usadas para resolver uma enorme variedade de problemas que são complexos demais para serem resolvidos utilizando apenas programação baseada em regras comuns.

Duas das principais aplicações das RNA's são em problemas de reconhecimento de padrões e de classificação, onde as redes se mostram ferramentas extremamente flexíveis, uma vez que são métodos multivariados, não-lineares, não-paramétricos e orientados a dados. A previsão para dados quantitativos se baseia na retirada de dados de observações passadas, sua modelagem, e sua posterior extrapolação para o futuro (HIPPERT *et al.*, 2001).

Considerada atualmente a principal técnica utilizada em neurocomputação, a teoria de redes neurais artificiais, vem se consolidando mundialmente como uma eficiente ferramenta para se lidar com a ampla classe dos, assim chamados, problemas complexos, em que extensas massas de dados devem ser modeladas e analisadas em um contexto multidisciplinar, envolvendo simultaneamente, tanto aspectos estatísticos e computacionais como dinâmicos e de otimização (BARBOSA, 2004; KOVACS, 1996).

Esta ferramenta tem sido usada com grande eficiência em sistemas que precisam aprender com usuários e adaptar-se a eles, pois ao contrario de programas computacionais comuns, que executam apenas comandos de forma ordinária e fixa, esta possui flexibilidade, sofre modificações enquanto evolui e aprende através de exemplos. É utilizada em um grande número de aplicações, nas mais diversas áreas do conhecimento, tais como, financeira, industrial, médica, etc., com diferentes propósitos, como, por exemplo, data mining, classificação, reconhecimento de padrões, segmentação, estimação e predição (TAFNER *et al.*, 1995; MALINVERNI, 2006).

Haykin (2001) defende que é necessário entender as RNA's como uma extensão das convencionais técnicas estatísticas, pela qual o conhecimento empírico sobre um fenômeno físico ou ambiente de interesse pode ser codificado através de treinamento. Neste sentido, uma das principais vantagens na utilização RNA's é a facilidade com que se pode alterar o modelo neural usado para a estimação. De forma que, alterando-se o número de neurônios, de camadas e/ou as funções de ativação da arquitetura, a função de regressão modelada é modificada. E isto, podendo ser feito empiricamente, sem que se faça necessário um amplo conhecimento sobre os modelos de regressão que estão sendo utilizados, simplifica a tarefa de obtenção de um modelo que satisfaça as necessidades específicas da aplicação. No

caso, encontrar um modelo matemático capaz de aprender a relação existente nos dados disponíveis, de forma a poder fazer predições acuradas (BRAGA, 2007; BARRETO, 2001).

Este trabalho restringe a aplicação desta ferramenta à tarefa de predição, e interpreta seu funcionamento do ponto de vista das análises de classificação e regressão. Contudo, o fato de interpretar o modelo neural sob o aspecto de um modelo de regressão, possibilita a aplicação de propriedades particulares, as quais não só permitem como também validam a criação de predições intervalares, desde que se respeitem alguns pressupostos e limitações deste tipo de estimação. Esta interpretação se torna possível devido à possibilidade de utilizar determinadas arquiteturas neurais como aproximadores universais de funções. A tarefa de predição, dentro do contexto da teoria da aproximação, consiste em obter estimativas para a variável de interesse, a variável de saída, a partir de um conjunto de exemplos, as variáveis de entrada (KOVACS, 1996). De maneira que, o modelo utilizado para simular, ou ainda, reproduzir o comportamento presente nas observações, deve ser capaz de aprender a relação existente entre as variáveis preditoras e a variável resposta, de forma aproximada (HAYKIN, 2001).

2.6 Revisão da literatura

A literatura mostra diversos trabalhos que tratam do engajamento ar-ar. Prasad *et al.* (1989) apresenta uma nova abordagem para a orientação de aeronaves na fase de pré-lançamento do combate a mísseis de médio alcance. As ações de controle são definidas de forma que elas funcionem em um modo de resposta para aproveitar os erros de estratégia do oponente. O método é baseado nas distâncias entre as posições finais dos mísseis e os alvos em hipotéticas trocas de disparos entre os agentes. Assim, é computacionalmente caro, uma vez que cada avaliação da lei de orientação requer um conjunto de simulações de míssil e alvo.

Davidovitz e Shinar (1989), Mukai *et al.* (2003), Karelahti *et al.* (2006) usam a teoria dos jogos para modelar o combate aéreo (Figura 2.11). A teoria dos jogos é o estudo de modelos matemáticos de interação estratégica entre decisores racionais (KALAI, 1991). Inicialmente desenvolvida como ferramenta para compreender comportamento econômico (NEUMANN *et al.*, 1944), atualmente a teoria dos jogos é hoje usada em diversos campos acadêmicos. De forma geral, nesses trabalhos tenta se descobrir o equilíbrio de Nash (NASH, 1951) com as funções de recompensa escolhidas como funções ponderadas da distância da falta - a menor distância do míssil à aeronave durante o voo do míssil. Ha *et al.* (2015) descrevem cenários de combate aéreo formalizados como um jogo estocástico que consiste em uma sequência de jogos normais com um sub-jogo contínuo. A estratégia de equilíbrio e as funções de valor do jogo são calculadas através de um procedimento

de programação dinâmica; o impacto da velocidade da aeronave e a cooperação para o combate são analisados com base nas estratégias de equilíbrio.

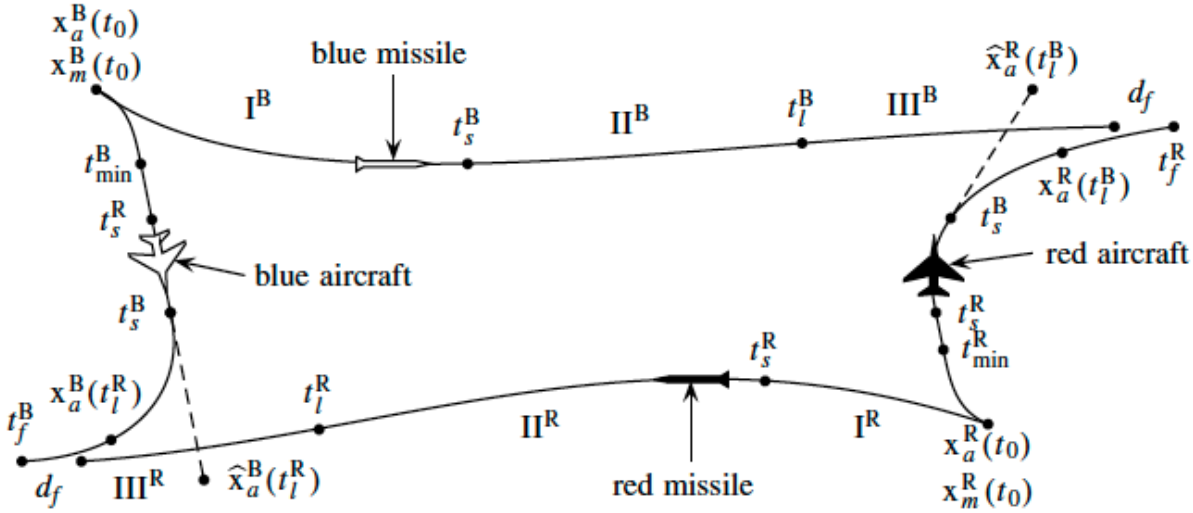


FIGURA 2.11 – Combate aéreo um contra um com as trajetórias extrapoladas dos alvos.
Fonte: Karelahti *et al.* (2006)

Feigin *et al.* (1984) propõem descrever múltiplos combates aéreos com um número moderado de participantes, com o auxílio de um processo estocástico com um modelo simples que descreve as características dominantes que levam a um processo de Markov de estado discreto em tempo contínuo.

Moritz *et al.* (1987) discutem a modelagem de ordem completa de engajamentos de um combate 1 contra 1 com aeronaves equipadas com mísseis de médio alcance, incluindo restrições de pressão dinâmica, visibilidade de radar e fatores de carga. Como exemplo, a solução de ciclo aberto de um problema característico de evasão de perseguição é apresentada e comparada com um resultado de simulação usando um típico programa de computador de simulação de combate aéreo além do alcance visual.

Austin *et al.* (1990) demonstram como utilizar técnicas estatísticas aplicadas para estimar jogos com base em dados produzidos por um modelo de simulação. O procedimento de estimação é apresentado em casos envolvendo jogos com variáveis de decisão discretas e contínuas. A validade do modelo de simulação é avaliada comparando as propriedades dos jogos estimados às práticas reais em combate aéreo. A abordagem da teoria dos jogos aprimora os métodos existentes para a validação de modelos de simulação de eventos discretos e técnicas para otimização baseada em simulação.

Jarmark (1985) resolve numericamente o problema do jogo diferencial não-linear de um combate aéreo, utilizado um algoritmo de otimização que consiste em um método de programação dinâmica diferencial de primeira ordem modificado combinado com uma técnica de controle de convergência efetiva. O movimento espacial tridimensional de veículos de massa pontual com modelos realistas é considerado no artigo.

Heinze *et al.* (1998) usam uma abordagem baseada em agentes para resolver este problema (Figura 2.12). A adoção de tecnologias orientadas a agentes realizou uma série de benefícios. Entre esses, destaca-se a capacidade de os recursos humanos da parte operacional se envolverem ativamente na modificação, projeto e desenvolvimento dessas simulações. Esse envolvimento reduziu drasticamente o tempo gasto para prototipar, testar e comissionar software e resultou em simulações que têm um significativo nível de confiança.

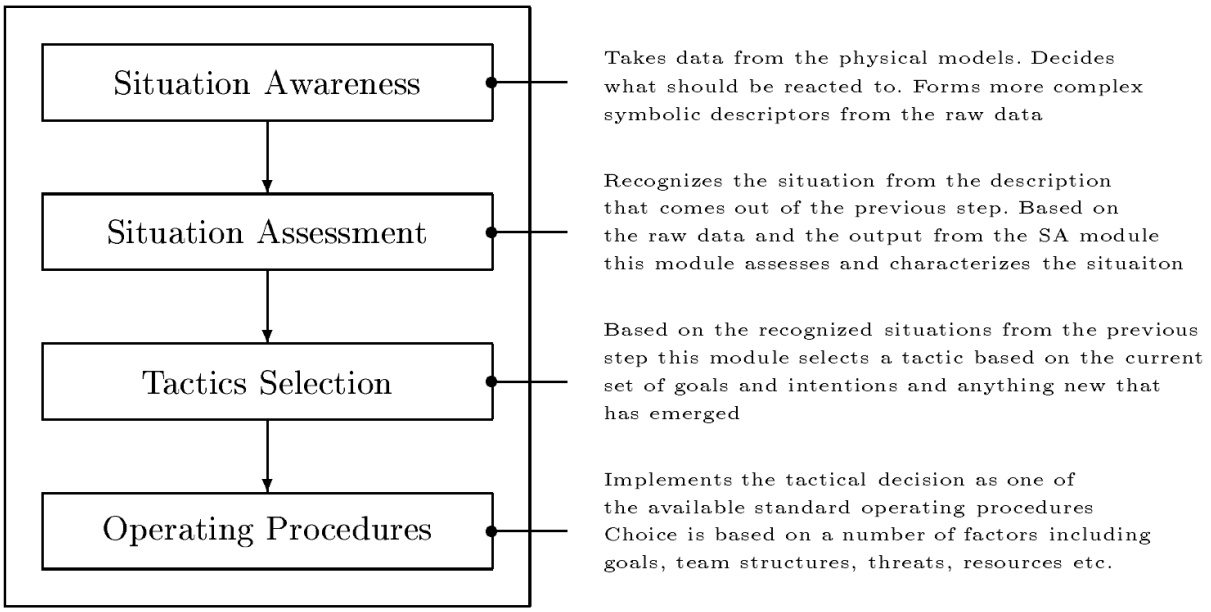


FIGURA 2.12 – Modelagem do agente do piloto de combate.
Fonte: Heinze *et al.* (1998)

Mulgund *et al.* (1998) descrevem o desenvolvimento de uma ferramenta de software para otimizar táticas de combate aéreo em grande escala usando algoritmos genéticos estocásticos. A implementação de táticas utiliza um conceito hierárquico que constrói grandes estratégias de formação a partir de pequenas unidades de combate convencionais, facilitando o desenho de táticas compatíveis com os princípios de combate aéreo existentes.

Akabari *et al.* (2005) propõem uma nova lei de orientação baseada na lógica *fuzzy* que pode ser aplicada com sucesso na modelagem e geração de manobras ofensivas complicadas em um combate aéreo entre duas aeronaves. Com base no processo de tomada de decisão de especialistas humanos, um método baseado em inteligência é proposto para modelar as manobras. As regras, que são obtidas diretamente do conhecimento do especialista, são usadas para representar as preferências do perseguidor em orientar seu sistema. Cada regra relaciona as direções móveis desejadas do perseguidor com os parâmetros da tarefa. Os parâmetros de controle da aeronave são calculados através do erro quadrático médio. Uma grande quantidade de simulações é usada para aprovar o desempenho satisfatório do modelo. Os resultados mostram que manobras semelhantes podem ser geradas pelo modelo proposto. Tran *et al.* (2002) apresenta uma abordagem híbrida de aprendizado

neuro-genético para a adaptação de um sistema de inferência usando *fuzzy logic* para o sistema tático de apoio à decisão de combate aéreo, ou ainda, *Tactical Air Combat Decision Support System* (TACDSS) (Figura 2.13). Alguns resultados de simulação demonstram a diferença das técnicas de aprendizagem e também são fornecidos. Diferentemente, na lógica booleana, os valores lógicos das variáveis podem ser apenas 0 e 1, a *fuzzy logic* mostra que esses valores verdadeiros ou falsos podem compreender valores intermediários entre completamente verdadeiro e completamente falso (AHLAWAT *et al.*, 2014).

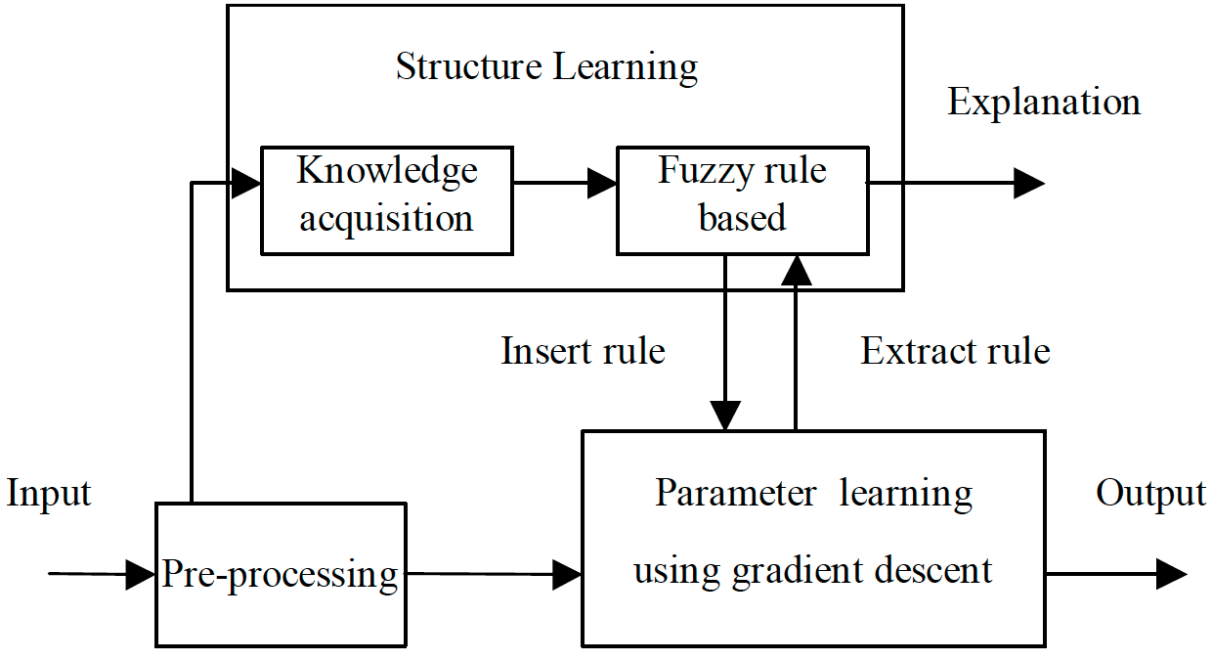


FIGURA 2.13 – Um diagrama esquemático geral da rede neural fuzzy híbrida.
Fonte: Tran *et al.* (2002)

Abordagens por algoritmos genéticos também foram feitas para o problema do combate aéreo. Luo *et al.* (2005) trazem a discussão do ataque múltiplo cooperativo em combate aéreo onde o objetivo é encontrar uma atribuição de ataque adequada de caças amistosos com capacidade de ataque a múltiplos alvos para alcançar um efeito de ataque ideal desejado. Um algoritmo heurístico adaptativo genético, ou ainda *Heuristic Adaptive Genetic Algorithm* (HAGA), é proposto para procurar sua solução ideal, conhecimentos heurísticos específicos são utilizados para melhorar a capacidade de pesquisa do algoritmo genético adaptativo ou *Adaptive Genetic Algorithm* (AGA). Os resultados da simulação mostram que o HAGA é eficaz e tem um desempenho muito melhor do que o da AGA. Lu *et al.* (2006) realizaram estudos na alocação de defesa aérea da frota naval e um modelo ótimo de alocação de alvos foi estabelecido. Para encontrar resultados ótimos globais de forma eficiente, um método de busca global eficaz foi proposto por algoritmos genéticos (AGs) de forma melhorada para resolver o problema proposto.

Karelahti *et al.* (2007) introduz uma modelagem de controle para obter controles próximos do ideal de modo que a aeronave tente evitar que um míssil ar-ar fique ativo e atinja o seu alvo (Figura 2.14). Os veículos são modelados como massas pontuais e a cinemática de rotação da aeronave é levada em consideração, limitando as taxas de inclinação e rotação, bem como as acelerações angulares do ângulo de ataque e do ângulo de rolagem. O míssil usa navegação proporcional e possui um sistema de propulsão e sustentação.

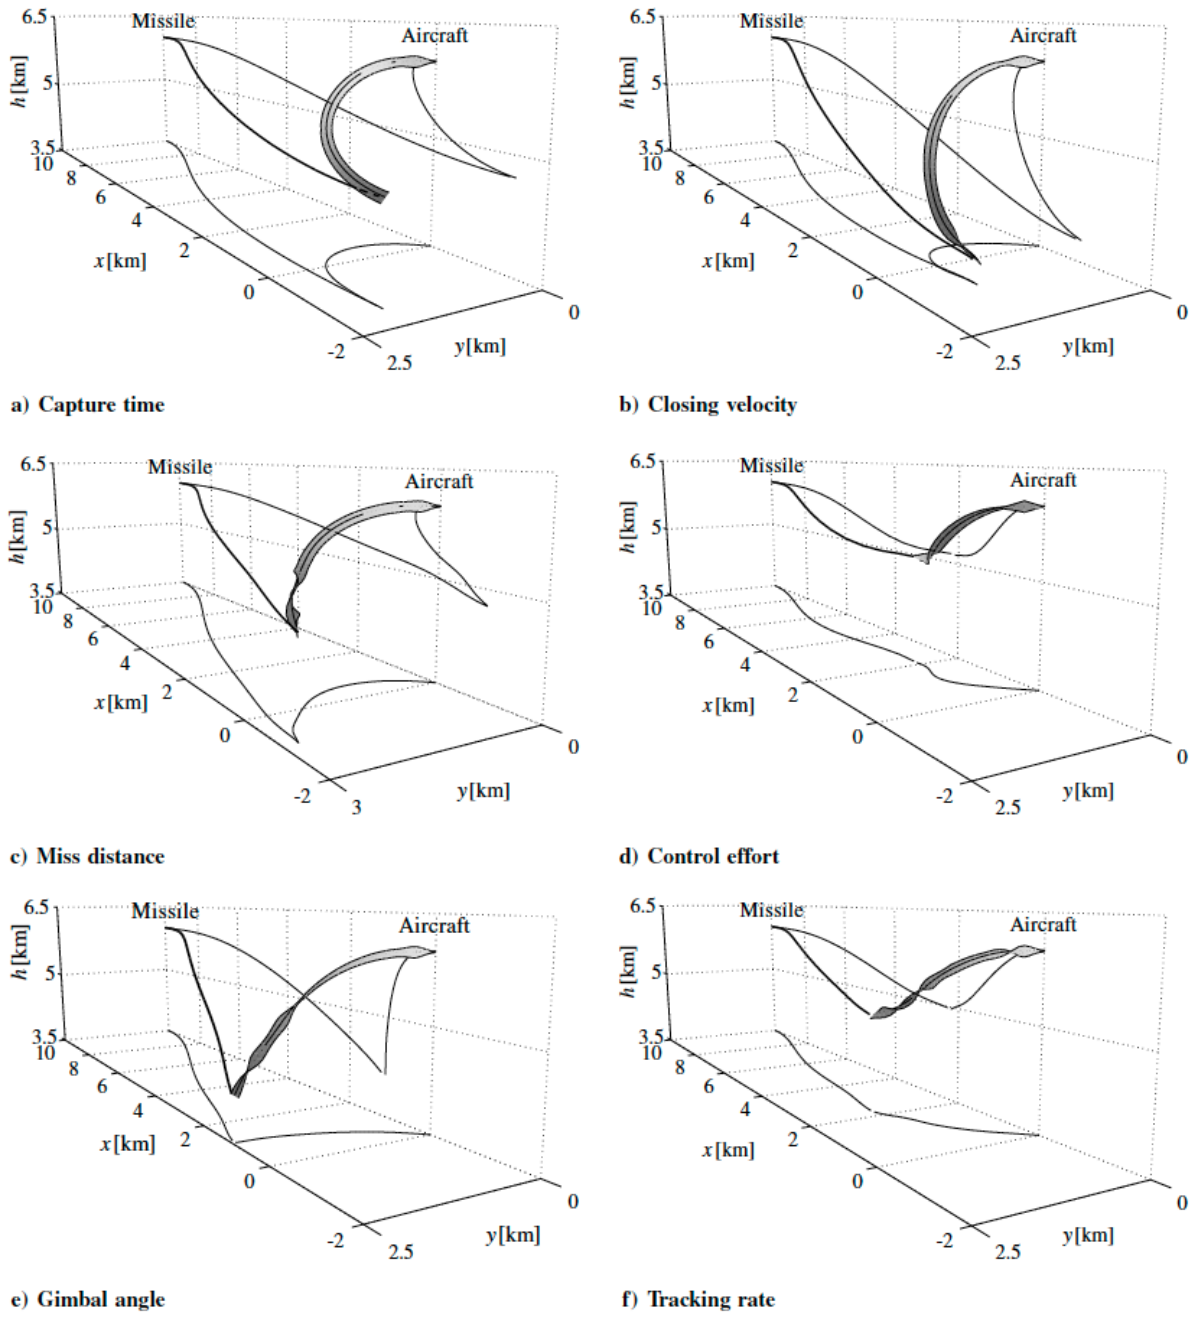


FIGURA 2.14 – Trajetórias ótimas no combate aéreo com diferentes medidas de desempenho.

Fonte: Karelahti *et al.* (2007)

Poropudas e Virtanen (2007) utiliza dados de simulação de combate aéreo que são reconstruídos em uma rede bayesiana dinâmica (Figura 2.15). Ele fornece um modelo probabilístico compacto que descreve o progresso do combate aéreo e permite uma computação eficiente para o estudo de diferentes cursos do combate. Esta capacidade é usada para investigar o efeito de diferentes situações de combate aéreo na evolução e no resultado do combate aéreo.

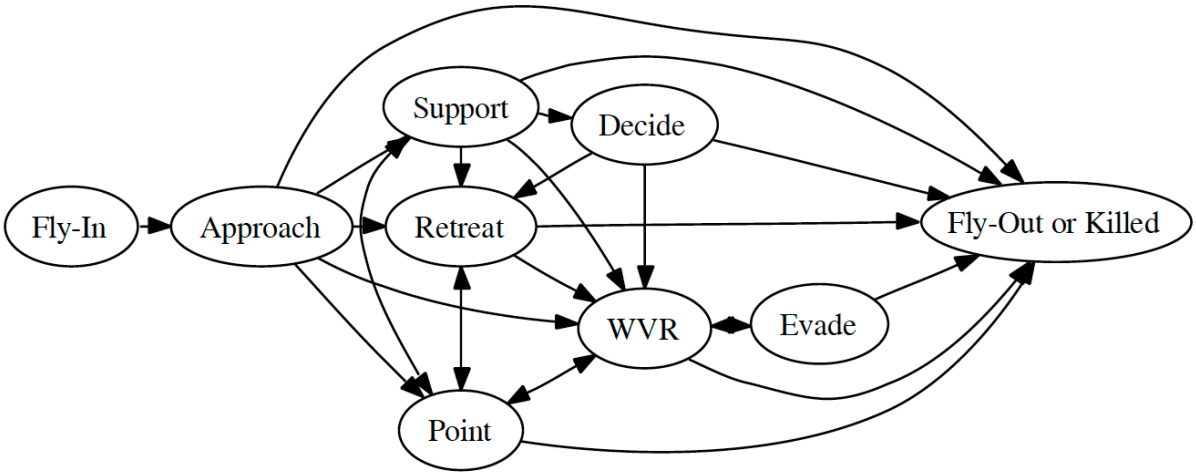


FIGURA 2.15 – O diagrama de fases descrevendo a tomada de decisão do piloto.
Fonte: Poropudas e Virtanen (2007)

Lin *et al.* (2007) propõem o uso de diagramas de influência multi-estágio para resolver o problema do combate aéreo. Um diagrama de influência de vários estágios é usado para modelar a tomada de decisões sequenciais do piloto em um combate aéreo que descreve graficamente os elementos do processo de decisão e contém um modelo de massa pontual para a dinâmica de uma aeronave e leva em consideração as preferências do tomador de decisão sob condições incertas. Considerando um oponente ativo, as manobras do oponente podem ser modeladas estocasticamente. A solução do diagrama de influências de múltiplos estágios pode ser obtida convertendo o diagrama de influência de múltiplos estágios em um problema de otimização de dois níveis.

Demkin *et al.* (2008) apresenta a estrutura da base de conhecimento de um sistema de assessoria em tempo real embarcado para combate aéreo além do alcance visual, na qual a informação atual sobre a situação externa é usada para a ativação de determinadas ações em um espaço amostral pré-estabelecido (Figura 2.16). Com base na análise do domínio do combate aéreo, as quatro ações são: tomar a posição taticamente vantajosa, ataque, defesa com ataque e defesa. Para cada um destas ações com base na simulação virtual do desenvolvimento proposto da luta aérea e o jogo correspondente de regras de produção, as recomendações à tripulação no método racional da sua resolução desenvolvem-se. Em resumo, algoritmos de Inteligência Artificial são usados para gerar táticas ótimas para combates aéreos além do alcance visual.

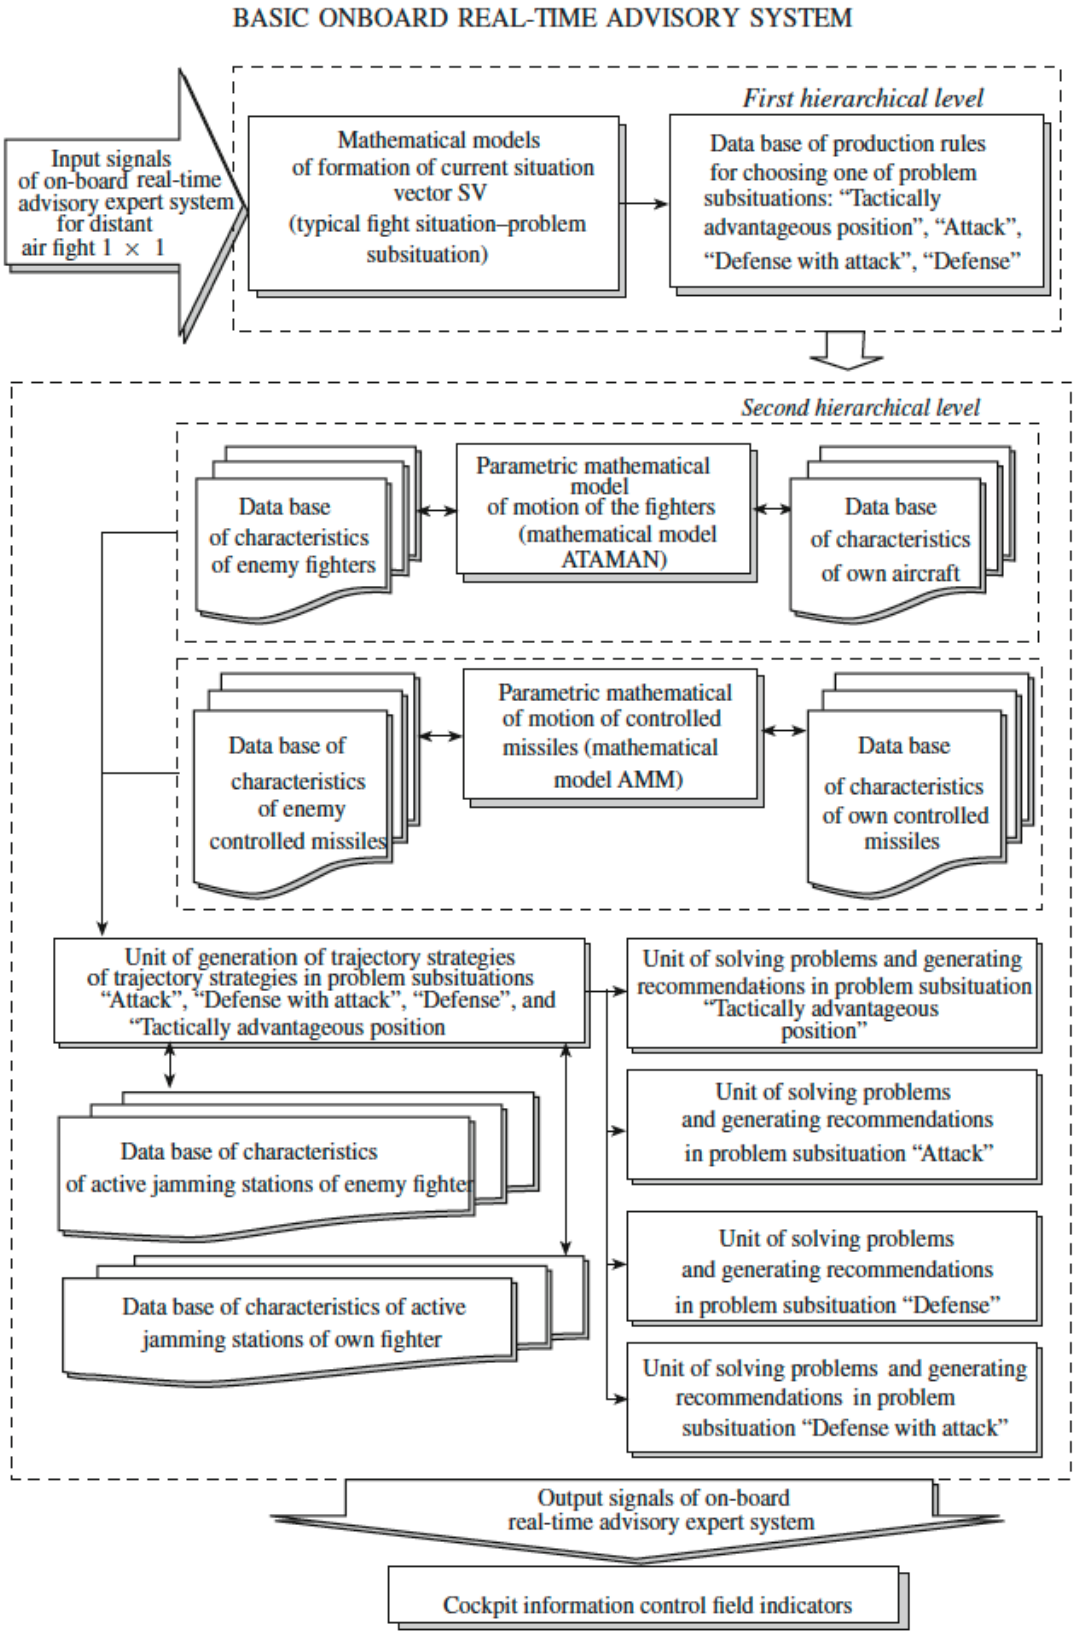


FIGURA 2.16 – Estrutura de conhecimento do sistema de apoio à decisão em tempo real para um combate aéreo um contra um.

Fonte: Demkin *et al.* (2008)

Júnior (2011) constata que o problema de combate ar-ar tem um fator de risco, e o que realmente importa é o desempenho em um único teste. Isso se deve ao fato de não se está interessado em ter, após vários anos de combate (supondo que tenhamos uma quantidade infinita de pilotos e aeronaves), uma maior média de sucesso que o inimigo. O que realmente importa na classe de problemas é ter a maior probabilidade de ser o vencedor em cada engajamento individual. Por esta razão, e devido ao fato de que várias variáveis de decisão são contínuas, a metodologia que foi adotada para essa aplicação é a seleção do sistema mais provável de ser o melhor e não aquele com a maior média de sucesso para modelar o problema proposto.

Macêdo (2017) mostra como a correta alocação coordenada de múltiplas aeronaves de combate contra vários alvos aéreos se apresenta como um fator crítico de sucesso no ambiente do combate BVR. O problema de alocação armamento-alvo, do inglês *Weapon-Target Assignment* (WTA), na sua versão estática, baseada no alvo e com restrições para a alocação foi abordado em um contexto de combate aéreo BVR, onde plataformas aéreas carregadas com mísseis de médio alcance devem alocar seus armamentos em alvos, também carregados com mísseis de médio alcance, a fim de minimizar a probabilidade de sobrevivência dos alvos. Os resultados obtidos demonstraram não só o alto grau de eficiência com que resolve o problema de WTA em um contexto real de alocação, como a velocidade da resposta do algoritmo possibilita sua implementação em sistemas de apoio à decisão de tempo real.

Floyd *et al.* (2017) descrevem o *Tactical Battle Manager* (TBM), um agente inteligente que utiliza várias técnicas integradas de inteligência artificial para controlar um veículo aéreo autônomo não-tripulado em cenários de combate aéreo simulado além do alcance visual. O TBM incorpora o raciocínio de metas, planejamento automatizado, reconhecimento de comportamento do oponente, previsão de estado e detecção de discrepância para operar em um ambiente em tempo real, dinâmico, incerto e adverso.

Nesta dissertação será utilizado um modelo de redes neurais artificias baseado no *perceptron* de multicamadas, que utiliza o algoritmo de *backpropagation*, para modelar um combate aéreo além do alcance visual de duas aeronaves. A avaliação contínua da condição do piloto no combate será constatada por meio desse modelo de RNA que permitirá o piloto ter uma maior consciência situacional durante o combate BVR. Na revisão da literatura não se vislumbrou trabalhos semelhantes na área com o uso de redes neurais artificiais. Por essa razão e devido a sua versatilidade de resolver problemas de natureza bastante complexa de forma relativamente eficiente, optou-se por esse tipo de aprendizado de máquina supervisionado para abordar o problema do combate aéreo além do alcance visual da presente dissertação.

3 Metodologia

Neste capítulo são descritos os passos que conduziram ao desenvolvimento da análise das redes neurais artificiais aplicadas ao combate aéreo além do alcance visual. Inicialmente, faz-se um relato das principais especificações do simulador utilizado para gerar cenários de combate. Em seguida, descreve-se um estudo de caso específico de um combate aéreo além do alcance visual com certas limitações, mas que permitem descrever eficientemente o cenário operacional proposto. Apresentam-se, então, o desenvolvimento dos modelos de aprendizagem utilizados para prever os resultados das simulações propostas a partir de dados de entrada pré-estabelecidos. Por fim, a metodologia utilizada para a concepção do sistema de melhoria da consciência situacional do piloto de combate aéreo além do alcance visual.

3.1 Simulador de combate aéreo além do alcance visual

A aplicação de um simulador de combate além do alcance visual se faz extremamente necessária na Força Aérea Brasileira nos cenários atuais. Devido ao alto custo operacional para se treinar o combate aéreo além do alcance visual por meio de simulações reais, diversos sistemas para simulação virtual e construtiva têm sido utilizados nesse contexto para avaliação de aeronaves, mísseis e táticas, além de treinar pilotos, provendo aeronaves inimigas em campos de batalha simulados (ERLANDSSON; NIKLASSON, 2015). Tais aplicações requerem que os comportamentos das aeronaves simuladas sejam indistinguíveis dos seres humanos, podendo inclusive ser mais eficientes, já que podem processar dados em uma quantidade e velocidade superior. Isto é importante tanto para o realismo da simulação, quanto para a aplicabilidade dos resultados nela obtidos.

Essa seção tem como objetivo contextualizar o leitor quanto a concepção do simulador de combate aéreo além do alcance visual, o ambiente utilizado para sua visualização e ainda detalhamentos acerca de sua modelagem comportamental, esclarecendo as principais limitações e peculiaridades do simulador que são relacionadas ao tipo de missão operacional analisada.

3.1.1 AEROGRAF

A plataforma AEROGRAF é um Sistema de Informação Geográficas (SIG) desenvolvido no Instituto de Estudos Avançados (IEAV) da Força Aérea Brasileira (FAB). A arquitetura é modular, permitindo o desenvolvimento e a integração de *plugins*, que é um conjunto de rotinas de código de programação com a finalidade de produzir uma capacidade que possa trazer novas funcionalidades à plataforma.

Neste trabalho, todo o desenvolvimento do simulador de combate além do alcance visual foi realizado por meio de um novo *plugin* de simulação no AEROGRAF e é baseado na implementação de algoritmos de apoio à decisão na plataforma de planejamento que já está em bastante uso pela Força Aérea Brasileira. Na plataforma encontram-se modeladas diversas entidades, incluindo tanto plataformas, tais como mísseis e aeronaves, quanto sistemas, tais como radares e *Radar Warning Receiver* (RWR).

Os modelos se baseiam nas características e parâmetros fornecidos por fabricantes e especialistas nas diversas áreas afins. Espera-se que as equipagens de combate da FAB possam usufruir de uma plataforma de apoio à decisão que incremente sua percepção das forças e fraquezas das táticas em uso e a serem desenvolvidas, potencializando o poder de combate dos pilotos de caça (MARQUES *et al.*, 2015).

3.1.2 Ambiente de Simulação Aeroespacial

O *plugin* do AEROGRAF desenvolvido para criação do simulador BVR precede a criação do Ambiente de Simulação Aeroespacial (ASA) que é um projeto da Divisão de C4ISR do IEAV que visa desenvolver uma solução (ferramental de software) a fim de viabilizar a simulação de cenários operacionais de interesse da FAB. O conceito de simulação abordado no contexto do projeto é aquele no qual os elementos do cenário são representados como agentes capazes de tomar decisões com base em modelos de inteligência artificial e/ou regras arbitrárias previamente estipuladas. Simulações dessa natureza, ditas construtivas, podem ser empregadas no processo decisório, por exemplo, para prever possíveis resultados de engajamentos entre forças oponentes e auxiliar na definição de linhas de ação. O projeto ASA não visa desenvolver uma solução exclusiva para apenas alguns cenários específicos definidos a priori. Alternativamente, visa criar uma arquitetura modular e flexível, na qual os componentes (ou modelos) da simulação possam ser utilizados como componentes que, configuradas com diferentes parâmetros e combinadas de diferentes formas, viabilizem a composição de diversos cenários.

O modelo utilizado no simulador de combate aéreo além do alcance visual ainda é determinístico e os agentes ainda não possuem capacidade de aprendizagem e interpretação robusta do ambiente. Contudo, espera-se que o simulador BVR, que foi utilizado na

presente dissertação, e o próprio projeto ASA possam contribuir positivamente para o desenvolvimento de projetos de pesquisa na área de inteligência artificial aplicada a cenários operacionais e que venham a solucionar as diversas demandas operacionais da FAB.

3.1.3 Modelagem comportamental

Esta seção propõe um modelo comportamental para a definição do momento de disparo de um míssil e da execução de manobras defensivas em um cenário de combate aéreo além do alcance visual. O modelo apresentado se propõe a lidar com tais características, gerando comportamentos para entidades representadas num ambiente de simulação construtiva.

3.1.3.1 Zona de engajamento do armamento

Para auxiliar no processo de tomada de decisão, tanto de pilotos quanto de analistas, define-se uma representação visual dos alcances máximos e mínimos de um míssil lançado por uma aeronave BVR. Tal região é chamada de zona de engajamento do armamento ou *Weapon Engagement Zone* (WEZ), também conhecida como *Launch Acceptability Region* (LAR), ou ainda *Dynamic Launch Zone* (DLZ), de acordo com Birkmire (2011). De acordo com Herrmann (1996), existem diversos métodos de cálculo e representação da WEZ. Neste trabalho será adotada uma modelagem implementada no Planejador de Missões Aéreas (PMA) utilizado pela Força Aérea Brasileira (GERALDO, 2015).

A montagem do envelope da aeronave inicia-se pela divisão da abertura angular máxima do radar utilizado em onze radiais. Para cada uma das radiais, são calculadas as duas distâncias de interesse, a saber, *Maximum Range* (MR), que é a distância máxima para lançamento do míssil contra determinado alvo, e *No Escape Zone* (NEZ), que é zona dentro da qual existe uma grande probilidade de a aeronave analisada ser abatida. O cálculo é realizado por meio da simulação de um disparo na condição que está sendo analisando, sendo tais limites encontrados por meio de uma busca binária (MACÊDO, 2017).

Com isso, o *plugin* faz a construção da WEZ e a apresenta graficamente para o analista. Como raramente a aeronave estará alocada exatamente em uma das radiais calculadas, é efetuada uma interpolação dos valores das duas radiais mais próximas ao ponto em que a aeronave inimiga se encontra para saber se está ou não dentro do envelope.

Adicionalmente, o *plugin* disponibiliza a visualização do indicador de WEZ, presente dentro das caixas tracejadas nos cantos da Figura 3.1, semelhante ao que se vê nas telas de alerta (*heads up displays*) das aeronaves BVR. Tais indicadores mostram o quanto uma aeronave detectada se encontra dentro do envelope do armamento disponível. As graduações da escala foram criadas para facilitar a visualização dos limites entre três filosofias de tiro (*short*, *medium* e *long*), não estando presentes na maioria das aeronaves.

Observa-se que para cada agente existem dois indicadores de WEZ: um representa o próprio o WEZ do agente e o outro seria uma estimativa do WEZ da aeronave inimiga, baseado nas crenças que se tem do oponente com relação a sua filosofia de tiro.

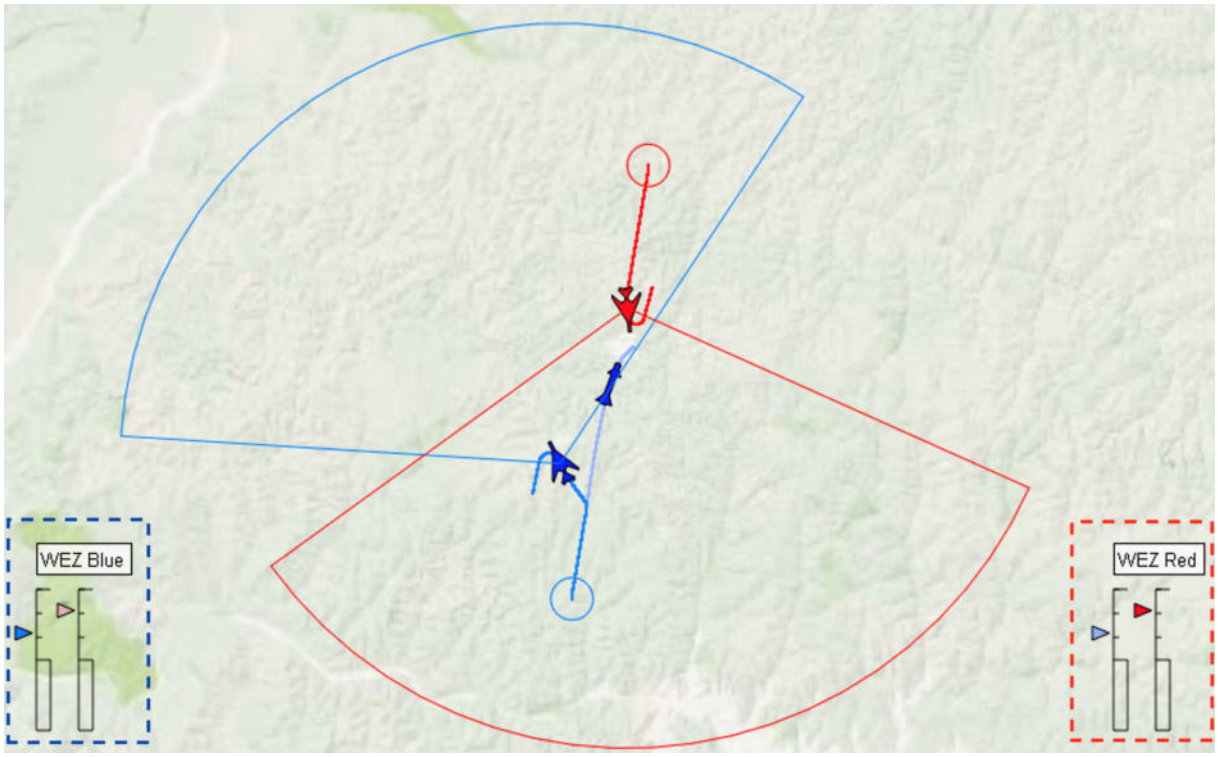


FIGURA 3.1 – Indicador de WEZ.

A fim de definir quando uma aeronave simulada deve realizar um disparo ou uma manobra defensiva, a solução proposta se baseia nos modelos detalhados a seguir.

3.1.3.2 Filosofia de tiro

Com o objetivo de se obter o nível de ameaça ao qual a aeronave está submetida, é necessário conhecer dois parâmetros relativos à aeronave inimiga, sendo o primeiro tratado nesta subseção e o segundo, efetividade de tiro, será tratado na próxima. Semelhantemente à aeronave escolhida como referência, a aeronave inimiga a essa não irá efetuar um disparo caso não esteja satisfazendo as condições relativas à sua filosofia de tiro. Entretanto, para a aeronave inimiga, tais condições são desconhecidas, podendo ser apenas estimadas com base em informações de serviços de Inteligência. Dessa forma, é estabelecida uma crença com relação a qual filosofia de tiro deve ter sido adotada pela aeronave oponente, sendo esta dependente da WEZ de tal aeronave. Para se estabelecer qual é a WEZ, algumas premissas devem ser assumidas a respeito do armamento empregado, já que os outros parâmetros, tais como altitude, velocidade e proa de ambas as aeronaves já são disponibilizados pelo radar da aeronave modelada.

Com a WEZ do oponente definida, é possível estimar qual seria o momento mais provável de seu disparo. No entanto, a filosofia de tiro, apesar de definir um ponto exato dentro da WEZ, não é claramente visualizada no indicador da aeronave, resultando em certa variabilidade no momento do disparo. Assim, como a chance de se efetuar o disparo vai aumentando na medida que o ponteiro atinge o ponto imaginário que define a filosofia de tiro, tal chance é modelada como uma reta que cruza o eixo das abscissas neste ponto, sendo o eixo das ordenadas centrado na NEZ. A partir do ponto que define o fim da região considerada pela filosofia de tiro, o qual representa a última possibilidade de disparo para que se cumpra a filosofia, o gráfico mantém-se constante, assim como antes do início desta região, conforme mostrado na Figura 3.2.

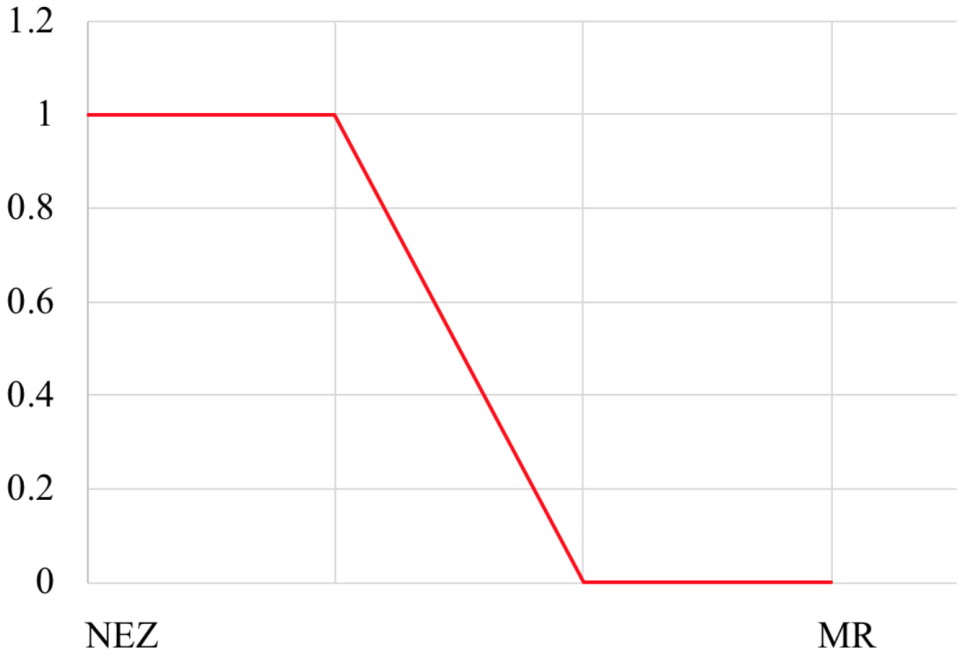


FIGURA 3.2 – Modelo para filosofia de tiro da aeronave inimiga.

A filosofia de tiro pode ser classificada em *short*, *medium* e *long*. Para efetuar o disparo, a filosofia de tiro pré-estabelecida para a aeronave deve ser obedecida em todas as fases do voo. Entretanto, como no indicador de WEZ presente na aeronave não há indicativo claro de se ter atingido a distância prevista na filosofia de tiro, os disparos são efetuados com alguma variabilidade dentro de uma região da WEZ. A fim de se levar em consideração este fato, propõe-se a utilização de um número aleatório tomado entre os limites de WEZ referentes à filosofia de tiro adotada para modelagem no simulador BVR. Tal número é obtido antes mesmo do início da simulação, determinando a condição exata, definido como *shot point*, que deve ser satisfeita para que a aeronave efetue o disparo.

3.1.3.3 Efetividade de tiro

De forma similar, a WEZ indica quais são as chances de, se efetuado o disparo, o míssil inimigo atingir a aeronave modelada. Quanto mais perto da NEZ, mais perigo o armamento apresentará, forçando manobras mais agressivas para que seja possível dele se defender. Assim, tal como feito na subseção anterior, a efetividade do disparo do oponente foi modelada por uma reta que cruza o eixo das abscissas no MR da WEZ, sendo o eixo das ordenadas centrado na NEZ, representando, por meio de sua cota unitária, o ponto de máxima efetividade, o que é representado na Figura 3.3.

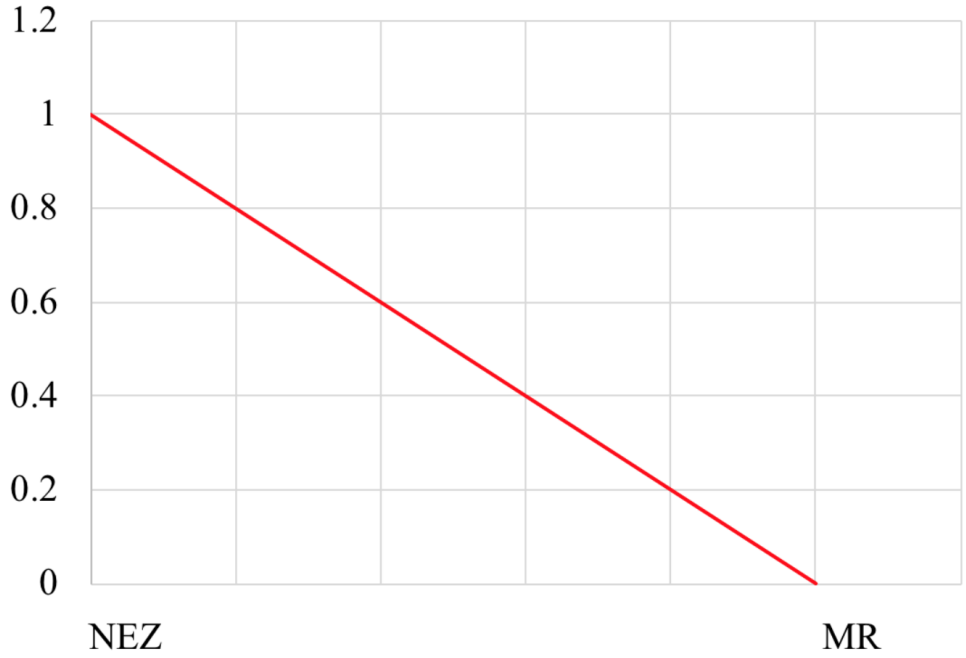


FIGURA 3.3 – Modelo para efetividade do disparo da aeronave inimiga.

É importante notar que a efetividade do disparo é dependente da crença que se tem com relação ao armamento inimigo, já que isso afeta diretamente a definição da WEZ do oponente. Por fim, os dois modelos relativos ao oponente, isto é, a efetividade do disparo e a expectativa de filosofia de tiro da aeronave inimiga, são compostos formando um coeficiente de ameaça, o qual é utilizado para balizar as decisões da aeronave, por meio de *thresholds* que indicam seus graus de aceitação do risco.

3.1.3.4 Parâmetros de simulação

No *plugin* desenvolvido foram disponibilizados aos usuários diversos parâmetros para serem editados conforme o cenário a ser simulado. Esta categoria de parâmetros inclui dados de indicação de data e hora em que a simulação se passa, ao tempo total de simulação e ao tamanho do passo de simulação. Além disso, trata de posições relativas entre as

entidades no cenário e dos critérios de término da simulação. Tais critérios definem quando que a simulação se encerra, apresentando as seguintes possibilidades: alvo fora da linha de visada do buscador do míssil, razão de rastreamento do buscador incapaz de detectar alvo muito veloz, velocidade do míssil menor do que a do alvo, velocidade absoluta do míssil menor do que um mínimo e velocidade de aproximação do míssil menor do que um mínimo. Os dois últimos parâmetros de simulação são relativos à atmosfera na arena BVR considerada: a pressão e a temperatura. A Figura 3.4 demonstra o painel do simulador BVR com os parâmetros de simulação a serem ajustados antes de simulação.



FIGURA 3.4 – Parâmetros de simulação do simulador de combate aéreo além do alcance visual.

3.1.3.5 Parâmetros de entidades

Para cada entidade presente na simulação, a saber, as aeronaves e os mísseis, uma série de parâmetros é disponibilizada para alteração. Muitos deles dizem respeito à posição e à manobrabilidade da aeronave (altitude, proa, arfagem, velocidade, fator de carga, inclinação inicial, razão de rolamento, curva nivelada). Tais parâmetros são utilizados ou não de acordo com o modo que a aeronave se encontra, podendo estes ser engajamento ou manobra. A Figura 3.5 demonstra o painel do simulador BVR com os parâmetros de entidades a serem ajustados antes de simulação.

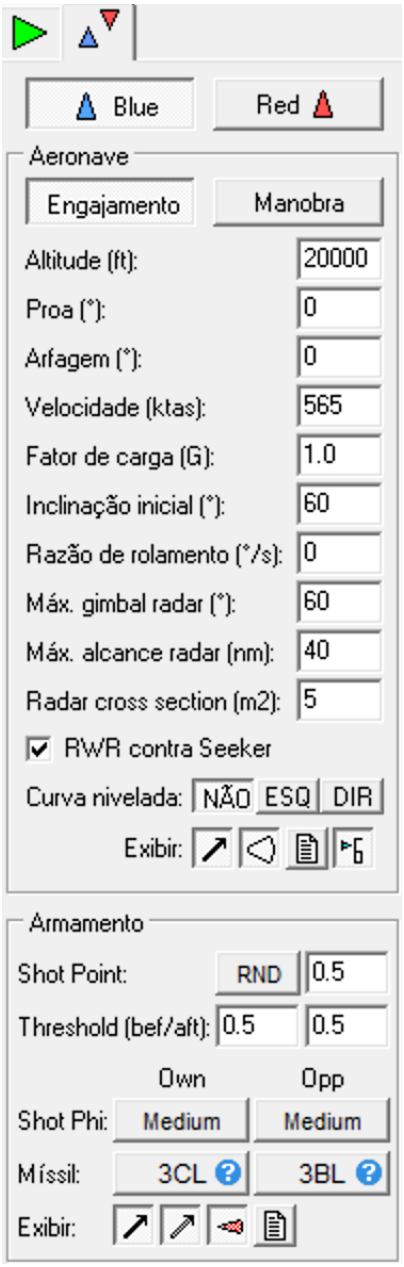


FIGURA 3.5 – Parâmetros de entidades do simulador de combate aéreo além do alcance visual.

No modo de manobra, a entidade utiliza todos parâmetros fornecidos para limitar seu movimento de acordo com o interesse do usuário. Já no caso em que o modo selecionado é o de engajamento, o *plugin* altera os parâmetros de acordo com a necessidade do combate, realizando manobras mais livres. Além disso, são disponibilizados alguns parâmetros referentes a radar (máxima abertura do *gimbal* radar, alcance máximo, *radar cross section*).

Com relação ao armamento, são definidos os parâmetros de tiro: *shot point* (ponto onde é realizado o disparo do míssil), *threshold* (limitante de aceitação do risco) e *shot philosophy* (filosofia de tiro). Além disso, o tipo de míssil que a aeronave possui também passa a ser analisado. É interessante notar que, para os parâmetros *shot philosophy* e tipo de míssil, também são incluídos dados relativos àquilo que o piloto acredita que o oponente adote.

Por fim, nesta categoria são inclusas as opções de visualização do *plugin*, permitindo que o alcance dos radares das aeronaves e dos buscadores dos mísseis, os dados relativos a cada entidade e as rotas desempenhadas pelas aeronaves e mísseis sejam mostrados na tela em tempo de execução.

3.1.4 Tipo de simulação

A simulação e a otimização são as ferramentas da Pesquisa Operacional (PO) mais utilizadas para solução de problemas no mundo real (MASON *et al.*, 2008). Para Law (1991), simulação é o conjunto de técnicas para utilização de computadores para imitar as operações de vários tipos de instalações ou processos. Estas técnicas permitem o teste de novas ideias e propostas para melhorar o processo estudado. Elas podem ser determinísticas, onde as ações de seu agente unicamente determinam sua saída. Um exemplo seria a simulação do comportamento aerodinâmico de uma nova asa de avião por métodos numéricos. Elas também podem ser estocásticas, quando há uma certa imprevisibilidade envolvida na saída da ação. Pode-se citar como exemplo de uma simulação estocástica o comportamento de uma carteira de títulos da bolsa de valores dada a distribuição de probabilidades de cada título (JÚNIOR *et al.*, 2012).

O DoD (1995) definiu três classes distintas de simulação militar: simulação viva, simulação virtual e simulação construtiva. Essas classificações de simulações também são conhecidas por *Live, Virtual and Constructive* (LVC). Em uma simulação viva, pessoas reais operam sistemas reais. Por exemplo, um piloto lançando armas de uma aeronave real em alvos físicos com o objetivo de treinar, testar ou avaliar a capacidade operacional é uma simulação viva. Em uma simulação virtual, pessoas reais operam sistemas simulados. Pode-se citar como exemplo, um piloto pilotando uma aeronave simulada, lançando armas simuladas em alvos simulados. Simulação construtiva é aquela em que todas as entidades são simuladas, tanto seres humanos, quanto os sistemas que eles operam. Pessoas reais

podem apenas dar entradas para a simulação, não determinando seus resultados de maneira direta.

Categorizar simulações em classes distintas como viva, virtual ou construtiva é problemático, pois não há uma divisão clara entre essas categorias. Por exemplo, o grau de participação humana em uma simulação pode variar bastante, assim como o grau de realismo do equipamento. A categorização de simulações também carece de uma categoria para pessoas simuladas interagindo com equipamentos reais. Pessoas simuladas que interagem com equipamentos reais podem desempenhar um papel importante no uso da simulação LVC para teste. As simulações LVC incluem vários níveis de todos os aspectos das classes definidas, que geralmente incluirá pessoas reais, sistemas reais e sistemas simulados interconectados para criar um ambiente simulado no qual possam interagir. Devido a isso, as simulações LVC são, na verdade, simulações híbridas que incluem uma mistura de tipos de entidades. Vale destacar as simulações virtuais que incluem rotineiramente entidades virtuais e construtivas. A Figura 3.6 fornece uma estrutura para classificar simulações viva, virtuais e construtivas com base nos tipos de entidades que elas incluem.

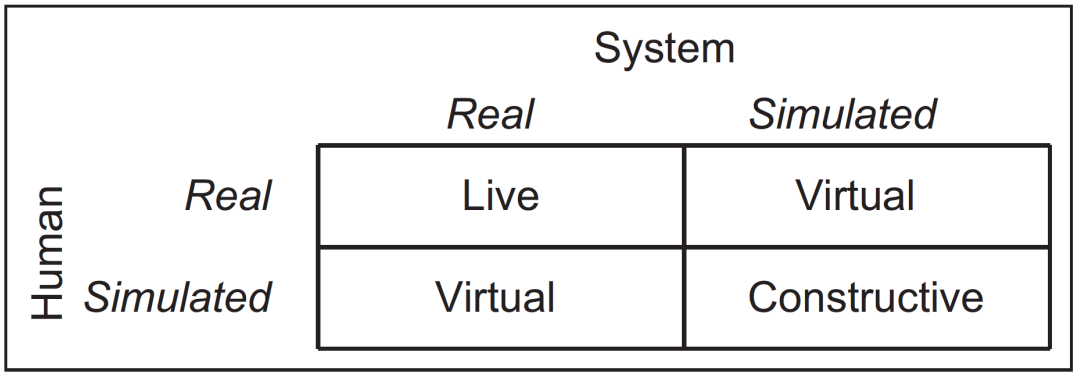


FIGURA 3.6 – Classificação das simulações de operações militares.
Fonte: Hodson e Hill (2014)

Essa estrutura inclui o aspecto de sistemas reais e atribui a classificação com base nos tipos de entidades incluídas. Por exemplo, entidades em uma simulação viva incluem pessoas reais e sistemas reais. Entidades em uma simulação virtual incluem sistemas simulados operados por pessoas reais e sistemas reais operados por pessoas simuladas. Todas as entidades em uma simulação construtiva são simuladas por modelos computacionais.

Hodson e Hill (2014) afirma ainda que as tecnologias de simulação viva, virtual e construtiva estão bem estabelecidas nas áreas de demonstração de tecnologia, ensaio de missão e exercícios. Um novo papel promissor para a tecnologia de simulação de LVC é facilitar o teste de sistemas de armas, produzindo resultados defensáveis.

Esta dissertação irá abordar somente as simulações determinísticas e construtivas. As entidades neste tipo de simulação são completamente simuladas por modelos computacionais e podem ser designadas como *Computer Generated Forces* (CGF), referindo-se a forças

geradas por computador. Tais simulações podem ser *non-real-time*, isto é, serem rodadas em velocidades superiores ao tempo real, já que não há entidades controladas por seres humanos (HODSON, 2009).

3.2 Estudo de caso

Nesta seção, faz-se um relato acerca do estudo de caso utilizado para analisar o combate aéreo além do alcance visual que mostra as principais fases do combate BVR, sendo desempenhadas por entidades que se comportam de acordo com o modelo proposto da seção anterior. Inicialmente se faz uma descrição das particularidades do tipo de estudo de caso da simulação BVR que foi utilizada na dissertação. Em seguida, é feita uma explicação detalhada das principais variáveis envolvidas nas simulações, que são os dados de entrada das simulações de combate aéreo além do alcance visual. Por fim, são descritos os dados de saída analisados das simulações e demonstra-se suas contribuições para o piloto do combate BVR.

3.2.1 Descrição

Para descrever a utilização da modelagem proposta, foi criada uma aplicação que utiliza o *plugin* desenvolvido na plataforma AEROGRAF num cenário BVR um contra um. Inicialmente, as duas aeronaves encontram-se em aproximação, desengajadas e fora do alcance radar de cada uma.

Na modelagem proposta nesta dissertação, será considerado um cenário de jogo entre duas aeronaves em combate aéreo além do alcance visual onde cada uma está equipada com um míssil de médio alcance. Sabe-se que o emprego de um míssil consiste tipicamente em três fases. No início, a aeronave lançadora retransmite a informação do alvo ao míssil na fase de apoio. Na segunda fase, a aeronave realiza uma manobra evasiva (*cranking*), e o míssil continua em direção ao ponto de encontro esperado. Finalmente o míssil liga seu próprio radar e tenta atingir a posição futura do alvo.

Um ataque bem-sucedido e a sobrevivência, dependem de duas variáveis: a probabilidade de que o míssil irá fixar a posição do alvo que depende do erro angular durante a primeira fase de engajamento e a probabilidade de que o ataque irá ser eficaz que depende da velocidade final adquirida pelo míssil. Muitos outros aspectos também afetam essas probabilidades, mas estes são considerados como os mais significativos. Quando elas adentram os limites do *gimbal* radar da oponente, inicia-se a fase de engajamento, conforme mostrado na Figura 3.7. Na Figura 3.8, após o *plugin* realizar os cálculos matemáticos

referentes ao modelo comportamental de cada aeronave, as trajetórias que serão seguidas durante a visualização da simulação são traçadas.

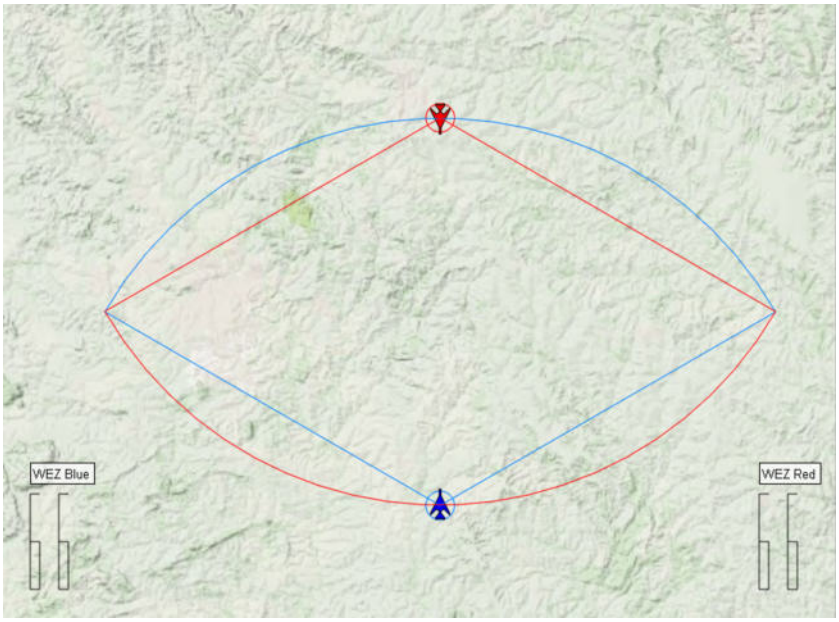


FIGURA 3.7 – Aeronaves adentrando os envelopes radar.

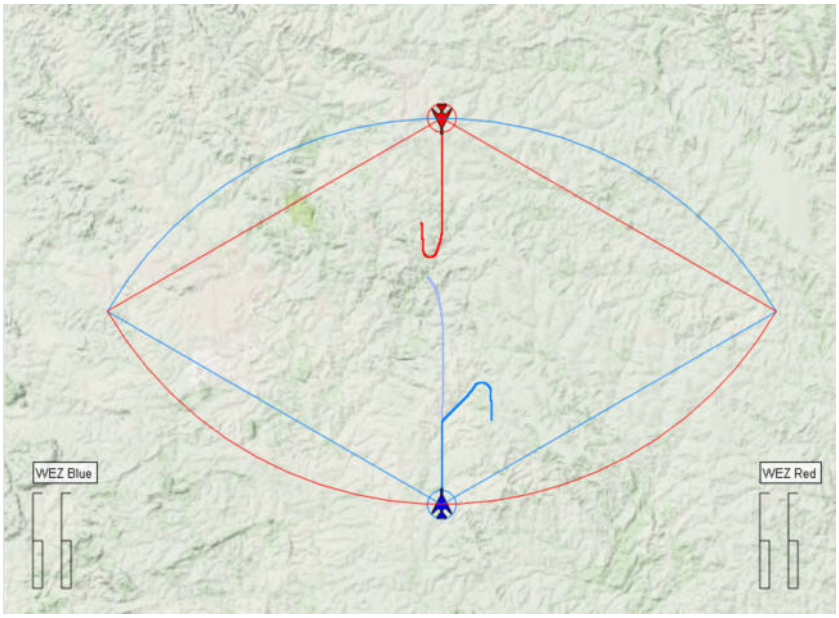


FIGURA 3.8 – Representação das trajetórias calculadas.

Decorrido certo tempo de simulação, a aeronave azul realiza o tiro de seu míssil, já que o ponto randomicamente selecionado de disparo (*shot point*), seguindo a filosofia de tiro selecionada, é alcançado. Nota-se que as WEZ de cada aeronave são indicadas pelo *plugin*, bem como as WEZ estimadas com relação à oponente. Isso pode ser observado na Figura 3.9, assim como o míssil sendo disparado.

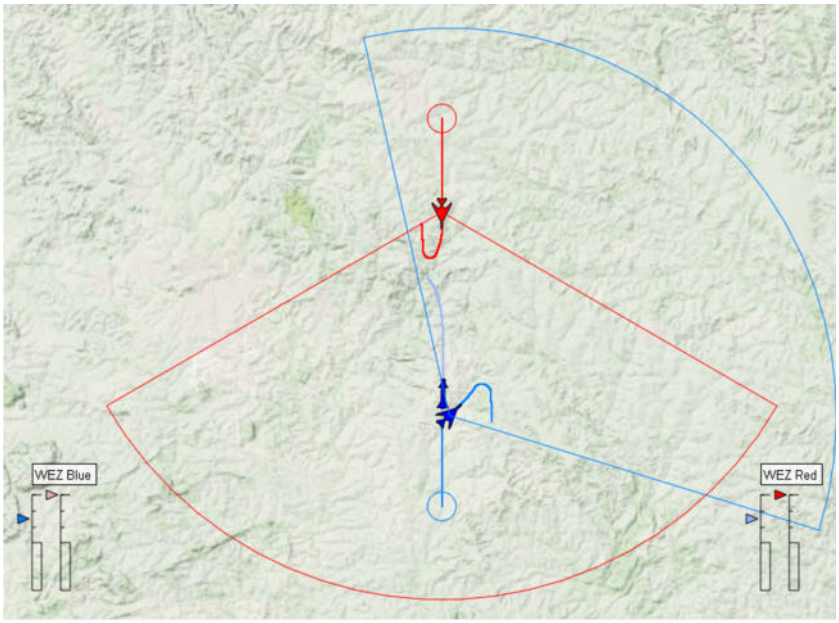


FIGURA 3.9 – Disparo do míssil azul.

O míssil segue sua trajetória até chegar na distância em que se torna ativo, ligando seu *seeker*, o que é visto na Figura 3.10. Se a aeronave inimiga for detectada, ele continua em perseguição direta. Enquanto isso, a aeronave azul realiza uma manobra evasiva *cranking*, deixando a aeronave vermelha dentro dos limites de seu *gimbal*, a fim de continuar a suportar o míssil disparado.

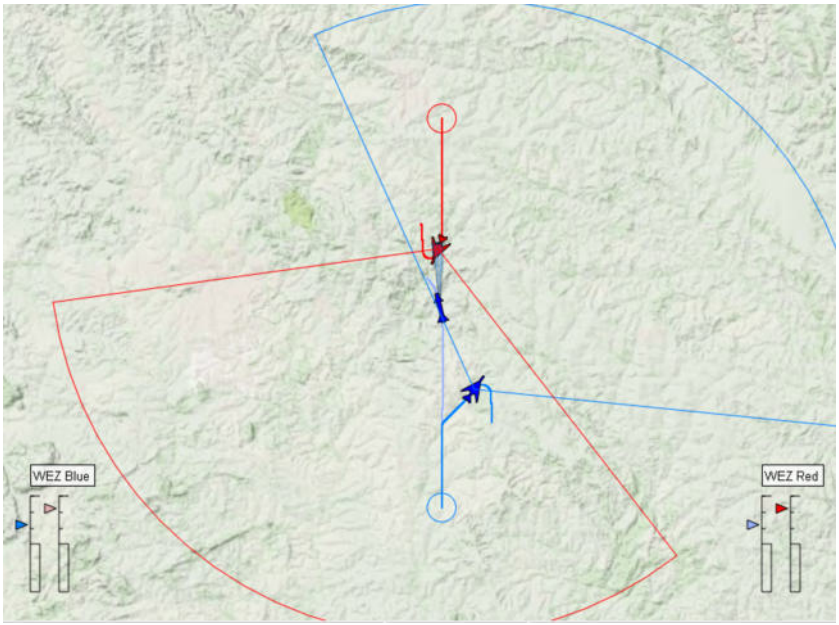


FIGURA 3.10 – Ativação do míssil azul (*seeker*).

Entretanto, ao ativar o *seeker*, inicia-se uma emissão eletromagnética que pode ser detectada pelo sistema de RWR da oponente, gerando uma reação que, conforme programado

no *plugin*, é uma curva de alta performance. Isso é mostrado na Figura 3.11, que também indica que tal manobra foi suficiente para defender a aeronave do míssil disparado.

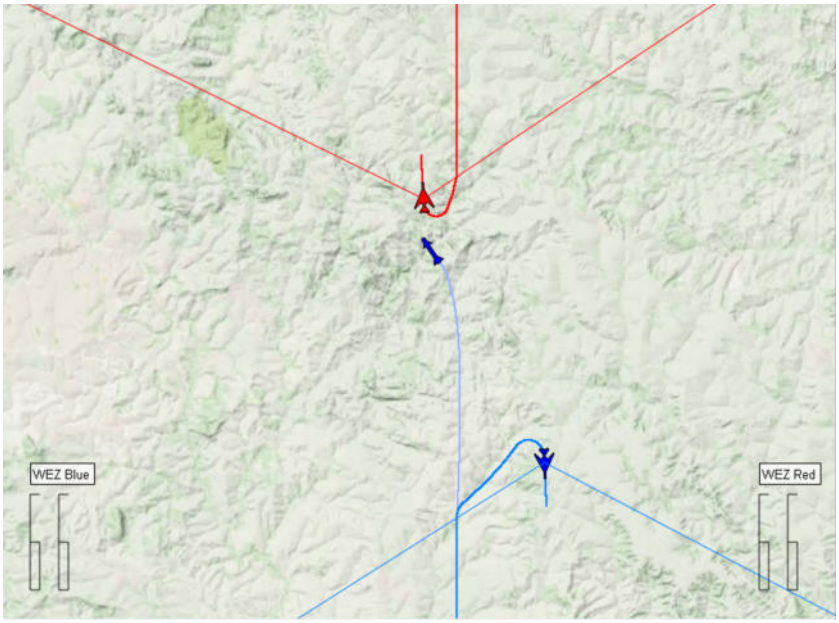


FIGURA 3.11 – Curva de alta performance vermelha e míssil azul neutralizado.

3.2.2 Variáveis de entrada das simulações

Foram analisadas as principais variáveis que coordenam a simulação de um combate aéreo além do alcance visual e serão descritas na seguinte subseção. Trinta e seis variáveis foram determinadas como as mais importantes para definir o andamento das simulações baseado no estudo de caso, conforme descrito na subseção anterior. Há variáveis categóricas e numéricas com diferentes intervalos de abrangência. A definição desses intervalos de atuação das variáveis no simulador foi feita baseado no conhecimento prático dos pilotos e em análises de especialistas em combate BVR. A seguir, é realizada a descrição de cada uma das variáveis de entrada das simulações.

3.2.2.1 Posição relativa

Posição relativa é variável definida como a relação posicional entre as aeronaves azul e vermelha. Essa variável é numérica e foi definido um intervalo de zero a sessenta graus, $[0°, 60°]$, para representá-la. A utilização desse intervalo para definir essa variável de entrada é baseada no limite de alcance radial do radar ($60°$). Para as simulações propostas foi utilizado a aeronave azul como referências para o cálculo da posição relativa. Portanto, a aeronave base é fixada e aeronave vermelha varia sua posição de zero a sessenta graus, sempre com sua proa alinhada com a reta imaginária que liga as duas aeronaves. Observe a Figura 3.12 que mostra a definição da variável descrita.

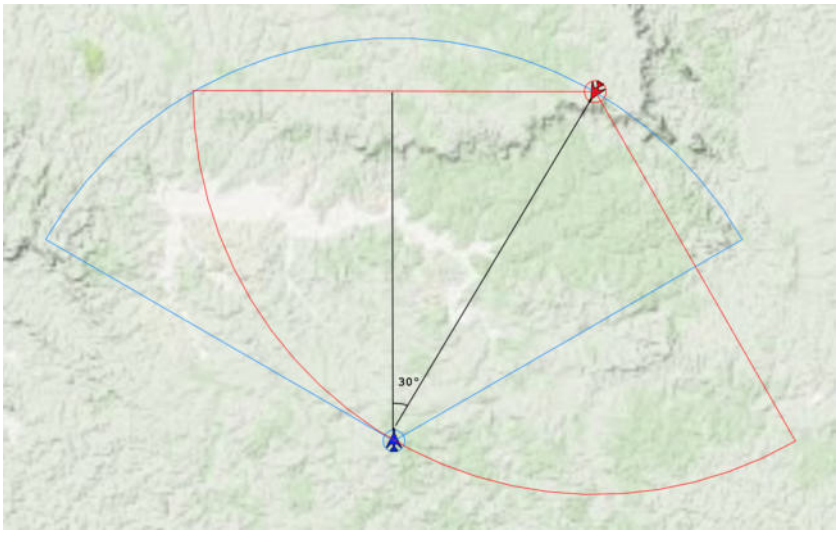


FIGURA 3.12 – Posição relativa de 30° entre as aeronaves azul e vermelha.

3.2.2.2 Distância

Essa variável numérica retrata a distância relativa entre as duas aeronaves, calculada em milhas náuticas (nm). Foi definido como intervalo para distância uma variação entre 25 nm e 50 nm por se tratar das distâncias que, em geral, o combate aéreo além do alcance visual ocorre. Um fato a ser destacado é que as aeronaves podem estar em altitudes diferentes durante o combate e, portanto, essa variável distância vai medir o comprimento do segmento de reta que une as duas aeronaves consideradas (azul e vermelha). Observe a Figura 3.13 que mostra a referência da variável distância.

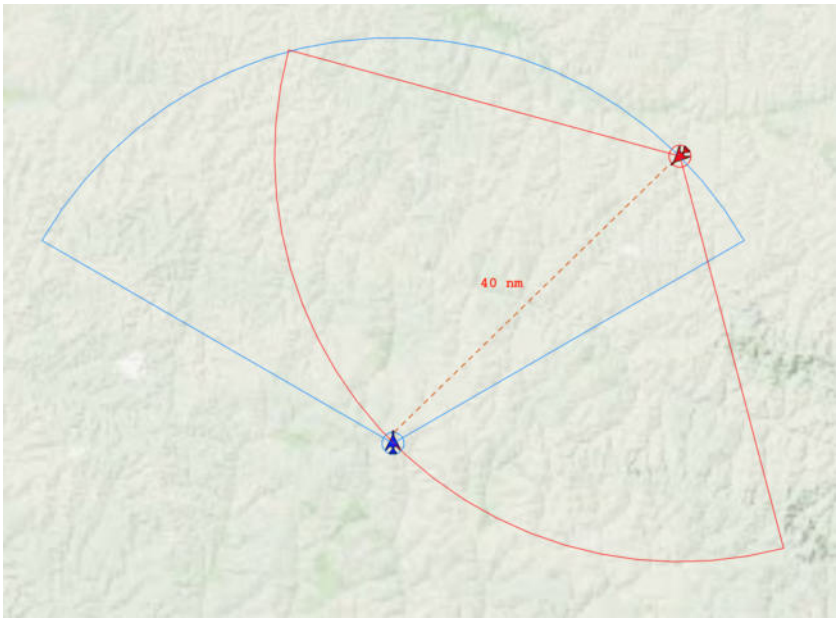


FIGURA 3.13 – Distância de 40 nm entre as aeronaves azul e vermelha.

3.2.2.3 Altitude

Altitude é uma variável numérica muito importante em um combate aéreo além do alcance visual, pois é um fator determinante da quantidade de energia que cada aeronave possui a cada instante. Uma maior quantidade de energia permite uma maior performance em um combate aéreo. Baseado no conhecimento de especialistas e pilotos de combate BVR, foi definido um intervalo de altitude para as simulações entre 20000 ft e 35000 ft, que geralmente são as altitudes que o combate além do alcance visual ocorre.

Pode-se definir, portanto, que o combate BVR, no estudo de caso analisado no simulador, está ocorrendo do FL200 ao FL350. O nível de voo é o nível de pressão atmosférica constante relativo ao nível de pressão atmosférica de 1.013,25 hPa e é indicado por FL (*Flight Level*) seguido de 3 dígitos referentes às centenas de pés (ANAC, 2011). Os dígitos são utilizados em múltiplos de 500 ft, sempre terminando em 0 ou 5.

3.2.2.4 Velocidade

As velocidades no combate aéreo além do alcance visual podem ser mais rápidas que o próprio som. Velocidades superiores traduzem em um ataque e defesa mais eficazes. Porém acabam gerando maior consumo de combustível, o que diminui a autonomia da aeronave para o combate. Para a análise das simulações empregadas no modelo descrito, foi utilizado para essa variável numérica o intervalo entre Mach 0.8 e Mach 1.00 por se tratar dos valores de velocidade das aeronaves que de forma geral ocorre no combate BVR. Observa-se que para realizar a conversão de Mach para knot, conforme definido nas definições dos parâmetros das entidades, é necessário considerar a altitude e temperatura consideradas, pois a velocidade do som varia conforme mudança destas grandezas.

3.2.2.5 *Radar Warning Receiver*

Radar Warning Receiver (RWR) é um sistema bastante utilizado no combate BVR que se baseia na detecção de ondas eletromagnéticas dos sistemas de radar que iluminam a antena receptora do RWR. Como as aeronaves oponentes estão a uma distância que não permite sua identificação visual, o combate muito se baseia em informações desses sensores disponíveis no combate. O RWR faz a emissão de um aviso quando o sinal de radar que pode ser uma possível ameaça detectada, podendo ser utilizado de forma manual ou de forma autônoma com a finalidade de fugir da ameaça detectada. A variável categórica RWR assume valores 1 quando a aeronave possuir o equipamento operante e valores 0 quando não possui equipamento ou se ele não estiver ativo no momento. A presença do RWR no combate BVR tem muita influência no combate aéreo além do alcance visual real, pois fornece uma maior percepção das ameaças em um combate ao piloto e permite

a realização de manobras evasivas de forma consciente e assertiva que garantem a sua sobrevivência. Nas simulações descritas no estudo de caso analisado pode ser verificado, posteriormente, a contribuição que o equipamento de detecção de ondas eletromagnéticas possui nos resultados finais dos combates realizados.

3.2.2.6 Tipo de míssil

Para simular este tipo de cenário operacional proposto no estudo de caso, foram utilizados no simulador BVR três tipos de mísseis que foram classificados como: AM-3AL, AM-3BL e AM-3CL (Figura 3.14).

Por ser tratar de uma variável categórica onde a entrada 1 significa a presença de determinado míssil na aeronave e a entrada 0 determina que aquela aeronave não possui o míssil em questão, para cada tipo de agente (azul e vermelho) foram criadas três entradas distintas que representam os mísseis AM-3AL, AM-3BL e AM-3CL onde a entrada 1 só poderá ocorrer em uma das variáveis para cada aeronave. Dessa forma, as possibilidades de entradas são $(1, 0, 0)$, $(0, 1, 0)$ e $(0, 0, 1)$ para cada aeronave já que no estudo de caso proposto é admitido somente o carregamento de um míssil por aeronave.

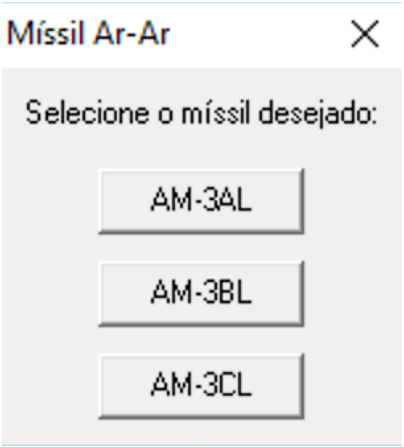


FIGURA 3.14 – Seleção do tipo de míssil no simulador BVR.

Na presente dissertação, o modelo de míssil adotado para caracterizar os mísseis AM-3AL, AM-3BL e AM-3CL foi o proposto por Broadston (2011) para o AIM-120 AMRAAM com suas características e dinâmica de voo. O modelo de míssil foi criado com base nas capacidades relatadas na literatura de código aberto dos artigos disponíveis na comunidade científica. Além disso, algumas aproximações foram consideradas para sua caracterização, contudo sem comprometer a representação dos mísseis no simulador de combate aéreo além do alcance visual . Portanto, não se pretende que o modelo seja uma réplica exata das capacidades reais do míssil. No entanto, o modelo de simulação é criado de forma modular para que as características do modelo de míssil possam ser facilmente modificadas e inseridas na simulação, conforme necessário. As dimensões do corpo de mísseis usadas

nesta simulação são dadas na Tabela 3.1 e foram simplificadas para seguir os modelos descritos em Blakelock (1965) e Zarchan (1997).

TABELA 3.1 – Resumo das dimensões do míssil utilizado na modelagem do simulador de combate aéreo além do alcance visual.

Description	**Value**
Missile body dimensions	
Missille mass	156.8 kg
Missile diameter	0.1778 m
Location of c.g. measured from the nose	1.8288 m
Length of the nose cone	0.6769 m
Missile tailplane dimensions	
Hinge line distance from nose	3.454 m
Tail root chord	0.4061 m
Tail tip chord	0.0676 m
Tail extension	0.0676 m
Tail height	0.2286 m
Missile wingplane dimensions	
Wing to radome tangecy point distance from nose	1.134 m
Wing root chord	0.3554 m
Wing tip chord	0 m
Wing extension	0 m
Wing height	0.1778 m

Fonte: Broadston (2011)

A seguir, serão descritos alguns componentes dos mísseis utilizados no estudo de caso analisado. *Proximity fuze* (espoleta de proximidade) é um transmissor e receptor instalado no nariz de um projétil antiaéreo, que detona o míssil quando próximo da aeronave. A espoleta sente quando um alvo está perto o suficiente para ser danificado ou destruído pela sua explosão. O sensor normalmente é um pequeno conjunto de radares que envia sinais e recebe sinais refletidos de objetos próximos.

Os benefícios do *proximity fuze* que funciona quando detecta um alvo próximo são claros pois permite a efetividade do armamento utilizado, particularmente para uso contra aeronaves (HOGG, 1970). O *proximity fuze* melhora o desempenho na distância efetiva de fragmentação do míssil. O ponto de ruptura ideal varia de acordo com a natureza do alvo (NASSER *et al.*, 2015). O ponto de ruptura ideal contra um alvo aéreo pode ser o ponto de aproximação mais próximo da aeronave ou um ponto ótimo de acordo com alguns critérios pré-definidos.

Para os mísseis modelados no simulador de combate aéreo além do alcance visual foi estabelecido que a distância mínima que o míssil deve atingir do alvo para o *proximity fuze* ativar a espoleta seja 10 metros. Com isso, baseado nesse valor limite, foram determinados o sucesso e o fracasso nas missões de ataque e defesa no primeiro tipo de caso analisado.

O segundo caso analisado se refere ao guiamento do míssil. A capacidade de guiar um míssil para um alvo detectado é a mais primária das leis de orientação. Em outras palavras, o objetivo da orientação é atingir o alvo (YANUSHEVSKY, 2008).

A orientação do míssil depende de seu *seeker* de bordo para detectar o alvo e calcular a orientação de comando necessária através de circuitos lógicos. Eles podem ser ativos, passivos ou mesmo semi-ativos, utilizando ondas eletromagnéticas de um radar, um sensor de infravermelho ou um laser. Este conjunto de habilidades sensoriais permite que o buscador detecte e identifique o alvo e guie o míssil até ele. A orientação de perseguição basicamente afirma que, enquanto o míssil estiver apontado para o alvo em todos os momentos, com energia cinética suficiente, o míssil atingirá o alvo. Porém, isso nem sempre ocorre dessa forma, pois a energia cinética disponível para esse míssil é limitada. O propulsor do míssil faz o projétil atingir a velocidade máxima dentro de segundos após o lançamento antes do combustível/propelente ser totalmente consumido e o míssil continua o resto do movimento apenas com energia cinética adquirida. Assim, na orientação de busca, o míssil está mais sucetível a ficar sem energia cinética antes de poder atingir com sucesso com o alvo (BROADSTON, 2011).

Para os mísseis modelados no problema proposto, foi adotado um *seeker* do tipo ativo. Portanto, em um primeiro momento os dados de posição do alvo passam a ser transmitidos pela aeronave para o míssil via *uplink*. A partir de certa distância do alvo, o míssil passa a ser ativo e o seu *seeker* começa, efetivamente, a realizar sua função de guiar, independente da aeronave lançadora, o míssil para atingir o alvo. O conceito do *seeker* do míssil é importante para entender o segundo tipo de caso analisado, pois foi escolhido como limite de distância o momento em que o *seeker* passe a ser ativo no míssil modelado. Baseado no míssil AIM-120 AMRAAM, conforme modelado no simulador de combate aéreo além alcance visual, foi adotado a distância de 10.000 metros do alvo para que o *seeker* passa a ser ativo no míssil e ele possa fazer sua orientação de forma independente.

Portanto, os três tipos de míssil descritos no simulador de combate aéreo além do alcance visual, AM-3AL, AM-3BL e AM-3CL, tratam-se do mesmo míssil, porém, observando, de forma qualitativa, uma performance crescente partindo do AM-3AL, em seguida o AM-3BL e, por fim, o com melhores valores de eficiência em combate o AM-3CL. Essa hierarquia entre os mísseis é importante para que possa ser realizado simulações em diversas configurações que irão permitir analisar o combate com inimigos que possuem mísseis superiores ou inferiores em relação à FAB, melhorando a sua capacidade de planejamento em cenários operacionais reais.

Por fim, na Figura 3.15 é demonstrada uma imagem ilustrativa do míssil AIM-120 AMRAAM, utilizado como míssil base para aqueles modelados no simulador de combate aéreo além do alcance visual. O seu raio limite para alcançar o alvo quando lançado em direção à posição futura de uma possível aeronave inimiga está representado por r_{cap}.

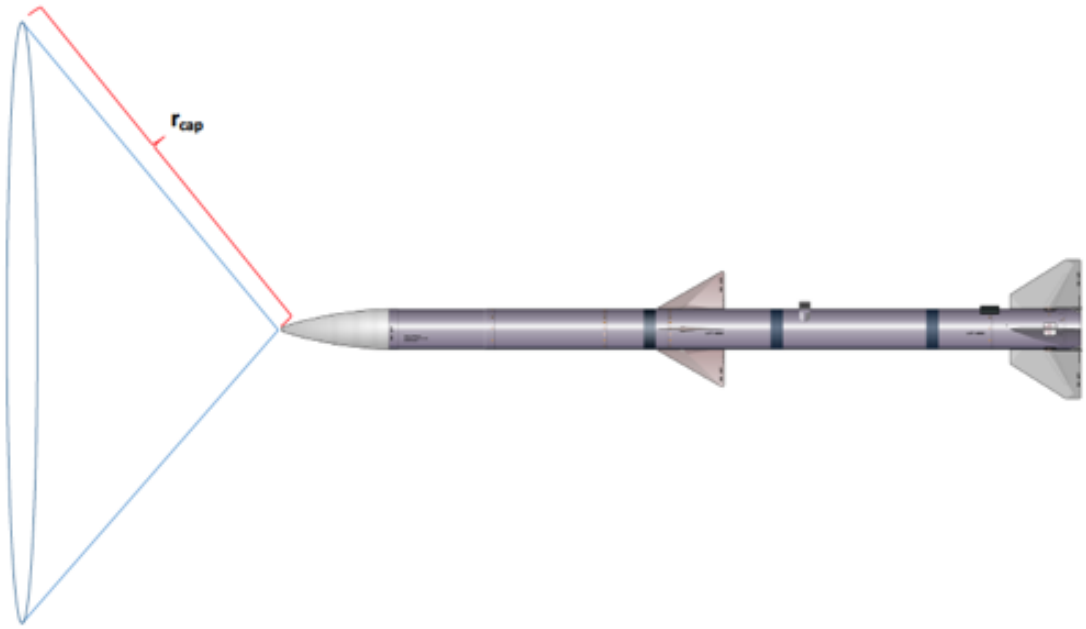


FIGURA 3.15 – Raio limite para alcançar o alvo (r_{cap}) do míssil AIM-120 AMRAAM.
Fonte: Dantas (2017)

3.2.2.7 Filosofia de tiro

As decisões dos pilotos devem estar também pautadas nas diretrizes de combate recebidas por seus respectivos esquadrões. Uma importante diretriz é a filosofia de tiro (*shot philosophy*), que determina as distâncias mínimas em que o disparo deve ser efetuado. Tais distâncias são definidas com base na doutrina adotada, bem como nos recursos disponíveis, já que, caso não haja grande disponibilidade de armamentos, por exemplo, é necessário que estes só sejam utilizados quando se tem maior certeza de sua efetividade.

Conforme descrito anteriormente na Subseção 3.1.3, a filosofia de tiro pode ser classificada em *short*, *medium* e *long*. Analogamente a escolha do tipo de míssil para as aeronaves na simulação, foram criadas variáveis categóricas para cada tipo de filosofia de tiro analisada, onde a entrada 1 e 0 representam, respectivamente, a escolha ou não de determinada filosofia de tiro. Dessa forma, considerando apenas as filosofias de tiro para cada agente em específico, as possibilidades de entradas são $(1, 0, 0)$, $(0, 1, 0)$ e $(0, 0, 1)$ que representam, respectivamente, a escolha por *short*, *medium* e *long*. Observa-se que cada agente só pode adotar um tipo de filosofia de tiro para cada simulação. Para a filosofia de tiro esperada da aeronave inimiga, foram realizados os mesmos procedimentos, ou seja,

foram criadas 3 variáveis categóricas para representar as possíveis filosofias de tiro do agente inimigo.

3.2.2.8 *Thresholds*

São definidos dois *thresholds* que guiam as decisões da aeronave no que tange a manobras defensivas. Ambos representam a aversão ao risco que o piloto possui, só que em fases diferentes do combate. É uma variável que representa a atitude de risco do piloto que indica se o piloto está com uma maior tendência de valorizar o sucesso em abater o alvo ou a sua própria sobrevivência.

O primeiro é utilizado para a fase anterior ao disparo do míssil e o segundo para a posterior. Tal divisão foi feita para que se pudesse aumentar a aceitação do risco por parte do piloto após ter realizado o tiro, posto que já se comprometeu com o disparo. Isso fica, contudo, a cargo do analista, que pode deixar ambos os *thresholds* com o mesmo valor. Os *thresholds* variam no intervalo $[0, 1]$ onde valores próximos de 0 ou 1 representam, respectivamente, uma maior aversão ou aceitação ao risco. Portanto, por exemplo, um piloto conservador, que prioriza a sua sobrevivência em relação ao abate da aeronave inimiga, terá um valor de *thresholds* baixo.

Tais valores devem ser calibrados a fim de representarem comportamentos próximos ao que se espera de um piloto de combate BVR, considerando a doutrina vigente e as condições político-estratégicas em que o combate simulado se insere.

3.2.3 Design de experimentos

O Design de Experimentos ou *Design of Experiments* (DOE) é uma atividade importante para qualquer cientista, engenheiro ou estatístico que planeja conduzir análises experimentais. Este exercício tornou-se crítico nesta era de campo em rápida expansão da ciência de dados e modelagem estatística associada e aprendizado de máquina. Um DOE bem planejado pode dar ao pesquisador um conjunto de dados significativo para atuar com um número ideal de experimentos, preservando recursos críticos.

Afinal, o objetivo da *Data Science* é essencialmente conduzir a investigação e modelagem científica da mais alta qualidade com dados do mundo real. E para fazer uma boa ciência com dados, é necessário coletá-la por meio de experimentos cuidadosamente planejados para cobrir todos os casos específicos e reduzir qualquer possível viés.

Em sua forma mais simples, um experimento científico tem como objetivo prever o resultado introduzindo uma mudança das pré-condições, que é representada por uma ou mais variáveis independentes, que são as variáveis de entrada (variáveis preditoras). Essas

variáveis resultam em uma ou mais variáveis dependentes, também referidas como variáveis de saída (variáveis de resposta). O projeto experimental também pode identificar variáveis de controle que devem ser mantidas constantes para evitar fatores externos, afetando os resultados.

Existem várias abordagens para determinar o conjunto de pontos a serem utilizados para as análises preditivas. Para garantir que as variáveis de entrada foram completamente abrangidas em seus respectivos intervalos estabelecidos de acordo com a aplicabilidade do combate aéreo além do alcance visual, conforme demonstrado na Subseção 3.2.2, foi utilizado a amostragem por hipercubo latino, que garante a amostragem aleatória das variáveis preditoras.

3.2.3.1 Amostragem por hipercubo latino

Amostragem por hipercubo latino ou *Latin Hypercube Sampling*, sugerida por McKay *et al.* (1979), é um método de amostragem que pode ser usado para produzir valores de entrada para estimativa de expectativas de funções de variáveis de saída. Posteriormente, Iman (1992) ampliou e desenvolveu técnicas independentes equivalentes a LHS. Esse método estatístico gera uma amostra aleatória de valores de parâmetros a partir de uma distribuição em múltiplas dimensões. A amostragem LHS, em linhas gerais, consiste em subdividir o universo de amostras em um certo número de subconjuntos disjuntos e para cada um desses subconjuntos extrair um elemento representativo, que é escolhido de forma aleatória. O LHS é baseado no design do quadrado latino, que tem uma única amostra em cada linha e coluna. Um hipercubo é um cubo com mais de três dimensões: o quadrado latino é estendido para amostras de várias dimensões e vários hiperplanos.

Em se tratando do contexto de amostragem estatística, a Amostragem por Hipercubo Latino irá ocorrer se houver apenas uma amostra em cada linha e cada coluna, tratando-se, nesse caso, em uma generalização desse conceito para um número arbitrário de dimensões, em que cada amostra é a única em cada hiperplano alinhado ao eixo que a contém (MONTGOMERY; WILEY, 2013).

O método de Monte-Carlo clássico utiliza a amostragem aleatória simples. Em geral, a amostragem aleatória simples faz uso do método da transformada inversa para gerar valores aleatórios para uma determinada distribuição de probabilidades, a partir de valores gerados segundo uma distribuição uniforme $[0, 1]$. As técnicas de amostragem abordadas neste item diferem da tradicional amostragem aleatória simples por terem um controle parcial do processo da amostragem, resultando desta forma em uma redução da variância dos estimadores, ou dito de outra forma, um aumento na precisão dos resultados das simulações (EDUARDO *et al.*, 2007).

A LHS é normalmente usada para economizar tempo de processamento do computador durante a execução de simulações de Monte Carlo. Estudos mostraram que um LHS bem realizado pode reduzir o tempo de processamento em até 50% em comparação a uma amostragem padrão de importância de Monte Carlo (OLSSON *et al.*, 2003). De forma geral, LHS é um método de simulação, semelhante ao método de Monte Carlo, que, na maioria dos casos, converge para melhores resultados (SHIELDS; ZHANG, 2016). Para Helton e Davis (2003), a Amostragem de Hipercubos Latinos pode ser vista como um procedimento que incorpora muitas das características desejáveis da amostragem aleatória e da amostragem estratificada e também produz resultados de análises mais estáveis do que a amostragem aleatória mostrada no método de Monte Carlo. Um conjunto de pontos de design aleatórios dentro de um determinado intervalo poderia ser atraente para o experimentador avaliar o impacto das variáveis do processo de saída. Simulações de Monte Carlo são um exemplo próximo dessa abordagem. No entanto, um design de Hipercubo Latino é a melhor escolha para o design experimental, em vez de construir uma matriz aleatória completa, uma vez que tenta subdividir o espaço amostral em células menores e escolher apenas um elemento de cada sub-célula (OLSSON *et al.*, 2003).

A utilização do simulador de combate além do alcance visual de forma não-automatizada se torna inviável para geração de um grande número de amostras de entradas para as simulações do combate BVR. Para tornar o processo mais rápido, eficiente e menos custoso em termos de tempo e processamento, adotou-se um método de geração de dados de entrada que abrangesse todos os intervalos das variáveis que foram descritas na subseção anterior de modo que os valores escolhidos para as variáveis estão mais bem distribuídas possíveis. A *Latin Hypercube Sampling* garante uma melhor distribuição dos valores de entrada nos intervalos propostos do que o método de Monte Carlo, que poderia acabar gerando uma concentração de pontos em determinados espaços em detrimento de outros valores que não seriam contemplados. A LHS garante uma melhor distribuição dos valores de entrada que permite obter informações mais condizentes e abrangentes das simulações de combate além do alcance visual propostas.

Utilizando o algoritmo da *Latin Hypercube Sampling*, foram gerados 100, 1.000 e 10.000 simulações utilizando o simulador de combate aéreo além do alcance visual. A partir das entradas geradas foram criadas arquiteturas para modelos de aprendizagem de máquina baseados em redes neurais artificiais para cada uma das saídas, que serão descritas na próxima seção.

3.2.4 Variáveis de saída das simulações

As simulações de combate BVR fornecem uma grande quantidade de informações referentes ao resultado da simulação. Para as análises feitas nesta dissertação, serão destacadas

as variáveis numéricas referentes às menores distâncias que os mísseis das aeronaves azul e vermelha, que foram lançados para ao seus respectivos oponentes, conseguiram atingir durante a simulação. Esse parâmetro permite que se possa analisar o grau de sucesso na missão em termos ofensivos e defensivos. Observa-se que uma menor distância do míssil ao alvo significa que mais próximo ele está de atingir seu objetivo que é destruir o oponente. Após atingir determinado limite de distância do alvo, o míssil irá ter sucessos.

Essas distâncias dizem respeito a quanto o piloto BVR se engajou em garantir um ataque ou uma defesa bem-sucedida. Os pilotos podem selecionar livremente a duração de suas fases de suporte, ou seja, o quanto tempo eles vão guiar o míssil até este encontrar o alvo e quando eles iniciarão uma curva defensiva. Conforme Karelahti *et al.* (2006), prolongar a fase de suporte encurta a fase de evasão, o que aumenta a probabilidade de acerto. A probabilidade de sobrevivência diminui porque fornecer suporte ao míssil lançado requer voar em direção a um míssil potencialmente lançado pelo adversário. As probabilidades acima mencionadas dependem das ações do adversário também. Assim, o problema em análise do jogo é selecionar as manobras e tempos de suporte que maximizam essas probabilidades sob a suposição de que o adversário se comporta racionalmente (DANTAS, 2017). Os *thresholds*, definidos na Subseção 3.2.2, relacionam-se diretamente a suscetibilidade dos pilotos ao risco, ou seja, o quanto estão dispostos a prolongar a fase de suporte e encurtar a fase de evasão.

3.3 Desenvolvimento do modelo de aprendizagem

Nesta seção da dissertação, serão desenvolvidas ferramentas e técnicas necessárias para um modelo fazer uma previsão. Ser capaz de fazer avaliações precisas do desempenho de cada modelo através do uso dessas ferramentas e técnicas ajuda a reforçar muito a confiança em suas previsões. A implementação de uma rede com múltiplas camadas requer a definição dos sinais de entrada e saída, a escolha da arquitetura a ser empregada e o treinamento da rede. A primeira etapa trata-se de organizar um conjunto de amostras que serão utilizadas para os treinamentos das redes neurais artificiais, além de definir quantas entradas e saídas a mesma irá possuir. Na segunda etapa, é determinada a estrutura que seja mais conveniente para desempenhar a tarefa desejada. O processo de treinamento, ou aprendizagem, compreendido na terceira etapa, ocorre através do ajuste dos pesos sinápticos para adequar a resposta da rede neural ao problema desejado. Será visto a seguir toda a metodologia referente ao desenvolvimento do modelo de aprendizado baseado em redes neurais artificiais para o simulador de combate aéreo além do alcance visual.

3.3.1 Exploração dos dados

Inicialmente, foi preparado um ambiente para a realização da análise exploratória dos dados de entrada e saída obtidos das simulações de combate aéreo além do alcance visual. Visando a estruturação desse ambiente e a seleção das tecnologias, considerou-se a natureza dos dados e as necessidades da FAB para solução de problemas.

Os trabalhos com ciência de dados para solução de problemas operacionais reais, de forma geral, adotam medidas conservadores em se tratando da escolha das ferramentas para a análise de dados. Os cientistas de dados da atualidade preferem trabalhar com ferramentas simples que permitem novos métodos analíticos com a adição de novos pacotes (CÂMARA *et al.*, 2016). Dessa forma, foram escolhidas ferramentas livres e que favorecessem a realização da análise de forma colaborativa e que pudessem ser facilmente reproduzidas por outros pesquisadores.

O ambiente de desenvolvimento R e a linguagem de alto nível *Python* são escolhas frequentes de analistas de dados por contarem com uma variedade de ferramentas estatísticas, gráficas e de análise numérica. Para o ambiente utilizado nesta dissertação, foi escolhida a linguagem *Python*. Wagner *et al.* (2017) afirma que a escolha é motivada pela sua crescente popularidade na comunidade acadêmica e a disponibilidade de pacotes para computação científica (*NumPy* e *SciPy*), manipulação e análise de dados (*Pandas*), manipulação e visualização de dados (*Matplotlib* e *Seaborn*) e para análise de bancos de dados utilizando inteligência artificial (*Scikit-learn*).

Como ambiente de desenvolvimento para integrar essas tecnologias, foi selecionado o *Spyder*. Essa plataforma é um ambiente de análise que permite a elaboração de programas, a rápida visualização do tipo e dos valores das variáveis escolhidas para análise e conta com uma rápida visualização dos dados desejados.

Em resumo, o conjunto de dados totaliza 36 entradas e 2 saídas, que representam as mais relevantes variáveis consideradas para a formulação dos modelos de aprendizado de máquina propostas nesta pesquisa. Esta base de dados foi dividida nas 38 colunas de dados assim nomeadas: *posicao_relativa, distancia, altitude_blue, altitude_red, velocidade_blue, velocidade_red, blue_rwr, red_rwr, missil_blue_a, missil_blue_b, missil_blue_c, missil_est_red_a, missil_est_red_b, missil_est_red_c, missil_red_a, missil_red_b, missil_red_c, missil_est_blue_a, missil_est_blue_b, missil_est_blue_c, shotphi_blue_s, shotphi_blue_m, shotphi_blue_l, shotphi_est_red_s, shotphi_est_red_m, shotphi_est_red_l, shotphi_red_s, shotphi_red_m, shotphi_red_l, shotphi_est_blue_s, shotphi_est_blue_m, shotphi_est_blue_l, threshold_before_blue, threshold_after_blue, threshold_before_red, threshold_after_red, dist_BM_RA, dist_RM_BA*. A Tabela 3.2 demonstra o significado de cada variável.

TABELA 3.2 – Significado das variáveis de entrada e saída utilizadas no modelo de aprendizagem.

Variável	**Significado**
posicao_relativa	Posição relativa entre as aeronaves azul e vermelha
distancia	Distância entre as aeronaves azul e vermelha
altitude_blue	Altitude da aeronave azul
altitude_red	Altitude da aeronave vermelha
velocidade_blue	Velocidade da aeronave azul
velocidade_red	Velocidade da aeronave vermelha
blue_rwr	RWR operante na aeronave azul
red_rwr	RWR operante na aeronave vermelha
missil_blue_a	Aeronave azul equipada com missil AM-3AL
missil_blue_b	Aeronave azul equipada com missil AM-3BL
missil_blue_c	Aeronave azul equipada com missil AM-3CL
missil_est_red_a	Aeronave azul estima aeronave vermelha equipada com missil AM-3AL
missil_est_red_b	Aeronave azul estima aeronave vermelha equipada com missil AM-3BL
missil_est_red_c	Aeronave azul estima aeronave vermelha equipada com missil AM-3CL
missil_red_a	Aeronave vermelha equipada com missil AM-3AL
missil_red_b	Aeronave vermelha equipada com missil AM-3BL
missil_red_c	Aeronave vermelha equipada com missil AM-3CL
missil_est_blue_a	Aeronave vermelha estima aeronave azul equipada com missil AM-3AL
missil_est_blue_b	Aeronave vermelha estima aeronave azul equipada com missil AM-3BL
missil_est_blue_c	Aeronave vermelha estima aeronave azul equipada com missil AM-3CL
shotphi_blue_s	Aeronave azul com filosofia de tiro short
shotphi_blue_m	Aeronave azul com filosofia de tiro medium
shotphi_blue_l	Aeronave azul com filosofia de tiro long
shotphi_est_red_s	Aeronave azul estima aeronave vermelha com filosofia de tiro short
shotphi_est_red_m	Aeronave azul estima aeronave vermelha com filosofia de tiro medium
shotphi_est_red_l	Aeronave azul estima aeronave vermelha com filosofia de tiro long
shotphi_red_s	Aeronave vermelha com filosofia de tiro short
shotphi_red_m	Aeronave vermelha com filosofia de tiro medium
shotphi_red_l	Aeronave vermelha com filosofia de tiro long
shotphi_est_blue_s	Aeronave vermelha estima aeronave azul com filosofia de tiro short
shotphi_est_blue_m	Aeronave vermelha estima aeronave azul com filosofia de tiro medium
shotphi_est_blue_l	Aeronave vermelha estima aeronave azul com filosofia de tiro long
threshold_before_blue	Threshold da aeronave azul antes do lançamento do míssil
threshold_after_blue	Threshold da aeronave azul depois do lançamento do míssil
threshold_before_red	Threshold da aeronave vermelha antes do lançamento do míssil
threshold_after_red	Threshold da aeronave vermelha depois do lançamento do míssil
dist_BM_RA	Distância entre o míssil da aeronave azul e a aeronave vermelha
dist_RM_BA	Distância entre o míssil da aeronave vermelha e a aeronave azul

As Figuras 3.16 e 3.17 representam, respectivamente, uma amostra dos grupamentos de dados de entrada e saída que foram definidos para as análises.

posicao_relativa	distancia	altitude_blue	altitude_red	velocidade_blue	velocidade_red	blue_rwr	red_rwr	missil_blue_a	missil_blue_b	missil_blue_c	missil_est_red_a
0.00325427	31.6034	33999.2	34103	0.822114	0.918976	1	0	1	0	0	0
0.0113592	35.0811	34403.8	30306.8	0.97413	0.97685	0	0	0	1	0	0
0.0135801	44.2713	21701.5	29066.1	0.804774	0.854407	1	0	0	1	0	0
0.0209921	28.8813	26424.7	25990.1	0.829339	0.894299	0	0	1	0	0	0
0.0285112	29.6897	27696.6	31193.5	0.918259	0.928487	0	1	0	0	1	0
0.0303091	42.6051	20241	32637.1	0.811833	0.823736	0	0	1	0	0	0

missil_est_red_b	missil_est_red_c	missil_red_a	missil_red_b	missil_red_c	missil_est_blue_a	missil_est_blue_b	missil_est_blue_c	shotphi_blue_s	shotphi_blue_m	shotphi_blue_l	shotphi_est_red_s
0	1	0	1	0	0	0	1	0	0	1	0
1	0	0	1	0	0	1	0	0	0	1	0
0	1	0	0	1	0	1	0	0	0	1	1
1	0	0	0	1	1	0	0	1	0	0	0
0	1	0	1	0	0	0	1	1	0	0	0
1	0	0	1	0	0	1	0	0	0	1	0

shotphi_est_red_m	shotphi_est_red_l	shotphi_red_s	shotphi_red_m	shotphi_red_l	shotphi_est_blue_s	shotphi_est_blue_m	shotphi_est_blue_l	threshold_before_blue	threshold_after_blue	threshold_before_rec	hreshold_after_re
0	1	0	1	0	0	1	0	0.849584	0.343499	0.723962	0.121272
1	0	1	0	0	0	0	1	0.857628	0.196357	0.105947	0.992903
0	0	0	0	1	0	1	0	0.326241	0.375115	0.158358	0.63402
1	0	0	1	0	0	0	1	0.772713	0.407687	0.512314	0.170849
0	1	0	0	1	1	0	0	0.911643	0.785672	0.889041	0.481416
1	0	1	0	0	0	0	1	0.682309	0.457746	0.644287	0.860213

FIGURA 3.16 – Conjunto de dados de entrada das simulações BVR.

dist_BM_RA	dist_RM_BA
1.57117	66395.3
8699.48	68902.7
24178.3	4582.17
61451	4.37524
5205.43	6.44159
3525.9	31274.1
37809.2	5123.09
5374.82	69701.2
1920.78	43121.4
10457.3	13381.7
10709.3	3097.04

FIGURA 3.17 – Conjunto de dados de saídas das simulações BVR.

Como o principal objetivo desta pesquisa é a concepção de um sistema embarcado de apoio à decisão que tenha a capacidade de prever o resultado final das simulações de combate aéreo além do alcance visual e, desta forma, melhorar a consciência situacional do piloto, é necessária esta separação do conjunto de dados em variáveis de entrada e saída para realizar os treinamentos dos modelos de aprendizado de máquina. As variáveis de entrada, conforme já citadas, fornecem informações sobre cada recurso que está influenciando o combate aéreo simulado. As variáveis-alvo ou variáveis de saída serão aquelas que irão receber os valores de interesse obtidos após a realização das simulações. Os dados

foram agrupados conforme a sua natureza na sua coluna correspondente e os dados são disponibilizada através de arquivos *Comma-Separated Values* (CSV).

A organização dos dados se iniciou a partir do armazenamento dos arquivos em um banco de dados interno. Nesse momento, havia mais variáveis do que as 38 listadas anteriormente. Inicialmente, foram conduzidos processos de limpeza e extração de novas informações. A limpeza foi utilizada para remover variáveis que não foram utilizados na análise. A partir desse ponto, os dados já estavam disponíveis para serem acessados para aplicações nas análises desejadas.

Nas próximas subseções será descrita a metodologia para a concepção de um modelo de redes neurais artificiais para a criação do sistema de apoio à decisão proposto com base nos dados coletados do simulador de combate BVR que foi apresentado na Seção 3.1. Um modelo de inteligência artificial bem treinado sobre esses dados é visto como um bom ajuste que poderia então ser usado para fazer previsões dos resultados obtidos nos cenários operacionais propostos, já que conseguiria fornecer respostas muitos mais rápidas e eficientes do que o próprio simulador BVR. Este modelo se provaria inestimável para a Força Aérea Brasileira, pois esta poderia fazer análises em tempo real das situações de combate aéreo além do alcance visual, fornecendo dados importantíssimos aos pilotos, elevando a sua consciência situacional na operação.

O conjunto de dados de entrada para este projeto foram feitos para 100, 1.000 e 10.000 entradas geradas pela LHS. Para os propósitos deste projeto, as etapas de pré-processamento no conjunto de dados se fazem necessárias e serão descritas a seguir.

3.3.2 Ajuste das variáveis de entrada

Antes da implementação dos algoritmos de aprendizagem é necessária a divisão dos dados em subconjuntos de treinamento, validação e teste. Normalmente, os dados também são misturados em uma ordem aleatória ao criar os subconjuntos para remover qualquer tendência na ordenação do conjunto de dados. O conjunto de treinamento é usado para realizar o treinamento dos modelos; e o conjunto de validação é usado para estimar o erro de previsão para a seleção do modelo; o conjunto de teste é usado para avaliação do erro de generalização do modelo final escolhido. Idealmente, o conjunto de testes deve ser mantido separado e ser exibido apenas no final da análise de dados.

Utilizou-se o pacote *train_test_split* da *sklearn.cross_validation* implementado na linguagem de programação *Python* para misturar e dividir as variáveis analisadas em conjuntos de treinamento, validação e teste. Em geral, a divisão dos dados ocorre em 70% de treinamento, 15% de validação e 15% de testes. A utilização de *random_state* e *train_test_split* para a variável analisada garante que os resultados sejam consistentes.

O benefício de separar o conjunto de dados em alguma relação de subconjuntos de treinamento, validação e teste para um algoritmo de aprendizagem é que utilizar esta metodologia valida se o modelo proposto generaliza bem os dados. Caso não seja possível testar esse modelo, pode-se ter um modelo que tem uma performance muito boa no treinamento, porém não tem um bom desempenho com dados reais que acontece no caso do *overfitting* já definido em outra subseção.

Além da separação do conjunto de dados conforme mencionado, é possível executar a chamada validação cruzada. É muito semelhante à divisão de treinamento, validação e teste, mas é aplicada a mais subconjuntos. Ou seja, os dados são divididos em k subconjuntos e é realizado treinamento em $k-1$ desses subconjuntos. Portanto, o último subconjunto é separado para teste e isso é feito para cada um dos subconjuntos. Existem alguns métodos de validação cruzada utilizados para preparação dos dados. No presente trabalho foi utilizado a validação cruzada *k-fold*, que será melhor detalhada em uma subseção adiante.

3.3.3 Normalização

A partir da descrição do conjunto de dados, podemos afirmar que, referentes as variáveis de entrada, existem 10 atributos de valores numéricos e 26 atributos de valor categórico do tipo binário. Referente as variáveis de saída, as duas variáveis possuem valores numéricos.

Observando minuciosamente os dados, verifica-se que cada coluna de dados possui seu próprio intervalo de dados. Essa situação atrapalha o treinamento da rede neural artificial, porque os valores de entrada fazem contribuições diferentes para o cálculo dos valores de saída. Valores maiores serão mais importantes para a rede, o que pode ser percebido como uma suposição inválida com base nos dados. Para corrigir este problema, deve-se normalizar todas as colunas para obter intervalos semelhantes.

Para realizar a normalização para cada variável, subtrai-se a sua média e divide-se pelo seu desvio padrão. Na linguagem *Python* existem códigos específicos no *Python*, como *preprocessing.MinMaxScaler* da *scikit-learn*, que fazem essa normalização dos dados de modo que é possível realizar todas as operações computacionais das redes neurais de maneira satisfatória. Estas bibliotecas de código específicas foram utilizadas no presente estudo.

3.3.4 Métricas de desempenho

É difícil medir a qualidade de um determinado modelo sem quantificar seu desempenho em relação a treinamento e testes. Isso geralmente é feito usando algum tipo de métrica de desempenho, seja através do cálculo de algum tipo de erro, da adequação do ajuste ou de alguma outra medida útil. Nesta subseção serão abordadas as métricas de desempenho

utilizadas para avaliar as redes neurais artificiais de classificação e regressão. Para o primeiro tipo, RNA's de classificação, serão utilizadas a acurácia do modelo e será feita uma análise por matriz de confusão dos resultados obtidos nas predições propostas. Para o segundo, RNA's de regressão, serão utilizados o coeficiente de determinação (R^2) e a raiz quadrada do erro médio quadrático ou *Root Mean Squared Error* (RMSE) para quantificar o desempenho do modelo. A Figura 3.18 demonstra as métricas de desempenho utilizadas nos modelos de redes neurais artificiais de classificação e regressão do presente estudo.

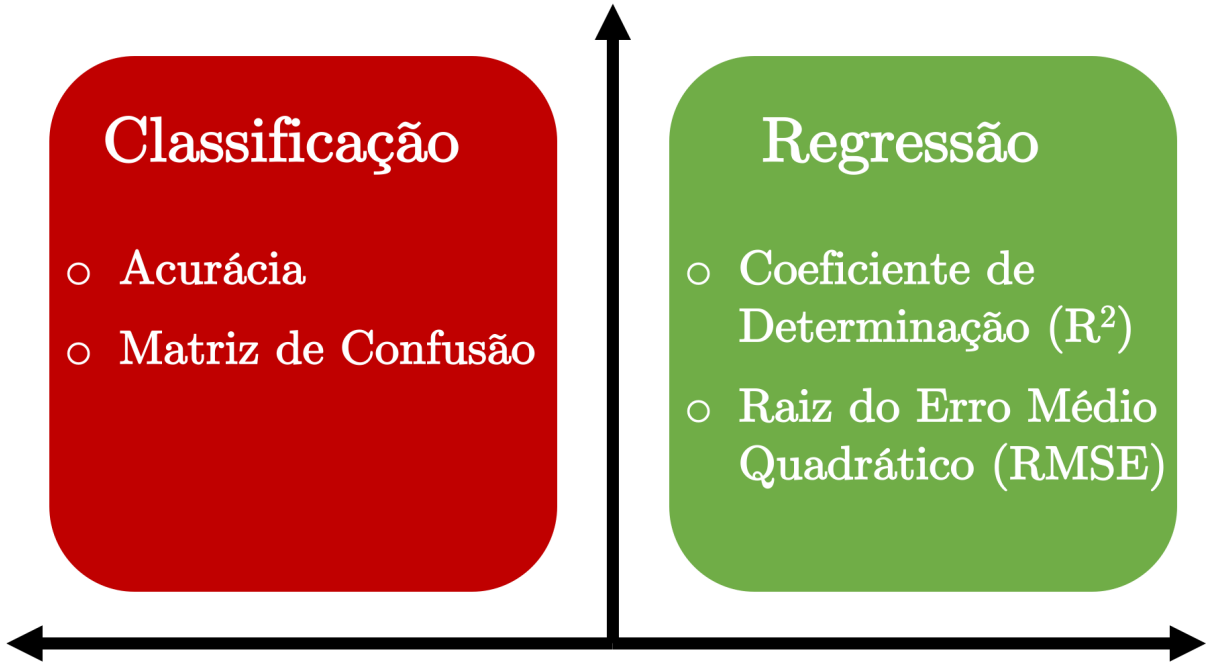


FIGURA 3.18 – Métricas de desempenho para aprendizagem de máquina por classificação e regressão.

3.3.4.1 Acurácia

A acurácia é a métrica de desempenho primária em modelos de classificação. Define-se como o número de previsões corretas feitas em relação ao número de previsões feitas. Esta é a métrica de avaliação mais comum para problemas de classificação, e, por vezes, é mal utilizada. É realmente mais adequada apenas quando há um número igual de observações em cada classe (o que raramente é o caso) e que todas as previsões e erros de previsão são igualmente importantes, o que geralmente não é o caso. Somente a acurácia não determina um bom ou mal desempenho de determinado modelo de classificação. É necessário utilizar outras métricas para tomar decisões mais assertivas sobre a escolha do modelo ideal.

Dado estes fatos, na presente dissertação, além da acurácia, será utilizada a matriz de confusão para fazer as devidas análises de performance dos modelos preditivos propostos.

3.3.4.2 Matriz de confusão

Matriz de Confusão ou *Confusion Matrix*, como o próprio nome sugere, fornece uma matriz como saída e descreve o desempenho completo do modelo. As variáveis utilizadas, extraídas do campo da inteligência artificial, levam a utilização dessa ferramenta para ajudar na visualização dos resultados. Em problemas de classificação binária, por exemplo, algumas amostras irão ser pertencentes a duas classes: Sucesso (1) ou Fracasso (0). A Figura 3.19 demonstra a matriz de confusão para sistemas preditivos.

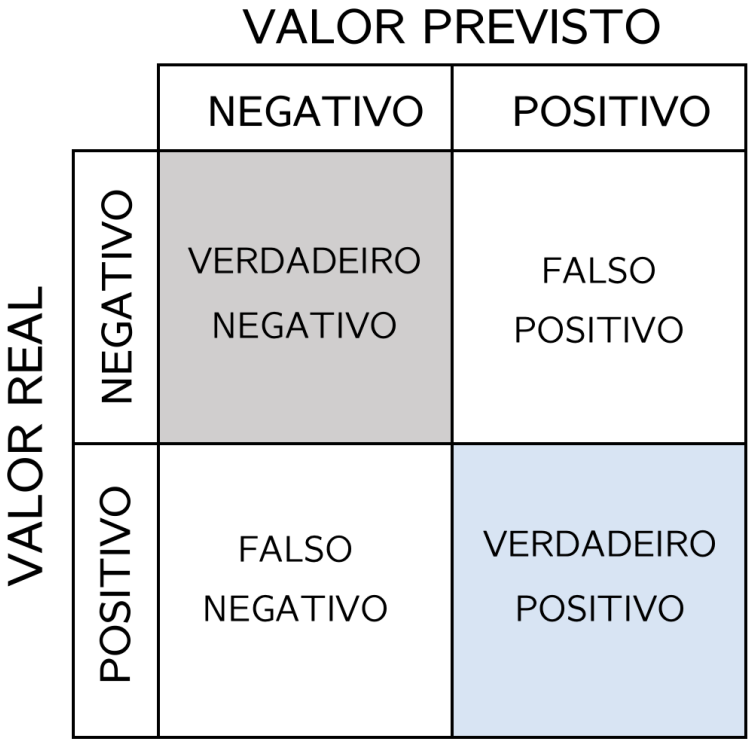


FIGURA 3.19 – Matriz de confusão para sistemas preditivos.

Quando se trata de matriz de confusão, existem 4 termos importantes que devem ser esclarecidos:

- Verdadeiros Positivos (VP): Os casos em foram previstos Sucesso (saída 1) e a saída real também foram Sucesso (saída 1).
- Verdadeiros Negativos (VN): Os casos em foram previstos Fracasso (saída 0) e a saída real também foram Fracasso (saída 0).
- Falsos Positivos (FP): Os casos em foram previstos Sucesso (saída 1) e a saída real foram Fracasso (saída 0).
- Falsos Negativos (FN): Os casos em foram previstos Fracasso (saída 0) e a saída real foram Sucesso (saída 1).

O cenário ideal esperado é que o modelo forneça 0 falsos positivos e 0 falsos negativos. Mas esse não é o caso na vida real, pois qualquer modelo NÃO será 100% preciso na maioria das vezes.

Duas inferências importantes podem ser constatadas da matriz de confusão. Primeiramente, o *recall* pode ser definido como a proporção do número total de exemplos positivos classificados corretamente dividido para o número total de exemplos positivos. Altos valores de *recall* indica que a classe é reconhecida corretamente (pequeno número de Falsos Negativos). Quanto maior o *recall*, melhor o desempenho do modelo preditivo e indica o quanto foi medido corretamente. A equação 3.1 demonstra como calcular o *recall*.

$$Recall = \frac{VP}{VP + FN} \tag{3.1}$$

Para a *precision*, divide-se o número total de exemplos positivos classificados corretamente pelo número total de exemplos positivos previstos. Altos valores de *precision* indica que um exemplo marcado como positivo é de fato positivo (pequeno número de FP). A equação 3.2 demonstra como calcular a acurácia.

$$Precision = \frac{VP}{VP + FP} \tag{3.2}$$

Portanto, analisando essas duas métricas, conclui-se que:

- Altos valores de *recall* e baixos valores de *precision*: Isso significa que a maioria dos exemplos positivos são reconhecidos corretamente (baixo FN), mas há muitos falsos positivos.
- Baixos valores de *recall* e altos valores de *precision*: Isso mostra que se perdeu muitos exemplos positivos (alto FN), mas aqueles que foram previstos como positivos são de fato positivos (baixo FP).

As matrizes de confusão serão utilizadas, no Capítulo 4, nas análises das redes neurais artificiais de classificação para melhor visualização da capacidade preditiva do modelo adotado.

3.3.4.3 Coeficiente de determinação

O uso de R^2, o coeficiente de determinação, também chamado de coeficiente de correlação múltipla, está bem estabelecido na análise de regressão clássica (RAO, 1973). O coeficiente de determinação de um modelo é uma estatística útil na análise de regressão, pois geralmente descreve como esse modelo é adaptável com a realidade para fazer previsões.

Os valores para R^2 variam de 0 a 1, que retrata a porcentagem de correlação quadrada entre os valores previstos e reais da variável de destino. É interpretado como a proporção da variância na variável dependente que é previsível da variável independente. Um modelo com um R^2 próximo de 0 irá, provavelmente, falhar em predizer a variável de destino, enquanto um modelo com um R^2 próximo de 1 irá, em grande partes dos casos, predizer de forma bastante satisfatória a variável de destino. Qualquer valor entre 0 e 1 indica qual porcentagem da variável de destino, usando esse modelo, pode ser explicada pelos recursos.

R^2 não é uma boa medida para avaliar a adequação de uma rede neural de classificação, mas é adequado para prever variáveis contínuas. Quando a variável dependente é contínua, o coeficiente de determinação é interpretado como parcela de variação da variável dependente que o modelo é capaz de reproduzir corretamente.

Quando a variável dependente é categórica, não faz sentido a sua utilização, porque R^2 usa distâncias entre valores previstos e reais. Portanto, distâncias entre 1 significando classe A, 2 significando classe B e 3 significando classe C não faz sentido para avaliação do modelo de classificação.

3.3.4.4 Raiz quadrada do erro médio quadrático

A raiz quadrada do erro quadrático médio (RMSE) é uma medida frequentemente usada das diferenças entre os valores preditos por um modelo ou um estimador, que mede a magnitude média do erro. É a raiz quadrada da média das diferenças quadradas entre previsão e observação real. A Equação 3.3 demonstra como calcular o RMSE.

$$RMSE = \sqrt{\frac{1}{n}\sum_{j=1}^{n}\left(y_i - \hat{y}_j\right)^2} \tag{3.3}$$

Ele é uma medida de precisão, para comparar erros de previsão de modelos diferentes para um conjunto de dados específico e não entre conjuntos de dados, pois é dependente da escala (HYNDMAN; KOEHLER, 2006). Tirar a raiz quadrada dos erros quadrados médios tem algumas implicações interessantes para o RMSE. Como os erros são elevados ao quadrado, o RMSE atribui um peso relativamente alto a erros grandes. Isso significa que o RMSE deve ser mais útil quando erros grandes são particularmente indesejáveis. Ele é sempre não negativo e um valor de 0 (quase nunca alcançado na prática) indicaria um ajuste perfeito aos dados. Em geral, um menor RMSE é melhor que um maior. No entanto, as comparações entre diferentes tipos de dados seriam inválidas porque a medida depende da escala dos números usados (WILLMOTT; MATSUURA, 2006).

Portanto, na análise dos modelos de previsão realizados na presente dissertação serão utilizados o coeficiente de determinação e a raiz quadrada do erro médio quadrático para

avaliar as melhores arquiteturas de redes neurais artificiais propostas para modelagem do combate aéreo além do alcance visual.

3.3.5 Análise inicial utilizando regressão logística

A regressão logística foi desenvolvida pelo estatístico David Cox em 1958 (COX *et al.*, 1958). O modelo de regressão logística é semelhante ao modelo de regressão linear. No entanto, no modelo logístico a variável dependente é de natureza dicotômica ou binária e as variáveis independentes tanto podem ser categóricas ou não. A partir de um conjunto de observações, a regressão logística é um modelo que permite a predição de valores escolhidos. Os resultados da análise ficam contidos no intervalo $[0, 1]$ e buscam estimar a probabilidade de a variável dependente assumir um determinado valor em função dos valores conhecidos de outras variáveis. Portanto, trata-se de um modelo de aprendizado de máquina supervisionado.

As vantagens de utilizar a regressão logística é a facilidade para lidar com variáveis independentes categóricas, classificar os indivíduos em categorias, fornece resultados em termos de probabilidade e requer pequeno número de suposições.

Comparando a regressão linear e logística, temos que além de na logística a variável dependente ser categórica, ela também utiliza o método da máxima verossimilhança, diferente da regressão linear que utiliza o método dos mínimos quadrados.

O modelo em si simplesmente modela a probabilidade de saída em termos de entrada, e não realiza classificação estatística, portanto, não é um classificador. Contudo, ele pode ser usado para fazer classificação, por exemplo, escolhendo um valor de corte e classificando entradas com probabilidade maior do que o corte como pertencente a uma classe e abaixo do ponto de corte como pertencente a outra. Essa é uma maneira comum de criar um classificador binário. Portanto, enquanto método de predição para variáveis categóricas, a regressão logística é comparável às técnicas supervisionadas propostas em aprendizagem, como por exemplo as redes neurais artificiais, onde é possível uma comparação da escolha do modelo mais adaptado para um certo problema preditivo a resolver.

Na presente dissertação será modelado uma regressão logística baseada nos dados coletados do simulador de combate aéreo além do alcance visual. Esse estudo inicial foi feito para demonstrar a importância da utilização das redes neurais artificiais na modelagem de sistemas complexos como é o caso do combate BVR. Vale ressaltar que a regressão logística se trata de uma rede neural artificial com um único neurônio e função de ativação sigmoide (esses conceitos serão melhor detalhados na próximas subseções). As amostragens de simulações geradas (100, 1.000 e 10.000) serão utilizadas com o modelo de regressão logística para verificar a importância do número de amostras utilizadas para os

modelos de aprendizado de máquina. Além disso, acurácia da regressão logística proposta será comparada com os valores encontrados nas diversas redes neurais artificiais propostas para modelar o problema.

3.3.6 Validação cruzada

Analogamente como existe uma metodologia por trás de utilizar um conjunto de teste, um conjunto de validação cruzada se faz necessário para que nada de errado ocorra no processo de modelagem e análise das redes neurais artificiais.

O objetivo da validação cruzada é testar a capacidade do modelo de prever novos dados que não foram usados na estimativa, a fim de sinalizar problemas como *overfitting* (CAWLEY; TALBOT, 2010). Ela fornece informações de como o modelo será generalizado para um conjunto de dados independente que podem ser os dados reais do problema. É usado principalmente em cenários em que o objetivo é a previsão e se deseja estimar a acurácia com que um modelo preditivo funcionará na prática.

Ao se fazer o treinamento de modelos de RNA, deve-se evitar utilizar o conjunto de teste para treinar o modelo. O comportamento ideal a ser adotado é a existência de um conjunto de validação para tomada de decisão em relação ao modelo, com o valor dos parâmetros, por exemplo. Dessa forma, conforme mencionado na Subseção 3.3.2, os dados ficarão divididos em três conjuntos principais: Treinamento, Validação e Teste. Dessa forma, as redes neurais de regressão no problema proposto nesta dissertação utilizaram esses três subconjuntos de dados para os treinamentos, testes e validação observando os critérios de parada inerentes a cada RNA modelada.

Em um primeiro momento, pode-se utilizar a ideia de se treinar e testar o modelo com os mesmos dados. Porém, maximizar a precisão do treinamento recompensa modelos excessivamente complexos que superam os dados de treinamento. À medida que mais recursos são adicionados, é possível alcançar lentamente uma acurácia de 100%, mas não é capaz de generalizar bem. Alternativamente, pode-se dividir o conjunto de dados em duas partes para que o modelo possa ser treinado e testado em dados diferentes. Então, a precisão do teste é uma estimativa melhor do que a precisão do treinamento do desempenho fora da amostra.

Contudo, existem problemas na divisão treinamento e teste. Ela fornece uma alta variação, pois a alteração de quais observações estão no conjunto de testes pode alterar significativamente a acurácia do teste. A acurácia dos testes pode mudar muito dependendo de qual observação estiver no conjunto de testes. Por isso, temos que usar a validação cruzada de *k-fold* para resolver este problema.

Quando for feita a utilização das redes neurais artificiais de classificação e da própria regressão logística, será utilizado a técnica de treinamento de validação-cruzada *k-fold* que irá proporcionar inúmeros benefícios para otimizar o modelo. Esse método de validação-cruzada é um método de reciclagem dos dados do problema que se trata de uma generalização do método da validação cruzada. O conjunto de dados de tamanho n (n exemplos) é dividido em m conjuntos disjuntos de tamanho $\frac{n}{m}$. O algoritmo é treinado m vezes, cada vez com um conjunto diferente sendo deixado de fora para fazer a validação. O desempenho é estimado como sendo o erro médio ou taxa de acerto média sobre estes m conjuntos de validação. O objetivo é estimar o quão preciso o modelo será quando novos dados entrarem. Essa técnica se mostra bastante eficiente, pois ao dividir os dados em conjunto de treinamento e conjunto de testes apenas uma vez o tamanho dos conjuntos fica limitado e ao usar um único conjunto de validação pode ocorrer *overfiting*. A Figura 3.20 demonstra a metodologia da validação *k-fold*.

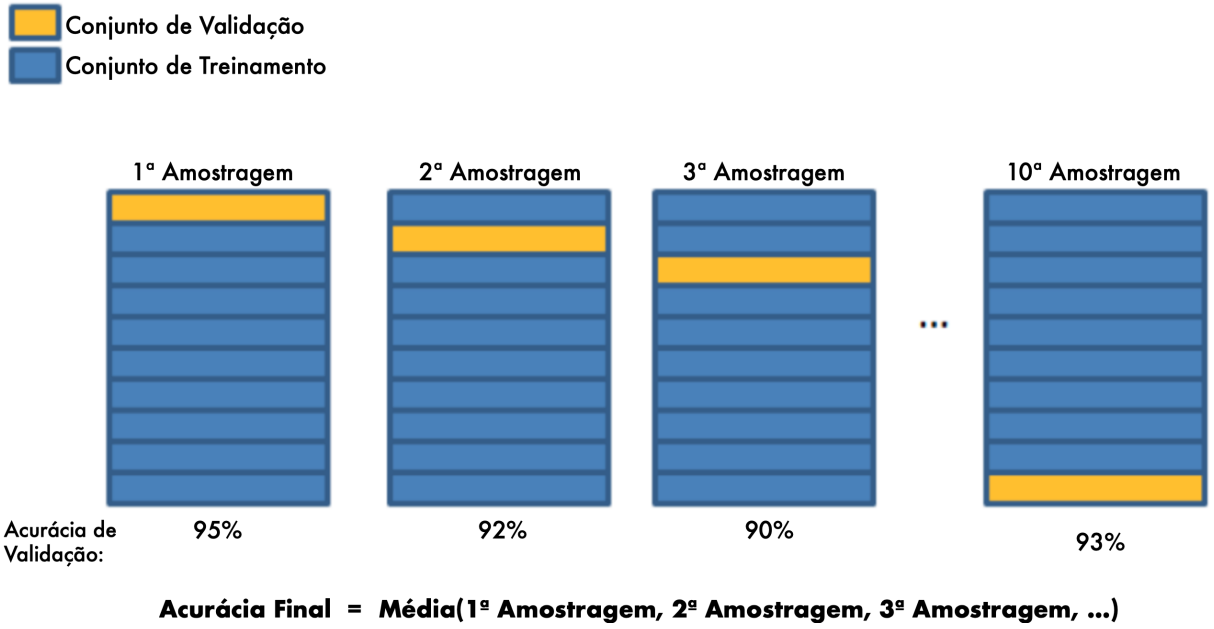


FIGURA 3.20 – Validação cruzada *k-fold*.

Assim o grande benefício de usar a validação-cruzada *k-fold* é que todas as observações são usadas para treinamento e validação, e cada observação é usada para validação uma única vez. Isso dá a segurança de usar todo o conjunto de dados para treinamento e validação sem correr o risco de superestimar o desempenho do conjunto de validação único que foi selecionado na otimização do modelo (CAWLEY; TALBOT, 2010).

Para diminuir a variação do resultado do *cross validation* (CV), deve ser repetido o processo com novas divisões aleatórias. Em geral, um valor de k grande significa menos viés e mais variância. Um valor de k demasiadamente grande significa que apenas um baixo número de combinações de amostra é possível, limitando assim o número de iterações que são diferentes.

Utilizar um k maior é capaz de reduzir consideravelmente o erro de previsão no conjunto de treinamento, mas ao mesmo tempo não é tão generalizável a ponto de apresentar um bom resultado no conjunto de teste. Portanto, nesse caso se tem menos viés em superestimar o verdadeiro erro esperado pois o conjunto de treinamento estará bem próximo do conjunto de dados total. Contudo, isso demonstra uma maior variância e maior tempo de execução. Ou seja, no conjunto de dados de treinamento, o modelo irá ter um erro de previsão baixo, mas quando o modelo for avaliado em um novo conjunto de dados, o erro sobe consideravelmente, e por isso dizemos que sua variância é alta. Este é o típico caso de *overfitting*.

Por outro lado, utilizar um baixo valor de k torna o modelo bem generalizável, mas não reduz consideravelmente o erro de previsão no conjunto de treinamento. Nesse caso, obtêm-se um modelo com viés mais alto, mas variância baixa. Dessa forma, permite-se um erro de previsão maior no conjunto de treinamento de modo a obter um erro de previsão semelhante (com pouca variância) no conjunto de teste. Nesse caso, acontece o *underfitting*.

Esse tipo de análise só se faz relevante com pequenos tamanhos de amostra. Com mais amostras disponíveis, k não tem um peso tão significativo. Com mais amostras de treinamento, geralmente, a diferença entre os modelos substitutos e o modelo real treinado em todas as n amostras torna-se insignificante.

Para as análises feitas na presente dissertação foram adotadas $k = 5$ para as divisões a serem feitas na validação cruzada. O valor escolhido se justifica devido ao fato de não aumentar, significativamente, o tempo computacional dos treinamentos , devido ao grande número de divisões, e por ter apresentado valores que foram condizentes com os esperados para as análises das redes neurais artificiais.

3.3.7 Funções de ativação propostas

Intuitivamente, as funções de ativação introduzem um componente não linear nas redes neurais, que faz com que elas possam aprender mais do que relações lineares entre as variáveis dependentes e independentes. As funções de ativação são essenciais para dar capacidade representativa às redes neurais artificiais. Por outro lado, com esse poder a mais surgem algumas dificuldades. Particularmente, ao introduzir uma ativação não linear, a superfície de custo da rede neural deixa de ser convexa, tornando a otimização mais complicada. Além disso, algumas não-linearidades tornam o problema de gradientes explodindo ou desvanecendo mais evidente (GOODFELLOW *et al.*, 2016). No problema proposto, serão utilizadas as três funções de ativação que foram discutidas no Capítulo 2: Sigmoide, Tangente hiperbólica e Unidade linear retificada.

3.3.8 Número de camadas ocultas

O teorema da aproximação universal afirma que uma rede de *feedforward*, com uma única camada oculta, contendo um número finito de neurônios, pode aproximar funções contínuas com pressupostos suaves sobre a função de ativação. Cybenko (1989) demonstrou o teorema para funções de ativação sigmoide. Hornik (1991) demonstrou a própria arquitetura de *feedforward* multicamadas que dá às redes neurais o potencial de serem aproximadores universais e que não existe relação com as funções de ativação utilizadas. Portanto, redes neurais artificiais simples podem representar uma ampla variedade de funções por essa abordagem clássica.

Devido a este teorema, uma literatura considerável sugere o uso de uma única camada oculta. Tradicionalmente, as redes neurais têm apenas três tipos de camadas: oculta, entrada e saída. Estes são todos o mesmo tipo de camada se você considerar que as camadas de entrada são alimentadas a partir de dados externos (não uma camada anterior) e os dados de alimentação de saída para um destino externo (não a próxima camada). Estas três camadas agora são comumente chamadas de camadas densas. Isso ocorre porque todos os neurônios nestas camadas estão totalmente conectados à próxima camada.

Problemas com duas ou menos camadas geralmente serão suficientes com conjuntos de dados simples. No entanto, com conjuntos de dados complexos envolvendo séries temporais ou visão computacional, camadas adicionais podem ser úteis. A Tabela 3.3 resume os recursos de várias arquiteturas de camadas comuns.

TABELA 3.3 – Determinando o número de camadas ocultas em redes neurais artificiais.

Número de Camadas Ocultas	**Resultado**
0	Representa funções ou decisões separáveis lineares
1	Aproxima qualquer função com mapeamento contínuo de um espaço finito
2	Aproxima qualquer função que contenha mapeamento suave a qualquer precisão
>2	Camadas adicionais podem aprender representações complexas

Problemas que exigem mais do que duas camadas ocultas eram raros antes do surgimento do aprendizado em redes profundas (*deep learning*). O aprendizado profundo mudou um pouco as recomendações mais clássicas de ter no máximo duas camadas e como escolher o número de camadas ocultas. Enquanto o teorema da aproximação universal afirma que uma rede neural de camada única pode aprender qualquer coisa, ela não especifica quão fácil será para que a rede neural realmente aprenda algo. Desde o perceptron multicamada, obteve-se a capacidade de criar redes neurais profundas. A partir da pesquisa de Hinton *et al.* (2006), o conceito de redes neurais profundas ou *Deep Neural Networks* (DNN) foi introduzido e a abordagem clássica foi sendo substituída por esse novo conceito. As redes neurais modernas têm muitos tipos de camadas adicionais para serem analisadas. Além das camadas densas clássicas, agora também se tem camadas de evasão, convoluções,

agrupamento e recorrentes. Camadas densas são frequentemente misturadas com esses outros tipos de camada.

Em resumo, para a maioria dos problemas, uma camada escondida é suficiente para representar a maioria dos problemas. Entretanto, se os dados contêm descontinuidades, uma camada escondida adicional pode ajudar. É importante notar que redes neurais com duas camadas intermediárias podem aproximar funções de quaisquer tipos ou formas, então não há uma razão plausível para usar mais de duas, de acordo com a abordagem clássica. No presente trabalho não serão abordadas as redes neurais profundas e será utilizado somente duas camadas ocultas para todas as análises feitas nesta dissertação. Porém, vislumbra-se em trabalhos futuros a abordagem do estudo realizado na presente dissertação por meio do uso da aprendizagem profunda.

3.3.9 Número de neurônios

Ao considerar a estrutura das camadas densas, existem dois aspectos importantes que devem ser analisados: quantas camadas ocultas realmente devem existem na rede neural e quantos neurônios estarão em cada uma dessas camadas. Na subseção anterior foi abordada a metodologia de escolha do número de camadas ocultas. Decidir o número de camadas de neurônios ocultos é apenas uma pequena parte do problema. Na presente subseção será analisado a escolha do número de neurônios.

Na verdade, não há nenhum embasamento matemático que forneça uma resposta definitiva para estas questões. Obtêm-se essas respostas na base de tentativa e erro. Caso sejam utilizados poucos neurônios na camada escondida, a rede neural é incapaz de modelar dados mais complexos, resultando em uma baixa capacidade de generalização, fenômeno conhecido como *underfitting*. Se muitos neurônios forem utilizados, o treinamento da rede irá se tornar excessivamente longo e a rede pode sofrer problemas de sobreajuste, conhecido como *overfitting*. Esse último resulta na perda da capacidade preditiva da rede, pois observam-se pequenos desvios de previsão para os dados usados na fase de treino, mas grandes desvios quando novos dados de entrada são utilizados. Dados com ruídos ou redundantes podem provocar a falha da rede na convergência de uma solução genérica. Esse fenômeno ocorre em geral quando a rede neural tem tanta capacidade de processamento de informação que a quantidade limitada de informação contida no conjunto de treinamento não é suficiente para treinar todos os neurônios nas camadas ocultas.

Um segundo problema pode ocorrer mesmo quando os dados de treinamento são suficientes. Um número excessivamente grande de neurônios nas camadas ocultas pode aumentar o tempo necessário para treinar a rede. A quantidade de tempo de treinamento pode aumentar a ponto de ser impossível treinar adequadamente a rede neural. Obviamente,

algum ponto ótimo de escolha deve ser alcançado entre muitos e poucos neurônios nas camadas ocultas.

Há muitos métodos de regra geral para determinar um número aceitável de neurônios a serem usados nas camadas ocultas. Nesta dissertação será adotada uma metodologia de escolha baseada em tentativa e erro, porém com algumas premissas iniciais que facilitarão a otimização da rede neural desejada. Tais premissas são baseadas na experiência e na prática na realização de treinamentos em redes neurais artificiais.

Primeiramente, sugere-se que o número de neurônios ocultos, preferencialmente, deve estar entre o tamanho da camada de entrada e o tamanho da camada de saída. Isso faz sentido quando se pensa no treinamento realizado pela rede. No problema do combate além do alcance visual há 36 entradas e 2 saídas, o que faria com que o número de neurônios da camada interna fique, preferencialmente, entre esses valores. Outra premissa importante baseada no conhecimento empírico de cientistas de dados em testes realizadas com outras redes neurais artificiais é que o número de neurônios ocultos deve ser próximo de valores entre a 1/2 (média aritmética) e 2/3 do tamanho da camada de entrada mais o tamanho da camada de saída. Essas duas regras fornecem uma análise inicial para a escolha do número de neurônios que serão adotados na camada oculta.

O processo utilizado por alguns estudiosos na área, é determinar o número de neurônios escondidos baseado na premissa de que redes neurais com muitos neurônios nas camadas intermediárias, em geral, irão convergir de maneira mais efetiva, contudo, terão um custo computacional maior e será mais demorado para atingir o convergência. Logo, o objetivo é tentar encontrar a menor rede neural possível que convirja e refinar a rede a partir desta encontrada.

3.3.10 Algoritmo de otimização

Para construção das RNA's desta dissertação serão utilizados 3 algoritmos de otimização: *Limited-memory BFGS* (L-BFGS), *Stochastic Gradient Descent* (SGD) e ADAM. Na biblioteca do *scikit-learn* eles são definidos no campo *solver*.

Limited-memory BFGS é um algoritmo de otimização da família de métodos *Quasi-Newton* que aproxima o algoritmo de Broyden-Fletcher-Goldfarb-Shanno (BFGS) usando uma quantidade limitada de memória de computador. É um algoritmo popular para estimativa de parâmetros em aprendizado de máquina (MALOUF, 2002). Basicamente, L-BFGS é uma maneira de encontrar um mínimo local de uma função objetivo, utilizando os valores da função objetivo e o gradiente da função. Esse nível de descrição abrange muitos métodos de otimização além do L-BFGS (NOCEDAL; WRIGHT, 2006). Métodos de *Quasi-Newton*, que aproximam a hessiana com base em diferenças de gradientes ao longo

de várias iterações. Existem muitos métodos de Quasi-Newton diferentes, que estimam a hessiana de maneiras diferentes. Um dos mais populares é o BFGS. A aproximação Hessiana BFGS pode ser baseada na série completa de gradientes, caso em que é referida como BFGS, ou pode se basear apenas nos gradientes mais recentes, caso em que é conhecida como memória limitada BFGS, abreviada como L-BFGS. O L-BFGS é usado em vez do BFGS para problemas muito grandes, mas pode não funcionar tão bem quanto o BFGS. Portanto, o BFGS é preferido em relação ao L-BFGS (que pode não ser muito pior no desempenho em alguns casos) quando os requisitos de memória do BFGS podem ser atendidos.

Stochastic Gradient Descent (SGD), também conhecida como gradiente descendente estocástico, é um método iterativo para otimizar uma função objetivo diferenciável por uma aproximação estocástica da otimização de gradiente descendente. É chamado de estocástico porque as amostras são selecionadas aleatoriamente em vez de um único grupo, como na descida gradiente padrão, ou na ordem em que aparecem no conjunto de treinamento. Mei *et al.* (2018) em artigo recente credita a autoria do SGD a Robbins e Monro (1951). SGD possui uma abordagem simples, mas muito eficiente, para a aprendizagem discriminativa de classificadores lineares sob funções de perda convexa, como por exemplo a regressão logística. Embora o SGD esteja presente há muito tempo na comunidade de aprendizado de máquina, ele recebeu considerável atenção recentemente, no contexto do aprendizado em grande escala. O SGD tem sido aplicado com sucesso em problemas de aprendizado de máquina grandes e complexos, frequentemente encontrados na classificação de texto e no processamento de linguagem natural. As vantagens da descida de gradiente estocástica são a sua eficiência e sua facilidade de implementação, pois possui muitas oportunidades para ajuste de código. A desvantagem da Descida de Gradiente Estocástica é o fato do SGD requerer um número de hiper-parâmetros, como o parâmetro de regularização e o número de iterações. A descida de gradiente estocástica mantém uma única taxa de aprendizado (denominada alfa) para todas as atualizações de peso e a taxa de aprendizado não muda durante o treinamento. Uma taxa de aprendizado é mantida para cada peso de rede (parâmetro) e adaptada separadamente à medida que o aprendizado se desdobra.

Adaptive Moment Estimation (ADAM) é um algoritmo de otimização que pode ser usado em vez do procedimento clássico de descida de gradiente estocástico para atualizar os pesos da rede de forma iterativa com base nos dados de treinamento. Kingma e Ba (2014) apresenta ADAM como um algoritmo para otimização baseada em gradiente de primeira ordem de funções objetivos estocásticas, com base em estimativas adaptativas de momentos de menor ordem. O método é simples de implementar, é computacionalmente eficiente, tem poucos requisitos de memória, é invariante para o reescalonamento diagonal dos gradientes e é bem adequado para problemas que são grandes em termos de dados ou parâmetros. O método também é apropriado para objetivos não estacionários e problemas com gradientes

muito ruidosos ou esparsos. Os hiper-parâmetros possuem interpretações intuitivas e normalmente requerem pouco ajuste. Adam é diferente da descida de gradiente estocástica clássica. O algoritmo de otimização Adam é uma extensão do gradiente estocástico de descida que recentemente vem sendo utilizado em aplicativos de aprendizagem profunda em visão computacional e processamento de linguagem natural.

A escolha do algoritmo de otimização para seu modelo de aprendizagem profunda pode significar a diferença entre bons resultados em minutos, horas e dias. Para a análise das simulações de combate aéreo além do alcance visual irão ser analisadas esses 3 tipos de algoritmos de otimização e, baseado nas métricas de desempenho, será escolhida a configuração de rede que melhor retratar o problema proposto.

3.3.11 Taxa de aprendizagem

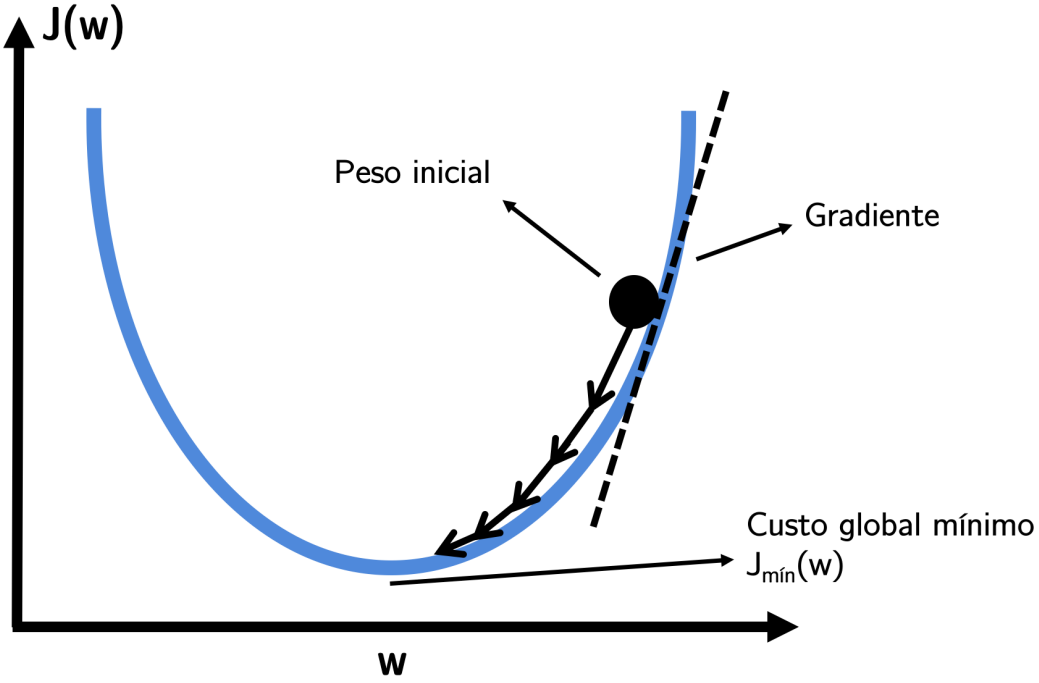
A taxa de aprendizado é um hiper-parâmetro que controla o quanto os pesos da rede neural artificial em questão estão sendo ajustados com relação ao gradiente de perda. Não há valor que se pode dizer que é o melhor valor para a taxa de aprendizagem. A taxa de aprendizagem é um hiper-parâmetro e tem seu valor determinado por experimentos. Normalmente, as taxas de aprendizado são configuradas intuitivamente de forma aleatória. Nesse caso, a experiência do cientista de dados conta bastante para que valores serão utilizados inicialmente nas análises das redes neurais. Portanto, diferentes valores são testados e analisados. As melhores taxas de aprendizado encontradas são utilizadas na representação do modelo.

Smith (2015) argumenta que é possível estimar uma boa taxa de aprendizado treinando o modelo inicialmente com uma taxa de aprendizado muito baixa e aumentando-o linearmente ou exponencialmente a cada iteração. Registrando o aprendizado em cada iteração, verifica-se que à medida que a taxa de aprendizado aumenta, haverá um ponto em que a perda para de diminuir e começa a aumentar.

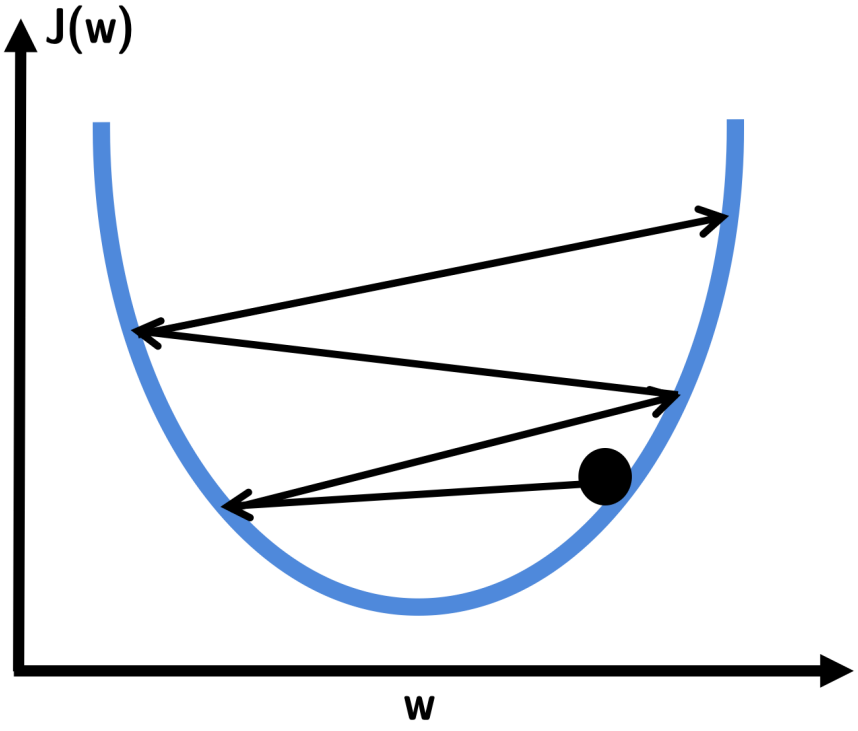
Quanto mais baixo o valor da taxa de aprendizagem, mais devagar será o processo de atualização dos erros. Embora utilizar um valor baixo de taxa de aprendizado possa parecer algo bom em termos de garantir que não será perdido nenhum mínimo local, também pode significar muito tempo para convergir, especialmente se convergir para uma região plana da curva. Altas taxa de aprendizagem pode fazer o algoritmo do gradiente descendente falhar em convergir ou até divergir. A Equação 3.4 demonstra o ajuste do gradiente descendente onde α representa a taxa de aprendizagem.

$$w := w - \alpha \frac{\partial J(w)}{\partial w} \tag{3.4}$$

As Figuras 3.21 e 3.22 demonstram, respectivamente, o comportamento do gradiente descendente e o comportamento do erro pelo número de épocas, de acordo com a escolha de valores maiores ou menores de taxa de aprendizagem.



(a) Baixa taxa de aprendizagem.



(b) Alta taxa de aprendizagem.

FIGURA 3.21 – Gradiente descendente com baixas e altas taxa de aprendizagem.

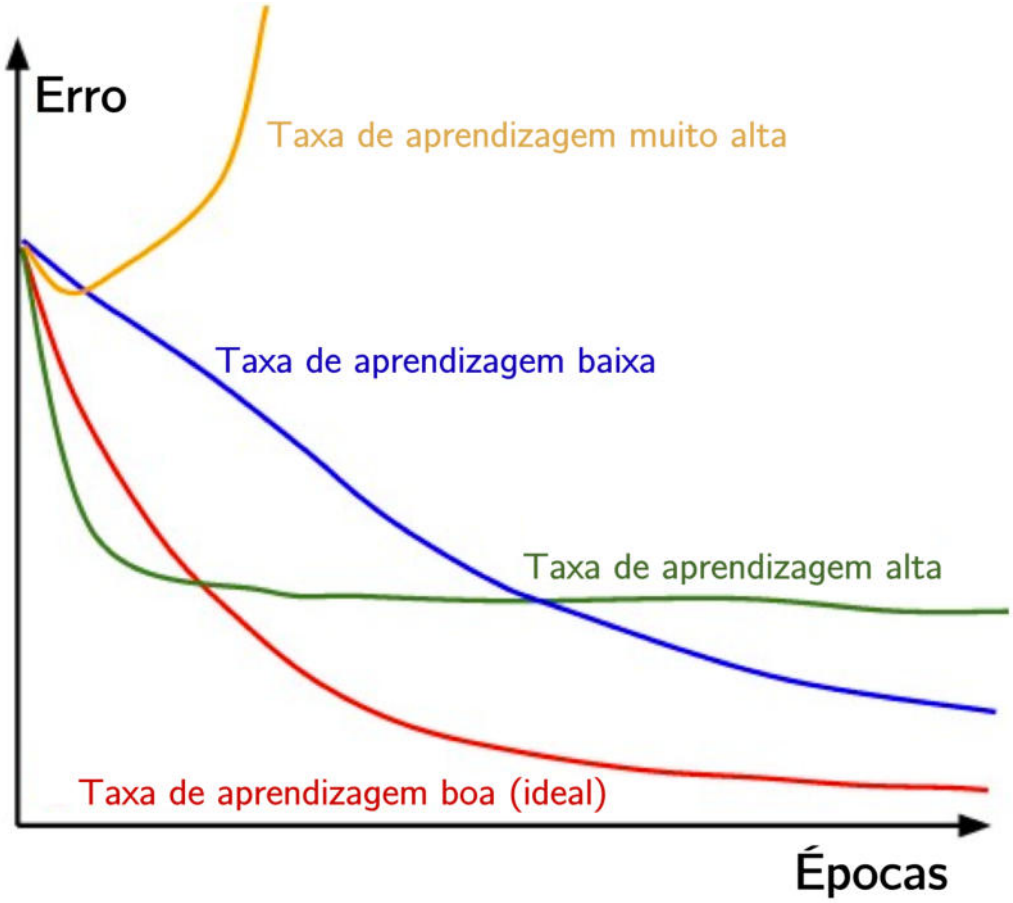


FIGURA 3.22 – Comportamento do erro por número de épocas de acordo com a taxa de aprendizagem escolhida.

No escopo da presente dissertação, serão utilizados valores diversos de taxa de aprendizado, com variações sempre com incrementos de pelo menos 10 vezes maior ou menor. Essa metodologia será adotada, pois mudanças muito pequenas na taxa de aprendizagem não trazem grandes mudanças no processo de treinamento das redes neurais artificiais. Serão observadas as mudanças nas métricas de desempenho baseadas na mudança desse hiper-parâmetro.

3.3.12 Treinamento e testes

Os treinamentos das redes neurais artificiais propostas nesse trabalho foram modeladas por meio de um pacote de códigos específico do *Python*, a *Scikit-learn*, que permite a modelagem de RNA's de classificação e regressão de forma bem mais simples e eficiente. Conforme já mencionado, foram utilizadas duas camadas ocultas em todas as redes modeladas e, nas análises de otimização das redes neurais, variou-se os seguintes hiper-parâmetros: função de ativação, número de neurônios das camadas ocultas, taxa de aprendizagem e algoritmo de otimização.

A classe *MLPClassifier* implementa um algoritmo perceptron multicamadas (MLP) que treina usando o algoritmo do *backpropagation*. Para uma tarefa onde o problema não é linearmente separável, é necessária a utilização de uma rede de múltiplas camadas (CYBENKO, 1989). O algoritmo mais popular e amplamente usado para este tipo de RNA é o *backpropagation* (RUMELHART *et al.*, 1985). O objetivo do *backpropagation* é otimizar os pesos sinápticos para que a rede neural possa aprender a mapear corretamente as entradas para as saídas. É um método computacionalmente eficiente para o treinamento de redes MLPs e que resolve o problema de realizar a propagação reversa do erro em RNAs com múltiplas camadas. Ele não requer normalização de vetores de entrada; no entanto, a normalização pode melhorar o desempenho (BUCKLAND, 2002).

Todos os processos foram realizados para cada uma das duas saídas das simulações de combate além do alcance visual. Portanto, foram analisadas as redes neurais referentes a defesa e ataque, sempre escolhendo como elemento base a aeronave azul. Foram realizadas varições dos hiper-parâmetros já descritos e as redes mais otimizadas foram escolhidas para representar o simulador de combate BVR no sistema de apoio à decisão proposto.

3.3.13 Previsão

Uma vez que o modelo foi treinado em conjunto de dados atribuído na modelagem proposta, ele agora pode ser utilizado para fazer estimativas em novos conjuntos de entrada de dados. No caso das redes neurais artificiais, o modelo aprendeu que para determinada configuração de valores para as entradas de dados, pode responder com uma estimativa para a variável alvo. Pode-se utilizar essas estimativas para conseguir informações sobre os dados dos quais o valor da variável alvo é desconhecida, por exemplo, os dados dos quais o modelo não foi treinado. Portanto, um modelo ótimo de aprendizado de máquina foi proposto para simular o combate além do alcance visual de forma satisfatória de acordo com as métricas de desempenho escolhidas.

Destaca-se, porém, que um modelo ótimo não é necessariamente um modelo robusto. Às vezes, um modelo é muito complexo ou muito simples para generalizar os novos dados. Em outros casos, o modelo pode utilizar um algoritmo de aprendizagem que não é apropriado para a estrutura de dados especificado. Pode ainda acontecer de os próprios dados terem informação excessiva ou exemplos insuficientes para permitir que o modelo aprenda a variável alvo, ou seja, o modelo não pode ser ajustado.

Essa capacidade preditiva do modelo de redes neurais artificiais do combate aéreo além do alcance visual pode ser utilizada para fornecer informações importantíssimas ao piloto BVR. Propõe-se nesse estudo, através da habilidade de previsão verificada, a construção de um dispositivo de melhoria da consciência situacional do piloto BVR. A próxima seção especifica de forma mais detalhada o objetivo desse sistema de apoio à decisão embarcado.

3.4 Sistema de melhoria da consciência situacional

A Consciência Situacional, ou ainda *Situation Awareness* (SA), é definida como a percepção dos elementos em um ambiente dentro de um volume de tempo e espaço, a compreensão de seus significados e a projeção de seus status em um futuro próximo (ENDSLEY, 1995).

A importância da consciência situacional, no aspecto operacional, surgiu dos próprios operadores e pilotos, os quais compreenderam como lhes seria difícil atingir e mantê-la em alto nível, aspecto considerado central em suas performances e no cumprimento de missões (ENDSLEY, 1995). Desde a Segunda Guerra Mundial, pilotos declaram essa importância e os desafios associados à aquisição da consciência situacional (ENDSLEY, 1995).

O aprofundamento do estudo no aumento e manutenção da SA é realizado por instituições da aviação civil e militar. No âmbito da aviação civil, a degradação da consciência situacional é responsável por parcela significativa dos acidentes aéreos, os quais se relacionam a decisões equivocadas das tripulações ou erros causados pela baixa consciência situacional. Foi identificado que 88% dos problemas relacionados ao erro humano são atribuídos à degradação da consciência situacional (ENDSLEY *et al.*, 1995). Na aviação militar, com a evolução dos sistemas de transmissão de informação em tempo real, os quais aceleram de forma significativa o processo de tomada de decisão, a necessidade de formação de SA, por parte do piloto de caça em missão operacional, surge como uma grande necessidade e impacta diretamente na letalidade do vetor de combate da Força Aérea Brasileira, assim como em sua sobrevivência.

Considerando a importância do assunto, Forças Aéreas de todo o mundo buscam soluções visando obter um maior nível de SA de suas equipagens de combate através do fluxo de dados entre aeronaves e demais atores no teatro de operações, tais como: controladores de voo, unidades de comando em solo, unidades de comando em voo e tripulantes de aeronaves em combate (PEREIRA, 2017).

Pilotos de caça consideram informações relativas a sua aeronave, aeronaves inimigas, ameaças advindas de mísseis ar-ar ou ar-solo e identificação de aeronaves amigas no mais alto nível de importância, dentre as informações a se dispor na formação de uma boa consciência situacional (ENDSLEY, 1993).

A capacidade de identificar uma aeronave como amiga, inimiga ou neutra é de suma importância. Esta influenciará diretamente na ação posterior à identificação. Em se tratando de uma aeronave amiga, maiores informações após a identificação não serão relevantes quando comparado a uma aeronave inimiga, porém a correta identificação é fator necessário para um nível mínimo de SA (ENDSLEY, 1993; PEREIRA, 2018).

Em decorrência do exposto, na aviação de combate a busca pela excelência na consciência situacional do piloto tornou-se imprescindível para a vitória. Desde o momento em que sistemas com alta carga de transmissão de informações tornaram-se presentes nas aeronaves de combate, a velocidade do processo decisório na nacele aumentou e passou a exigir meios de viabilizar decisões acertadas, atreladas à rapidez do processo de gerenciamento do combate (PEREIRA, 2017).

Fornecer melhores níveis de consciência situacional para o piloto com rapidez e facilidade traz melhorias para o correto julgamento e tomada de decisões no combate. Adicionalmente, as informações e dados transmitidos devem comportar todas as variáveis necessárias e permitir um engajamento ar-ar com grande consciência situacional (AERONÁUTICA, 2014). A constante atualização de informações, perante o grande dinamismo da missão de Defesa Aérea, servirá para manter alto ou aumentar o nível de consciência situacional do piloto.

Os erros relacionados à consciência situacional dizem respeito a um conjunto de problemas provocados por tecnologias com sobrecarga de dados, baixa integração de informações para apoiar a compreensão e projeção, causando sobrecarga de trabalho e outros fatores de estresse, conforme indicado pela Figura 3.23 (JONES; ENDSLEY, 1996).

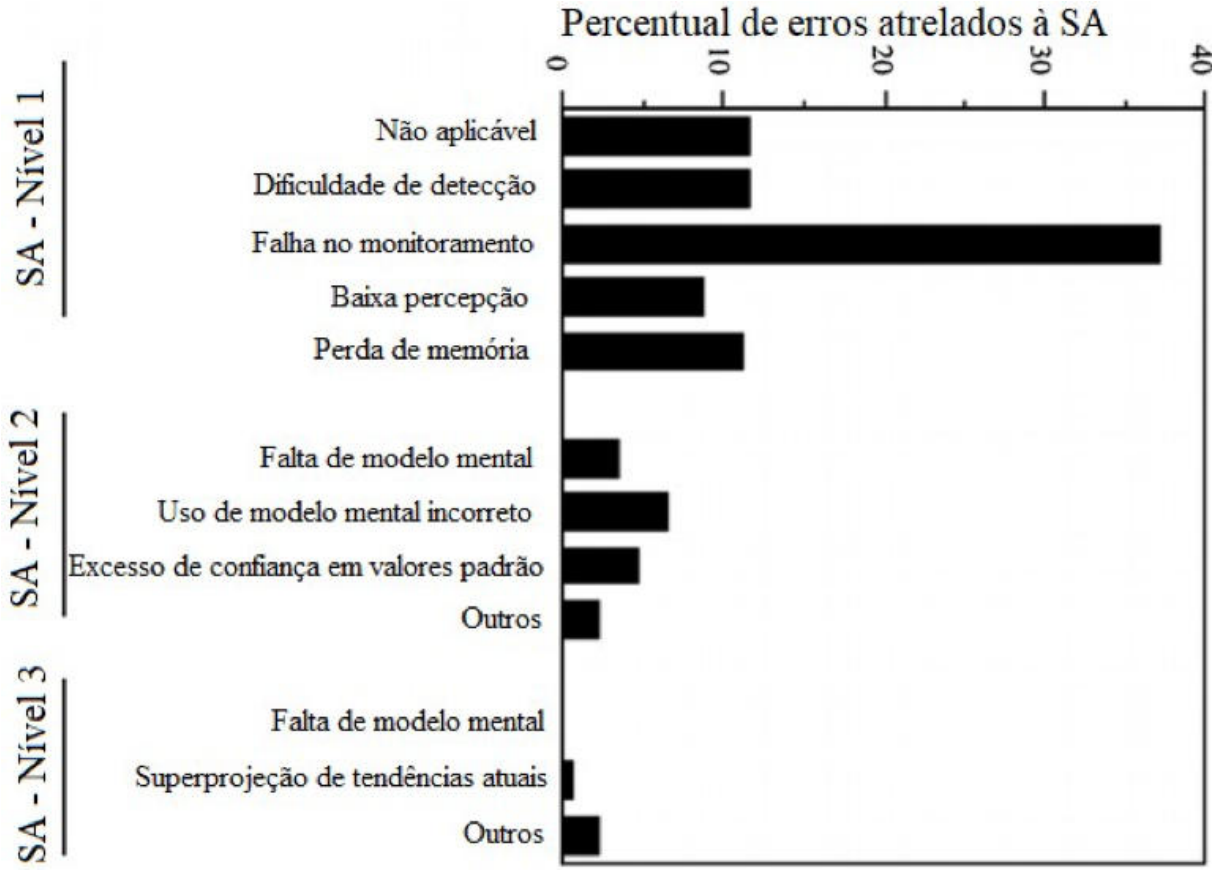


FIGURA 3.23 – Análise de fatores atrelados à Consciência Situacional causadores de erros na aviação geral.

Fonte: Pereira (2017)

Observada a importância de uma alta consciência situacional do piloto de combate aéreo além do alcance visual, propõe-se a criação de um sistema que possibilite uma melhoria da consciência situacional dos pilotos em combate. A confiabilidade desse sistema atrela-se à manutenção desta alta SA, já que o único meio de se enfrentar uma aeronave dotada de armamento BVR é proporcionar ao piloto uma clara e constante consciência da situação de combate aéreo. Não é possível escapar de mísseis BVR sem se conhecer, pelo menos, a distância do inimigo (AERONÁUTICA, 2014).

Primeiramente, buscou-se obter quais informações são importantes para manter uma alta capacidade de projeção de cenário de um piloto em um engajamento, visando evitar desperdícios de oportunidades de tiro BVR. Baseado nisso, primeiramente, foram listadas as variáveis mais importantes para modelagem do combate BVR que foram descritas na Seção 3.2. A partir dessas variáveis e com o uso das redes neurais artificiais é possível, em tempo real (considerando o valor dos intervalos de resposta das redes neurais propostas) e embarcado, obter informações relativas às possíveis distâncias finais que os possíveis mísseis lançados pela aeronave inimiga e pela própria aeronave analisada atingiram. Portanto, baseado na mecânica de combate que resultou nos valores obtidos por essas distâncias, é possível prever a todo instante a situação final do combate aéreo além do alcance visual entre uma aeronave amiga contra uma aeronave inimiga ambas equipadas com somente um míssil. Tal tecnologia pode ser usada para produzir apresentações que darão ao piloto melhores níveis de consciência situacional no cenário analisado. Ademais, simulações feitas no simulador de combate aéreo além do alcance visual sugerem uma maior eficácia do dispositivo de incremento da consciência situacional e redução de erros técnicos em voo.

Foram adotados, a partir dos valores de distância mínima de atuação do *proximity fuze* padronizada como 10 metros e da distância mínima de guiamento independente do míssil através do *seeker* como 10.000 metros, duas situações de combate baseadas no tipo de missão que se deseja, efetivamente, realizar. Vale destacar que essas distâncias adotadas são aproximações, pois os valores reais dependem do tipo de míssil e de outros fatores relacionados. Esse tipo de análise, feito por meio de simuladores, permite que a FAB tenha uma maior autonomia e segurança na hora de escolher os armamentos certos para utilizar em combate, ou ainda, para a compra de novos equipamentos bélicos para atualização do seu poder de combate com vistas a garantir a soberania do espaço aéreo brasileiro.

Portanto, a criação de um modelo de aprendizado de máquina baseado em redes neurais artificiais, que consiga representar o simulador de combate aéreo além do alcance visual em tempo real, permite a concepção de um sistema embarcado de apoio à decisão para a melhoria da consciência situacional do piloto em todas as fases de engajamento do combate BVR, auxiliando na sua escolha das melhores ações a serem feitas para ter um efeito desejado em um cenário operacional.

Vale ressaltar ainda que o dispositivo de melhoria da consciência situacional para o combate BVR não irá substituir o piloto em voo. Entretanto, a partir de análises quantitativas extraídas das simulações realizadas, é possível fornecer informações que facilitem, juntamente com a experiência do piloto em combates aéreos desse tipo, a tomada de decisão em voo para obter sucesso nas missões demandadas pela FAB. O objetivo é fornecer, dessa forma, uma ferramenta ao piloto para desempenhar suas missões da maneira mais assertiva possível.

4 Resultados e discussões

No capítulo anterior foram apresentados os passos que conduziram à construção da metodologia utilizada nesse estudo. A predição dos resultados finais da simulação BVR utilizando RNA é uma ferramenta de extrema importância para fornecer um suporte a tomada de decisão do piloto em combate. Ao longo do capítulo foi apresentada a metodologia a ser adotada no treinamento das redes neurais artificiais além das métricas de desempenho utilizadas.

O presente capítulo tem como foco apresentar a modelagem e treinamento dos resultados das redes neurais artificiais de classificação e regressão com suas respectivas métricas de desempenho utilizadas para realização das análises necessárias. Para as redes de classificação foram analisados dois estudos de caso específicos baseados nas distâncias atingidas pelos mísseis ao fim do combate. Para as redes de regressão, será realizada a previsão de uma saída com um valor numérico que permitirá uma maior versatilidade na análise de estudos de caso específicos do combate BVR em trabalhos futuros.

Inicialmente, é realizada uma avaliação das variáveis utilizadas nas simulações BVR. Essa avaliação consiste em análises estatísticas descritivas e o uso de ferramentas de qualidade para as verificações primárias do conjunto de dados utilizado no problema. A apresentação numérica dos resultados é acompanhada da discussão teórica acerca de suas implicações. Em seguida são gerados os modelos de regressão logística, redes neurais artificiais de classificação (com análises dos estudos de caso propostos) e de regressão. Ao final do capítulo, é apresentado um modelo do sistema embarcado de apoio à decisão de melhoria da consciência situacional do piloto baseada nos resultados obtidos nas redes neurais artificiais modeladas.

Esse capítulo demonstra a aplicação da metodologia proposta no trabalho e seus resultados após realizada a modelagem da aprendizagem de máquina que contribuirá na construção do sistema de apoio à decisão para o combate aéreo além do alcance visual.

4.1 Análise das variáveis

Nesta seção será realizada inicialmente a análise estatística descritiva dos dados de saída das simulações. Em seguida, será realizada a utilização de algumas ferramentas de qualidade para verificar o comportamento das variáveis de entrada em relação as variáveis de saída e observar possíveis correlações que permitam associar um grau de maior importância a uma variável preditiva específica.

4.1.1 Estatística descritiva das variáveis de saída

Nesse momento, serão feitas as análises estatísticas iniciais dos dados das simulações. Estes estudos estatísticos serão extremamente importantes, posteriormente, para analisar vários resultados de previsão do modelo construído em redes neurais artificiais. Os cálculos de média, desvio padrão, mínimo, máximo e mediana de dist_BM_RA e dist_RM_BA que representa as distâncias finais que o míssil da aeronave azul se aproximou da aeronave vermelha e que o míssil da aeronave vermelha se aproximou da aeronave azul. Tomando como base a aeronave azul, as distâncias referem-se, respectivamente, aos modelos de ataque e defesa. A tabela 4.1 demonstra as estatísticas descritivas das variáveis de saída das simulações para os três conjuntos de dados utilizados: 100, 1.000 e 10.000 simulações.

TABELA 4.1 – Estatísticas descritivas: variáveis de saída do modelo de simulação do combate aéreo além do alcance visual.

Variável	Unidade	Simulações	Média	Desvio-Padrão	Mínimo	Máximo	Mediana
dist_BM_RA	metros	100	25.429,58	21.143,47	2,41	80.795,18	27.901,83
dist_BM_RA	metros	1.000	24.660,19	21.298,51	0,91	88.426,51	21.629,48
dist_BM_RA	metros	10.000	24.847,88	21.577,41	0,31	100.859,66	21.916,28
dist_RM_BA	metros	100	21.675,52	18.802,40	1,39	70.169,59	17.032,10
dist_RM_BA	metros	1.000	24.945,67	20.995,43	0,41	84.613,66	24.622,16
dist_RM_BA	metros	10.000	24.720,36	21.575,09	0,60	90.242,77	21.858,10

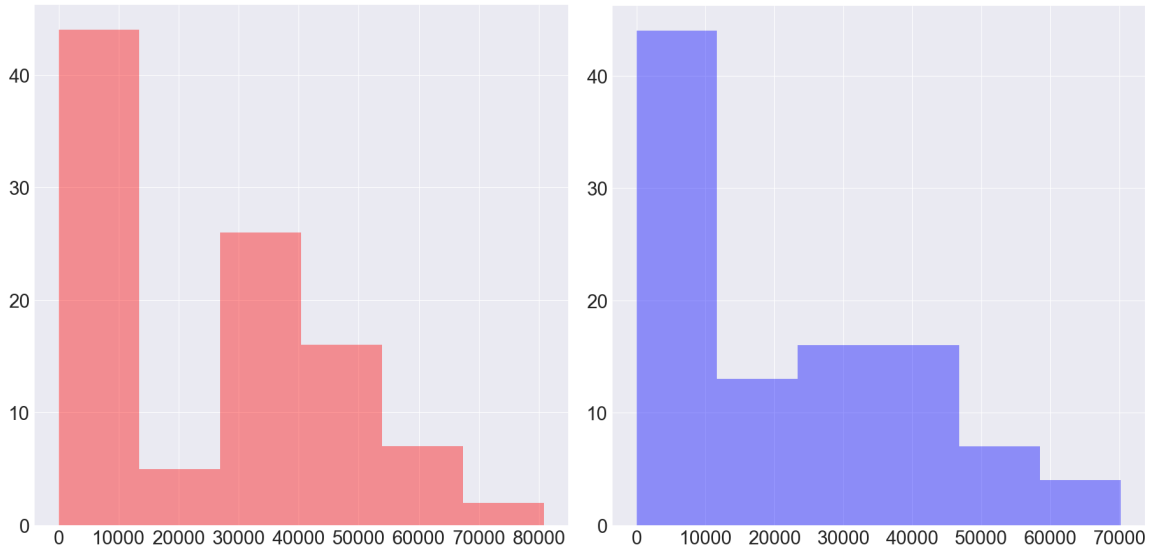
Por fim, observa-se que foi realizada somente a análise estatística descritiva dos dados de saída das simulações, pois os dados de entrada foram gerados a partir do particionamento em 100, 1.000 e 10.000 partes dos intervalos de cada variável por meio da utilização da *Latin Hypercube Sampling*. As variáveis de entrada foram propostas para modelagem do cenário BVR baseadas no conhecimento prático dos pilotos e especialistas que atuam no treinamento desse tipo de combate. Portanto, seus intervalos foram pré-definidos e foram amostrados e embaralhados para descrever de forma mais abrangente possível o máximo de possibilidades de interação entre essas variáveis. Por essa razão, não se vê a necessidade de tal análise estatística para compreender o cenário do combate BVR, pois essas *features* já foram modeladas e pré-processadas no início da estruturação do problema. A descrição de todas as variáveis de entrada do problema foi realizada no Capítulo 3.

4.1.2 Ferramentas de qualidade

Magalhães (1996) ressalva a importância das sete ferramentas de qualidade definidas da estatística: Fluxograma, Diagrama Ishikawa (Espinha-de-Peixe), Folhas de Verificação, Diagrama de Pareto, Cartas de Controle, Histograma e Diagrama de Dispersão. Nesse estudo, para a análise de qualidade estatística serão utilizados para visualização os histogramas de frequência e para as análises de dispersão os cálculos dos valores de covariância e correlação, ferramentas muito importantes na observação dos dados do problema proposto.

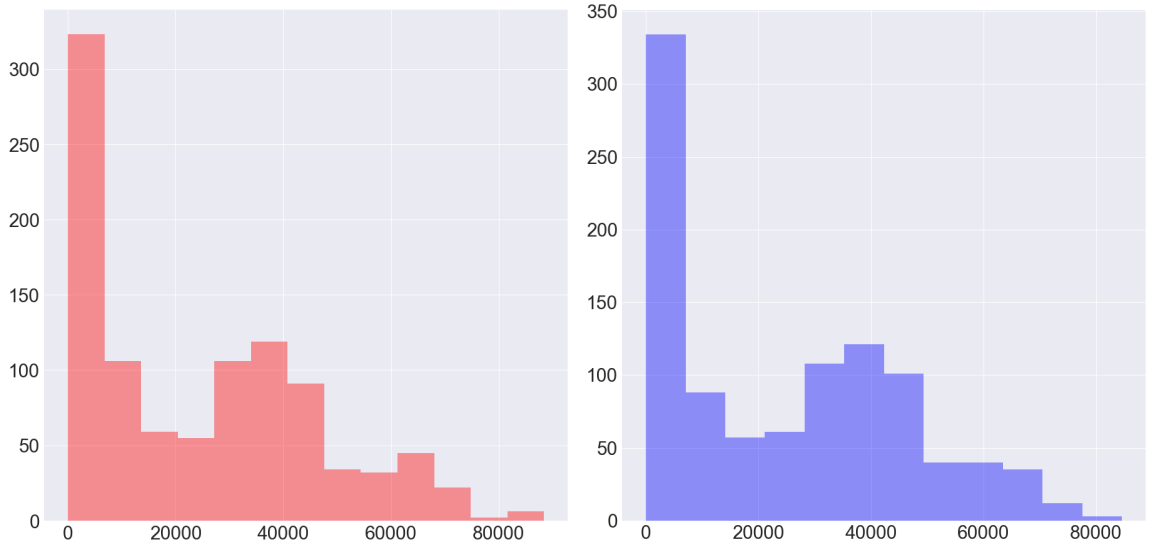
4.1.2.1 Histogramas

A seguir são descritos os gráficos histogramas de frequência das variáveis de saída. Freund (2006) descreve histograma como uma representação gráfica em colunas ou em barras de um conjunto de dados previamente tabulado e dividido em classes uniformes ou não uniformes. Trata-se de um gráfico de frequência onde a base de cada retângulo representa uma classe definida no problema. A altura de cada retângulo representa a frequência absoluta com que o valor da classe ocorre no conjunto de dados em que foi realizada a análise. As Figuras 4.1, 4.2 e 4.3 representam os histogramas de frequências das variáveis de saídas das simulações de combate aéreo além do alcance visual para 100, 1.000 e 10.000 simulações.



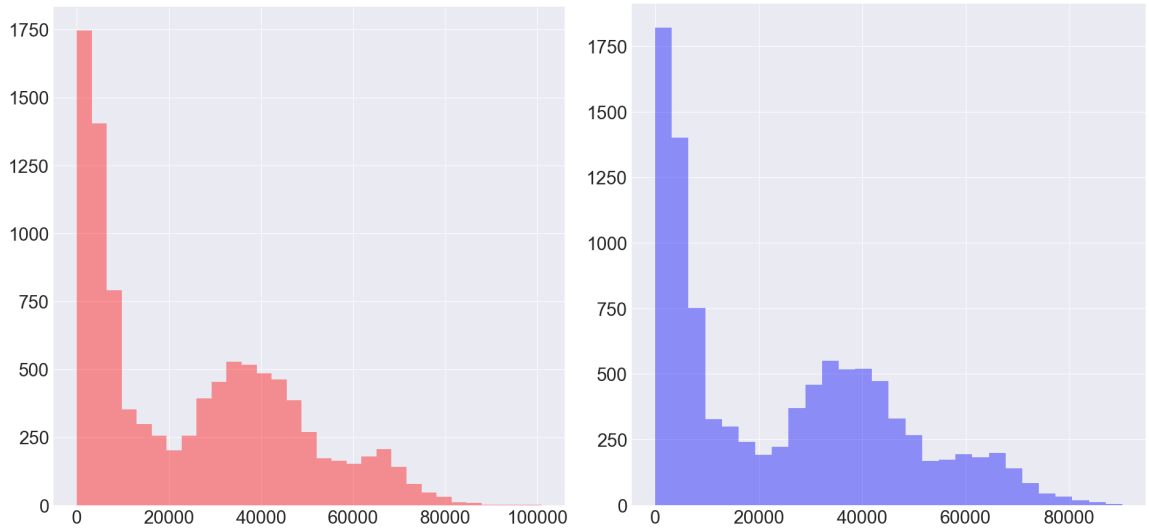
(a) Modelo de ataque (dist_BM_RA) (b) Modelo de defesa (dist_RM_BA)

FIGURA 4.1 – Histogramas das variáveis de saída para 100 simulações.



(a) Modelo de ataque (dist_BM_RA) (b) Modelo de defesa (dist_RM_BA)

FIGURA 4.2 – Histogramas das variáveis de saída para 1.000 simulações.



(a) Modelo de ataque (dist_BM_RA) (b) Modelo de defesa (dist_RM_BA)

FIGURA 4.3 – Histogramas das variáveis de saída para 10.000 simulações.

4.1.2.2 Covariância e correlação

A análise de dispersão mostra o que acontece com uma variável quando a outra sofre alteração, para testar possíveis relações de causa e efeito (MAGALHÃES, 1996). No estudo estatístico, por vezes, é necessário se obter informações sobre a capacidade de duas variáveis possuírem alguma relação entre si dentro de um conjunto de dados. Para estes casos, é realizado o cálculo da covariância e da correlação entre elas.

Milone (2004) define a covariância como uma medida numérica que indica a inter-dependência entre duas variáveis e que mostra como elas se comportam conjuntamente em

relação às suas médias. Uma covariância nula indica que as duas variáveis são totalmente independentes, enquanto que uma covariância alta e positiva indica que uma variável é grande quando a outra é grande. Analogamente, uma covariância negativa e com valor absoluto alto indica que uma variável é pequena quando a outra é grande.

TABELA 4.2 – Covariância entre as variáveis de entrada e as variáveis de saída das simulações BVR.

	dist_BM_RA	**dist_RM_BA**
posicao_relativa	44252350000.00	40254140000.00
distancia	8934704000.00	8245807000.00
altitude_blue	-3974489000000.00	10451780000000.00
altitude_red	10415600000000.00	-4585339000000.00
velocidade_blue	-39202650.00	53750930.00
velocidade_red	27005760.00	-65874410.00
blue_rwr	857215700.00	437743400.00
red_rwr	386644400.00	919676700.00
missil_blue_a	1134309000.00	-517153900.00
missil_blue_b	750973900.00	-688727700.00
missil_blue_c	-1885283000.00	1205882000.00
missil_est_red_a	-52541460.00	-514092300.00
missil_est_red_b	-126892200.00	-334350800.00
missil_est_red_c	179433700.00	848443100.00
missil_red_a	-498198000.00	1138740000.00
missil_red_b	-799716900.00	718312800.00
missil_red_c	1297915000.00	-1857053000.00
missil_est_blue_a	-518160800.00	-423078300.00
missil_est_blue_b	-315879600.00	-141848800.00
missil_est_blue_c	834040500.00	564927100.00
shotphi_blue_s	4522683000.00	-2167752000.00
shotphi_blue_m	69783350.00	-159425700.00
shotphi_blue_l	-4592466000.00	2327178000.00
shotphi_est_red_s	-404406300.00	-1126787000.00
shotphi_est_red_m	-114601100.00	-111898600.00
shotphi_est_red_l	519007400.00	1238686000.00
shotphi_red_s	-2240252000.00	4520320000.00
shotphi_red_m	-329225600.00	42243920.00
shotphi_red_l	2569478000.00	-4562564000.00
shotphi_est_blue_s	-1093669000.00	-473346300.00
shotphi_est_blue_m	-84133200.00	-161974000.00
shotphi_est_blue_l	1177802000.00	635320300.00
threshold_before_blue	-483549700.00	-287419900.00
threshold_after_blue	73809900.00	-478713100.00
threshold_before_red	-366319600.00	-438733700.00
threshold_after_red	-530647400.00	92666970.00
dist_BM_RA	465631300000000.00	-91343900000000.00
dist_RM_BA	-91343900000000.00	465531100000000.00

A covariância, entretanto, pode ser difícil de ser compreendida e comparada, pois ela nos dá valores em escalas que serão diferentes conforme as variáveis mudem. Para uma melhor comparação, normalizamos a covariância para ter um valor que sempre estará entre 1 e -1. Essa normalização gera a correlação.

Morettin e Bussab (2012) define correlação como a relação estatística, seja causal ou não causal, que envolva dependência entre duas variáveis. Portanto, a correlação também é outra medida que indica o quanto duas variáveis estão relacionadas. Seu valor fica sempre entre -1, que indica uma anti-correlação perfeita, e 1, que indica uma correlação perfeita. Contudo, é necessário cuidado ao avaliar as correlações pois algumas informações dos bancos de dados analisados podem indicar uma correlação que não existe de fato, e é apenas obra do acaso, o que é possível em certos casos onde variáveis apresentam algum tipo de padrão que pode levar a este valor de correlação.

Borges (2007) afirma que a existência de correlação entre duas variáveis nada diz sobre os mecanismos e processos intervenientes, ou seja, correlação não implica causalidade. Causalidade diz respeito a uma relação entre dois eventos, A e B, que estabelece o evento A como causa do evento B, e o evento B como efeito do evento A. Quando duas variáveis apresentam um alto valor de correlação, pode ser que a primeira variável cause este comportamento na segunda, que a segunda causa este comportamento na primeira, que ambas causam o comportamento na outra ou isso também pode não dizer nada. Em todo caso, o mais importante a ser feito é analisar bem os problemas e conhecer de forma aprofundada os dados utilizados na análise para fazer criteriosas análises estatísticas necessárias para correta interpretação do problema.

Observa-se na Tabela 4.3, demonstrada a seguir, que não existe nenhuma variável de entrada que tenha alguma correlação forte (positiva ou negativa) com as variáveis de saída da simulação, fato que já era esperado devido a complexidade do problema. Caso existisse variáveis que tivessem forte correlação significaria que tais variáveis teriam um peso maior na decisão final da simulação, o que não condiz com o que acontece na prática em um combate aéreo além do alcance visual. Combates aéreos desse tipo são determinados por uma grande quantidade de fatores e é muito difícil modelar um problema dessa magnitude com a influência de apenas alguns atributos. Portanto, o problema de combate BVR é bastante complexo e não pode ser analisado baseado-se apenas em algumas variáveis, e sim, como um conjunto de vários atributos que, de forma conjunta, representam o combate aéreo além do alcance visual. À vista dessas constatações, o fato de se tratar um problema de modelagem complexa contribuiu para a escolha dos algoritmos de redes neurais artificiais para representar esse tipo de cenário operacional simulado, pois esse tipo de modelo de aprendizado de máquina supervisionado consegue representar problemas robustos através da relação de diversas camadas e seus respectivos neurônios, com uma eficiência computacional condizente, interagindo dinamicamente para calibração

dos pesos sinápticos e, consequentemente, obtendo-se a representação de forma verossímil do problema analisado.

TABELA 4.3 – Correlação entre as variáveis de entrada e as variáveis de saída das simulações BVR.

	dist_BM_RA	**dist_RM_BA**
posicao_relativa	0.118395	0.107709
distancia	0.057371	0.052953
altitude_blue	-0.042534	0.111865
altitude_red	0.111466	-0.049077
velocidade_blue	-0.031465	0.043147
velocidade_red	0.021676	-0.052879
blue_rwr	0.079447	0.040575
red_rwr	0.035834	0.085245
missil_blue_a	0.111788	-0.050972
missil_blue_b	0.074010	-0.067882
missil_blue_c	-0.184426	0.117977
missil_est_red_a	-0.005178	-0.050670
missil_est_red_b	-0.012505	-0.032954
missil_est_red_c	0.017553	0.083007
missil_red_a	-0.049098	0.112237
missil_red_b	-0.078813	0.070798
missil_red_c	0.126967	-0.181684
missil_est_blue_a	-0.051065	-0.041699
missil_est_blue_b	-0.031130	-0.013981
missil_est_blue_c	0.081589	0.055269
shotphi_blue_s	0.445717	-0.213658
shotphi_blue_m	0.006877	-0.015713
shotphi_blue_l	-0.449254	0.227679
shotphi_est_red_s	-0.039855	-0.111058
shotphi_est_red_m	-0.011294	-0.011029
shotphi_est_red_l	0.050771	0.121186
shotphi_red_s	-0.220780	0.445532
shotphi_red_m	-0.032446	0.004164
shotphi_red_l	0.251357	-0.446377
shotphi_est_blue_s	-0.107783	-0.046654
shotphi_est_blue_m	-0.008291	-0.015964
shotphi_est_blue_l	0.115217	0.062156
threshold_before_blue	-0.077623	-0.046144
threshold_after_blue	0.011848	-0.076855
threshold_before_red	-0.058804	-0.070436
threshold_after_red	-0.085183	0.014877
dist_BM_RA	1	-0.196193
dist_RM_BA	-0.196193	1

4.2 Aplicabilidade

A aplicabilidade das redes neurais artificiais que foram modeladas na presente dissertação diz respeito a concepção do sistema embarcado de apoio à decisão ao piloto BVR que permitirá fornecer informações importantes de sucesso ou fracasso nos combates aéreos, tanto em aspectos defensivos como ofensivos. As saídas obtidas das redes construídas calibram um dispositivo de melhoria da consciência situacional do piloto em um combate aéreo além do alcance visual, visto que, é possível obter resultados em tempo real da situação final da simulação baseado nas mudanças das variáveis de entrada propostas. O sistema fornece informações semelhantes ao simulador de combate BVR porém com uma resposta significativamente mais rápida. Para construção do sistema de apoio à decisão proposto nesse estudo, inicialmente, irá se utilizar a regressão logística para uma abordagem preliminar do problema. A seguir, foram utilizadas redes neurais de classificação adorando a saída 1 para sucesso e a saída 0 para fracasso, tanto em situações de ataque como defesa. Para definição dos valores 1 ou 0 referentes as distâncias máximas atingidas pelos mísseis ao final da simulação, foram propostas duas situações operacionais desejáveis a serem analisadas: o míssil atingindo uma distância mínima de 10 metros e 10.000 do alvo. Foram modeladas redes neurais artificiais com duas camadas ocultas, 36 variáveis de entrada e 1 variável de saída. O que variou nas redes projetadas foram os seguintes atributos: número de amostras utilizadas para treino, validação e teste, funções de ativação, taxa de aprendizagem inicial, algoritmo de otimização e número de neurônios das camadas ocultas. Em seguida, foi realizado uma modelagem de redes neurais artificiais de regressão, fornecendo um panorama mais generalista da simulação, que permitirá, em trabalhos futuros, análise de outros estudos de caso operacionais. Foram utilizadas ainda diversas métricas para as redes de classificação e regressão: Acurácia, Matrizes de Confusão, *Root Mean Square Error* (RMSE) e o Coeficiente de Determinação (R^2). O detalhamento de utilização de cada um desses parâmetros foi descrito no Capítulo 3. Em linhas gerais, argumenta-se nesta seção as aplicabilidades do modelo de inteligência artificial proposto e como deve ser utilizado, de acordo com as configurações do mundo real, para contribuir com operacionalidade do combate aéreo além do alcance visual.

4.2.1 Modelo de regressão logística

Como primeiro modelo de previsão será proposto um modelo de regressão logística simples e com a utilização da validação cruzada *k-fold* a obter a precisão do conjunto de dados. A validação cruzada é um método usado para evitar *overfitting*, ou seja, quando o modelo se ajusta muito bem aos dados de treinamento, mas não generaliza bem o suficiente para os dados que estão fora do conjunto de treinamento, conforme já descrito em capítulos anteriores.

Portanto, os dados de treinamento serão divididos em 5 partes, o modelo de previsão é gerado nas 4 partes e testado na 5ª parte. Isso é feito 5 vezes usando diferentes combinações dessas partes como conjuntos de treinamento e teste, e, eventualmente, uma média de todos esses modelos é usada para obter a precisão final.

As Tabelas 4.4 e 4.5 demonstram os resultados obtidos utilizando regressão logística para o caso do míssil atingindo uma distância mínima em relação ao alvo de 10 metros e 10.000 metros respectivamente. Observa-se que foram analisadas as situações de ataque e defesa e sempre variando o número de amostras escolhidas. As acurácias analisadas com validação cruzada *k-fold* estão dispostas nas Tabelas 4.4 e 4.5.

TABELA 4.4 – Resultados do modelo de regressão logística para o caso do míssil atingindo a distância máxima de 10 metros.

ID	Tipo de modelo	Nº de dados	Acurácia com validação cruzada *k-fold*
1	Ataque	100	0,6667
2	Ataque	1.000	0,8600
3	**Ataque**	**10.000**	**0,9013**
4	Defesa	100	0,7999
5	Defesa	1.000	0,8533
6	**Defesa**	**10.000**	**0,8913**

TABELA 4.5 – Resultados do modelo de regressão logística para o caso do míssil atingindo a distância de 10.000 metros.

ID	Tipo de modelo	Nº de dados	Acurácia com validação cruzada *k-fold*
1	Ataque	100	0,6667
2	Ataque	1.000	0,7400
3	**Ataque**	**10.000**	**0,8160**
4	Defesa	100	0,5333
5	Defesa	1.000	0,7200
6	**Defesa**	**10.000**	**0,8153**

Como esperado, em modelos de aprendizado de máquina, quanto maior a quantidade de dados melhor é a performance das redes. Os valores ótimos, para o estudo de caso do míssil atingindo 10 metros, obtidos de acurácia para os modelos de ataque e defesa, respectivamente, foram 90,13% e 89,13%. Além disso, para o estudo de caso do míssil atingindo 10.000 metros, foram encontrados valores de acurácia de 81,60% e 81,53%. De forma geral, uma maior quantidade de dados permite um treinamento de modelos de aprendizado de forma mais otimizada. A justificativa da utilização da validação cruzada *k-fold* é justificada pela falta de dados de simulação devido a demora da execução de cada combate no simulador, além de, com esse tipo de validação cruzada, o fenômeno de *overfitting* dificilmente irá ocorrer, devido a reamostragem do grupo de teste em cada etapa do processo de validação cruzada *k-fold*.

A análise inicial por regressão logística permitiu verificar a importância da quantidade de dados para realização dos treinamentos, conforme o método de aprendizagem de máquina utilizado. O modelo utilizado nesta subseção se trata de uma rede neural de apenas um neurônio com uma função de ativação sigmoide. Portanto, a utilização da regressão logística permitiu uma abordagem inicial do problema e seus parâmetros de desempenho. Uma abordagem por redes neurais artificiais com arquitetura mais robusta será realizada na próxima Subseção (4.2.2), onde as métricas de desempenho serão analisadas para uma otimização de representação do problema. Por fim, serão utilizadas as matrizes de confusão para entender a distribuição preditiva do modelo para aplicação no sistema de apoio à decisão aplicado ao combate aéreo além do alcance visual.

4.2.2 Modelo de redes neurais artificiais de classificação

Nesta subseção será realizada a modelagem das redes neurais artificiais de classificação das simulações de combate BVR. Inicialmente, serão demonstrados os treinamentos e testes realizados pelas redes para construção do modelo de aprendizado supervisionado proposto. Concomitantemente, será feita uma análise de desempenho do modelo por meio dos parâmetros adotados no Capítulo 3 para representar a sua eficiência e capacidade de representar o problema proposto. A seguir, o modelo de previsão para novas amostras será confrontado com a realidade das simulações de combate além do alcance visual. Foram realizadas variações das redes neurais artificiais de classificação nas funções de ativação, na taxa de aprendizagem inicial, nos algoritmos de otimização e número de neurônios para duas camadas ocultas.

4.2.2.1 Míssil atingindo a distância de 10 metros do alvo

A primeira situação proposta foi utilizando 10 metros como fator determinante de sucesso pois esta é, de acordo com o modelo de míssil modelado no estudo, a distância limite do alvo que a cabeça de busca precisa para acionar o sistema de espoleta de proximidade ou *proximity fuze*, que, conforme já mencionado, é um detonador que detona automaticamente um dispositivo explosivo quando a distância ao alvo se torna menor do que um valor predeterminado, e, dessa forma, o míssil poderá atingir o alvo efetivamente. Contudo, esse valor é uma aproximação para analisar o estudo de caso proposto. Portanto, todas as distâncias obtidas nas saídas das simulações foram transformadas de variáveis numéricas para variáveis categóricas, onde para distâncias menores que 10 metros assumem valor 1 (sucesso) e para distâncias maiores que 10 metros assumem valor 0 (fracasso). A Tabela 4.6 demonstra a descrição das saídas, baseada na classificação de sucesso e fracasso, para esse estudo de caso de acordo com as quantidades de vezes que cada um ocorre.

TABELA 4.6 – Descrição das saídas no estudo de caso do míssil atingindo 10 metros.

Tipo de modelo	**Número de saídas 0 (fracasso)**	**Número de saídas 1 (sucesso)**
Ataque	8711	1289
Defesa	8690	1310

As Tabelas 4.7 e 4.8 demonstram, respectivamente, as redes neurais de classificação modeladas para ataque (dist_BM_RA) e defesa (dist_BM_RA), considerando a proposta de análise escolhida, sempre tomando como referência a aeronave azul na simulação.

TABELA 4.7 – Otimização das redes neurais artificiais de ataque para o estudo de caso do míssil atingindo distância mínima de 10 metros do alvo.

ID	**F. de ativação**	**T. de aprendizagem inicial**	**Alg. de otimização**	**Nº neurônios das camadas ocultas**	**Acurácia com validação cruzada *k-fold***
1	Sigmoide	0,1	L-BFGS	(5,5)	0,8799
2	Sigmoide	0,1	SGD	(5,5)	0,8800
3	Sigmoide	0,1	ADAM	(5,5)	0,9027
4	Sigmoide	0,01	ADAM	(10,10)	0,9086
5	Sigmoide	0,01	ADAM	(15,5)	0,8766
6	TanH	0,01	L-BFGS	(5,5)	0,8840
7	TanH	0,001	SGD	(5,5)	0,9153
8	TanH	0,01	ADAM	(5,5)	0,9033
9	TanH	0,01	ADAM	(15,5)	0,9007
10	TanH	0,001	ADAM	(35,5)	0,8807
11	ReLU	0,001	L-BFGS	(10,5)	0,8913
12	ReLU	0,001	SGD	(10,5)	0,9140
13	ReLU	0,001	ADAM	(15,5)	0,9060
14	ReLU	0,001	ADAM	(10,4)	0,9173
15	ReLU	0,001	SGD	(10,4)	0,9119
16	TanH	0,001	SGD	(10,3)	0,9193
17	TanH	0,001	SGD	(8,2)	0,9080
18	ReLU	0,001	SGD	(10,2)	0,9039
19	**ReLU**	**0,001**	**ADAM**	**(13,7)**	**0,9255**
20	ReLU	0,001	ADAM	(35,35)	0,8966

TABELA 4.8 – Otimização das redes neurais artificiais de defesa para o estudo de caso do míssil atingindo distância mínima de 10 metros do alvo.

ID	**F. de ativação**	**T. de aprendizagem inicial**	**Alg. de otimização**	**Nº neurônios das camadas ocultas**	**Acurácia com validação cruzada *k-fold***
1	Sigmoide	0,1	L-BFGS	(3,2)	0,9020
2	Sigmoide	0,1	SGD	(3,2)	0,8826
3	Sigmoide	0,01	ADAM	(5,2)	0,9153
4	Sigmoide	0,01	ADAM	(10,5)	0,8946
5	Sigmoide	0,01	ADAM	(2,2)	0,9053
6	TanH	0,001	L-BFGS	(3,2)	0,8786
7	TanH	0,001	SGD	(5,5)	0,9093
8	TanH	0,001	ADAM	(5,5)	0,9173
9	TanH	0,01	ADAM	(8,5)	0,8980
10	TanH	0,001	ADAM	(10,4)	0,8773
11	ReLU	0,001	ADAM	(5,5)	0,9093
12	ReLU	0,1	ADAM	(4,3)	0,9073
13	ReLU	0,01	SGD	(8,5)	0,8899
14	ReLU	0,001	L-BFGS	(30,5)	0,9000
15	TanH	0,001	L-BFGS	(30,15)	0,9053
16	TanH	0,001	SGD	(3,3)	0,8966
17	**ReLU**	**0,001**	**ADAM**	**(22,10)**	**0,9241**
18	TanH	0,01	ADAM	(5,4)	0,9066
19	ReLU	0,01	ADAM	(5,4)	0,9139
20	ReLU	0,01	ADAM	(4,3)	0,8973

Como esperado, a função ReLU é melhor do que as funções sigmoidais. Quanto às ativações sigmoidais, a função TanH é significantemente melhor do que a Sigmoide. Isso confirma que a otimização se torna mais fácil com ativações que aproximam a identidade. Além disso, observa-se que valores menores de taxa de aprendizagem evitam o encontro de mínimos locais nas funções o que tornou os treinamentos com resultados melhores. O

algoritmo de otimização ADAM se mostrou com os melhores resultados também. Além disso, como já constatado anteriormente, uma maior amostra de simulações vai permitir um treinamento mais efetivo do modelo preditivo. Portanto, quando foram utilizados valores maiores de amostras, foi possível obter um RMSE menor e uma acurácia maior do modelo.

Observa-se que, ao realizar as tentativas de se encontrar a configuração ideal para a rede neural artificial de classificação para o modelo de ataque referente ao estudo de caso do míssil atingindo distância mínima de 10 metros, o melhor resultado encontrado obteve uma acurácia de 92,55%.

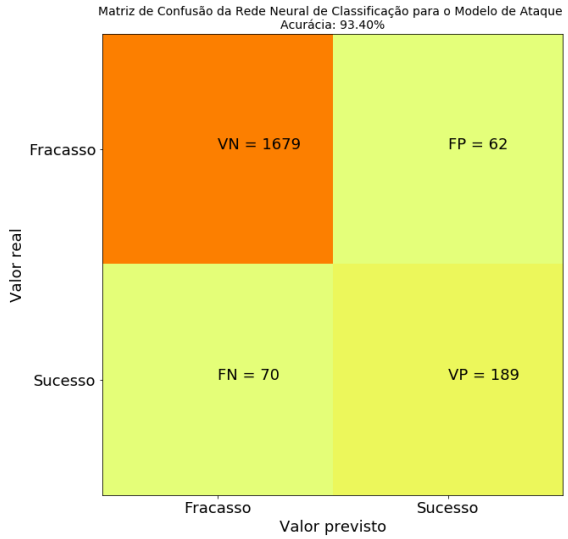
Os resultados encontrados do modelo preditivo adotado foram satisfatórios para representação das simulações BVR por meio de redes neurais artificiais. A utilização da validação cruzada *k-fold*, conforme já visto no modelo de regressão logística na Subseção 4.2.1, permitiu que, mesmo com mostras desbalanceadas referentes aos casos de sucesso e fracasso, fossem realizados treinamentos sem *overfitting* e com valores de acurácia condizentes. Semelhantemente ao modelo de aprendizagem anterior, foram utilizadas 5 camadas na validação cruzada.

Analogamente, quando se trata da rede neura artificial de classificação para defesa, para o estudo de caso do míssil atingindo distância mínima de 10 metros, o resultado otimizado encontrado possui uma acurácia de 92,41%.

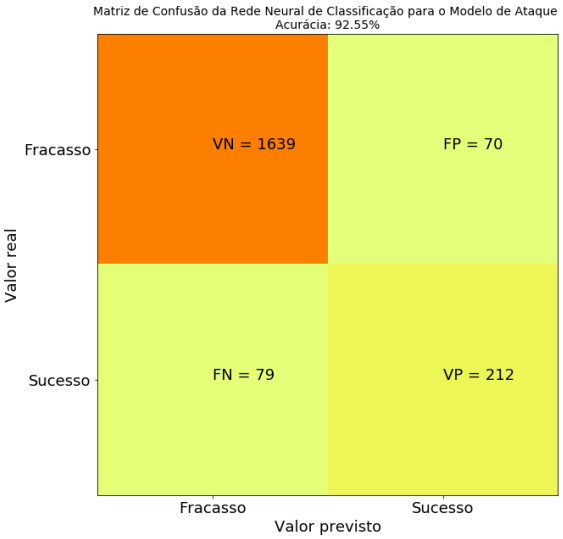
Foram calculadas ainda as matrizes de confusão das redes neurais artificiais de ataque e defesa com as 5 divisões dos conjuntos de dados utilizados na validação cruzada *k-fold*. A matriz de confusão é uma apresentação útil da precisão de um modelo com duas ou mais classes. As matrizes de confusão apresentadas possuem previsões sobre o eixo x e valores reais no eixo y. As células da tabela são o número de previsões feitas por um algoritmo de aprendizado de máquina. Observa-se que a acurácia do modelo preditivo é a média da acurácia de cada divisão de amostragem da validação cruzada.

Na análise preditiva, uma tabela de confusão relata o número de falsos positivos, falsos negativos, verdadeiros positivos e verdadeiros negativos. Isso permite uma análise mais detalhada do que a mera proporção de classificações corretas (precisão). Somente a acurácia não é uma métrica confiável para o desempenho real de um classificador, porque produzirá resultados enganosos se o conjunto de dados estiver desequilibrado, ou seja, quando o número de observações em diferentes classes variar muito. Por essa razão estão sendo utilizadas essas duas métricas de desempenho, acurácia e matriz de confusão, para análise dos classificadores. O ideal seria que os valores ficassem concentrados em VN e VP. Observa-se, contudo, que alguns casos foram classificados como FP e FN.

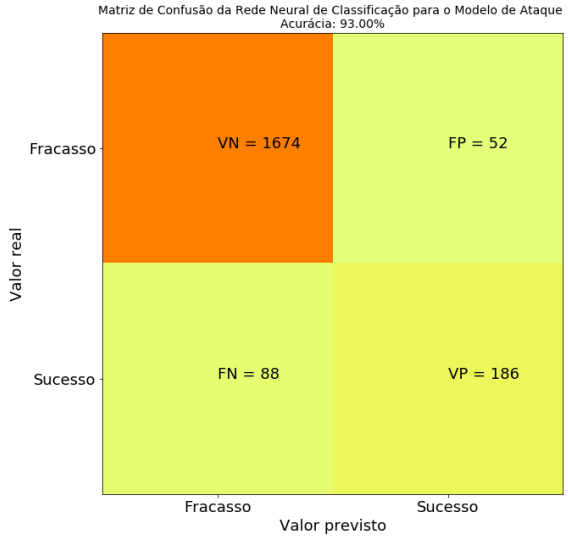
As Figuras 4.4 e 4.5 demonstram as matrizes de confusão calculadas para os modelos de ataque e defesa no caso do míssil atingindo a distância de 10 metros.



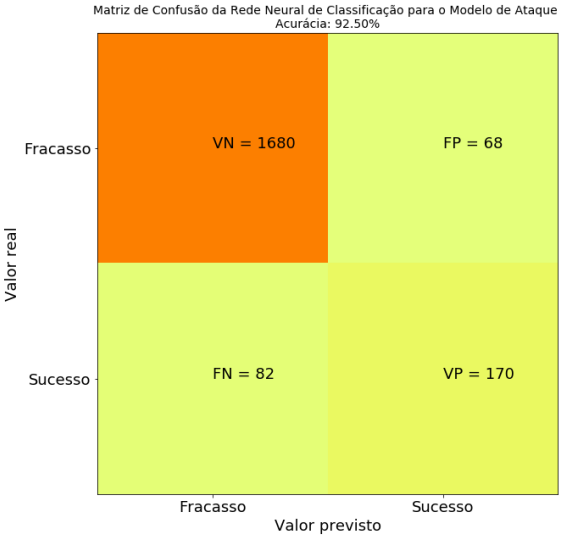
(a) 1ª amostragem



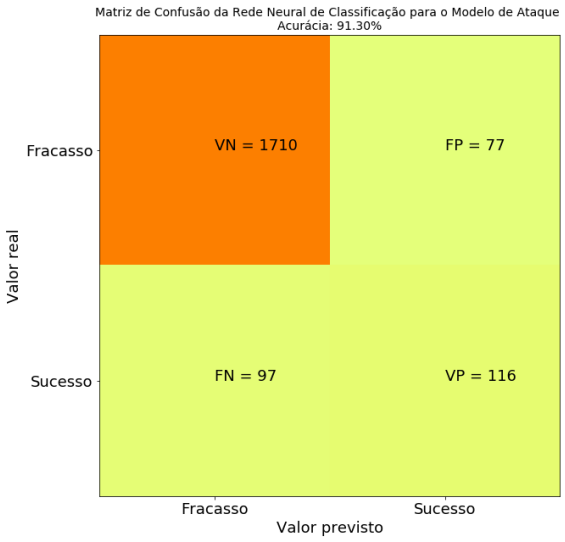
(b) 2ª amostragem



(c) 3ª amostragem

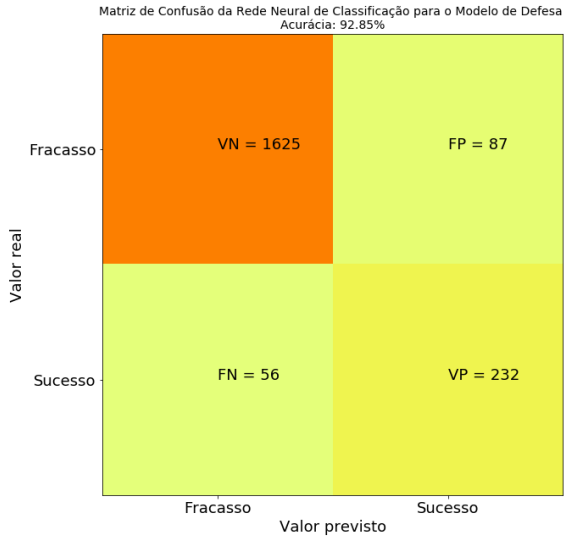


(d) 4ª amostragem

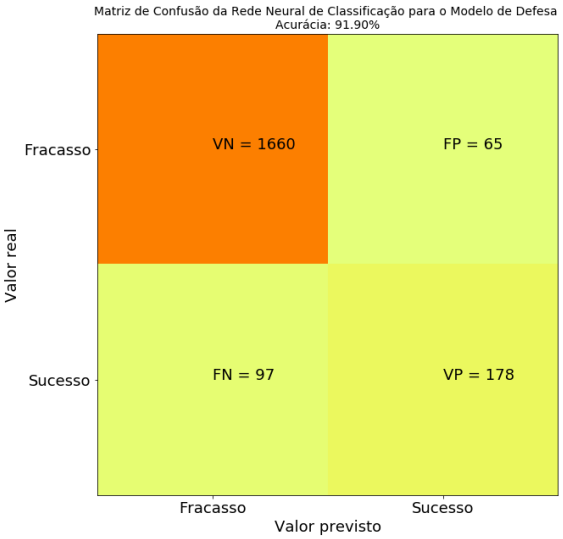


(e) 5ª amostragem

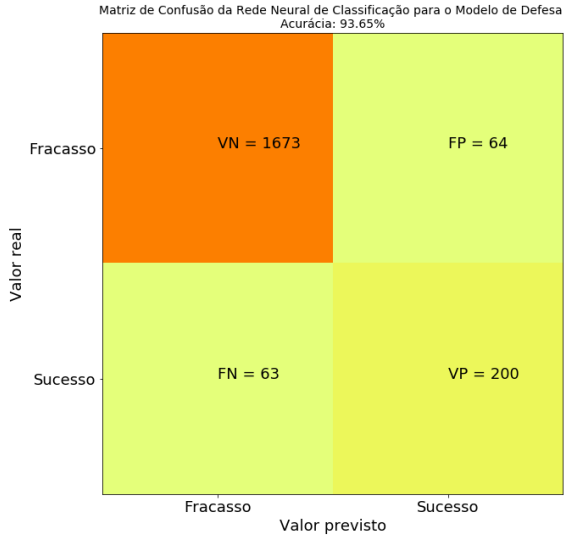
FIGURA 4.4 – Matrizes de confusão de redes neurais artificiais de ataque chegando a 10 metros.



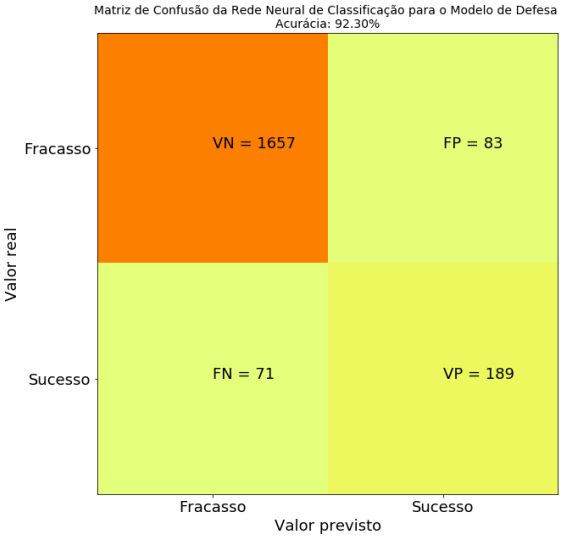
(a) 1ª amostragem



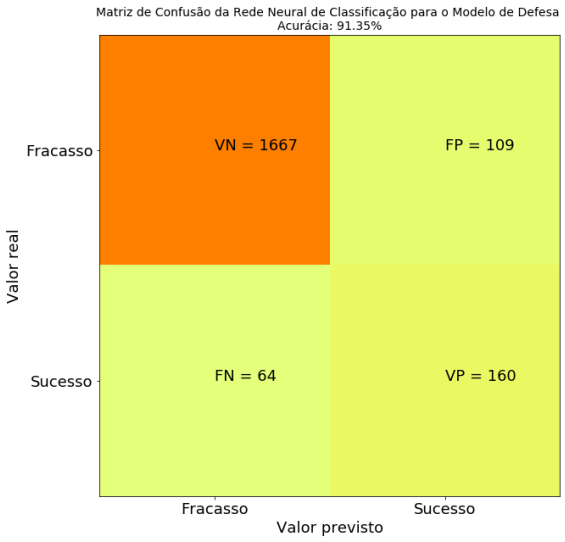
(b) 2ª amostragem



(c) 3ª amostragem



(d) 4ª amostragem



(e) 5ª amostragem

FIGURA 4.5 – Matrizes de confusão de redes neurais artificiais de defesa chegando a 10 metros.

Para a situação do modelo de combate aéreo além do alcance visual analisado, o algoritmo de aprendizado de máquina pode prever 0 ou 1 e cada previsão pode ter sido 0 ou 1. Observa-se que nas duas matrizes de confusão a maioria das previsões recai na linha diagonal da matriz (que são previsões corretas). Ou seja, o modelo prever, em grande parte dos casos analisados, valores corretos para as definições de sucesso ou fracasso.

4.2.2.2 Míssil atingindo a distância de 10.000 metros do alvo

Na segunda situação proposta foi utilizado 10.000 metros como fator determinante de sucesso pois esta é, de acordo com o modelo de míssil modelado no estudo, a distância mínima para ativar os sensores de busca ou *seeker*, que permite detectar e identificar o alvo e guiar o míssil até ele. Evidentemente, semelhante ao primeiro estudo de caso analisado, esse valor é aproximado dado que essa distância depende de inúmeros outros fatores e não pode ser determinada de forma tão determinística.

Esse estudo de caso representa situações em que se deseja criar uma situação de ameaça ao inimigo, não necessariamente com o objetivo de abate total. A situação de um míssil lançado contra uma aeronave inimiga conseguir ativar o *seeker*, irá gerar uma situação de preocupação com a sobrevivência por parte da aeronave alvo. O RWR da aeronave inimiga irá receber o sinal de que um míssil ativo está em sua direção e isso irá provocar a realização, de forma imediata, de uma possível manobra defensiva para garantia da sobrevivência. Este tipo de manobra pode ser usada em cenários operacionais para realizar uma mudança de rota da aeronave oponente ou para destacar as intenções hostis que determinado grupo está adotando em um combate aéreo além do alcance visual.

A partir dessas informações, todas as distâncias obtidas nas saídas das simulações foram transformadas de variáveis numéricas para variáveis categóricas, onde para distâncias menores que 10.000 metros assumem valor 1 e para distâncias maiores que 10.000 metros assumem valor 0. A Tabela 4.9 demonstra a descrição das saídas, analogamente ao caso anterior, baseada na classificação de sucesso e fracasso, para esse estudo de caso de acordo com as quantidades de vezes que cada um ocorre.

TABELA 4.9 – Descrição das saídas no estudo de caso do míssil atingindo 10.000 metros.

Tipo de modelo	**Número de saídas 0 (fracasso)**	**Número de saídas 1 (sucesso)**
Ataque	6034	3966
Defesa	5980	4020

As Tabelas 4.10 e 4.11 demonstram, respectivamente, as redes neurais modeladas para ataque (dist_BM_RA) e defesa (dist_BM_RA), considerando a proposta de análise escolhida, sempre tomando como referência a aeronave azul na simulação. Para esse estudo

de caso específico serão analisadas novamente somente as amostras de 10.000 simulações, visto que se mostraram as com melhores resultados em todas as análises até então.

TABELA 4.10 – Otimização das redes neurais artificiais de ataque para o estudo de caso do míssil atingindo distância mínima de 10.000 metros do alvo.

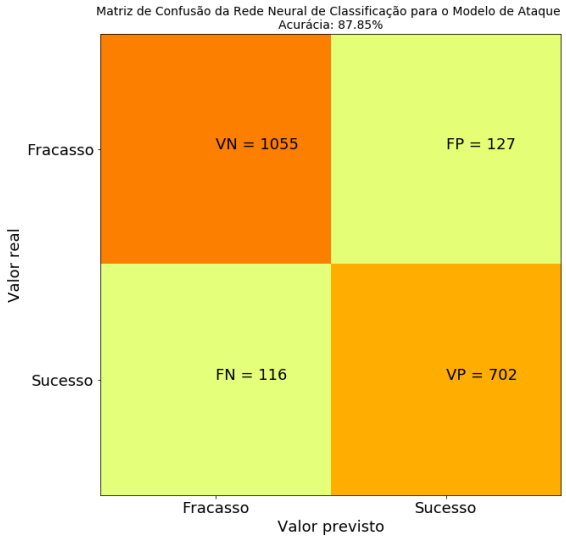
ID	F. de ativação	T. de aprendizagem inicial	Alg. de otimização	Nº neurônios das camadas ocultas	Acurácia com validação cruzada *k-fold*
1	Sigmoide	0,005	SGD	(10,10)	0,8390
2	TanH	0,001	SGD	(10,10)	0,8415
3	ReLU	0,001	SGD	(10,10)	0,8380
4	ReLU	0,001	L-BFGS	(10,10)	0,8450
5	ReLU	0,001	ADAM	(10,10)	0,8510
6	ReLU	0,001	ADAM	(15,15)	0,8465
7	ReLU	0,001	ADAM	(25,25)	0,8520
8	ReLU	0,001	ADAM	(30,30)	0,8425
9	**ReLU**	**0,001**	**ADAM**	**(19,10)**	**0,8551**
10	ReLU	0,00001	ADAM	(35,10)	0,8525
11	ReLU	0,001	ADAM	(25,10)	0,8515
12	ReLU	0,001	ADAM	(25,15)	0,8490
13	Sigmoide	0,0001	ADAM	(25,15)	0,8400
14	ReLU	0,0001	SGD	(25,15)	0,8320
15	ReLU	0,0001	L-BFGS	(25,15)	0,8230
16	ReLU	0,001	ADAM	(100,100)	0,8410
17	ReLU	0,0001	ADAM	(500,25)	0,8460
18	ReLU	0,001	ADAM	(1000,1000)	0,8495
19	TanH	0,001	ADAM	(22,10)	0,8486
20	Sigmoide	0,1	ADAM	(19,11)	0,8464

TABELA 4.11 – Otimização das redes neurais artificiais de defesa para o estudo de caso do míssil atingindo distância mínima de 10.000 metros do alvo.

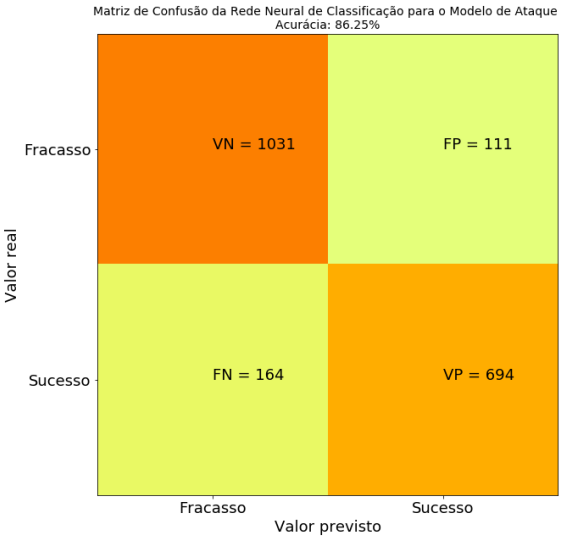
ID	F. de ativação	T. de aprendizagem inicial	Alg. de otimização	Nº neurônios das camadas ocultas	Acurácia com validação cruzada *k-fold*
1	ReLU	0,01	ADAM	(15,20)	0,8445
2	ReLU	0,001	ADAM	(35,35)	0,8400
3	ReLU	0,001	ADAM	(25,25)	0,8540
4	ReLU	0,0001	ADAM	(40,35)	0,8515
5	Sigmoide	0,01	ADAM	(35,35)	0,8370
6	TanH	0,0001	ADAM	(35,25)	0,8310
7	ReLU	0,001	ADAM	(30,30)	0,8475
8	**ReLU**	**0,001**	**ADAM**	**(19,10)**	**0,8617**
9	ReLU	0,001	ADAM	(35,10)	0,8465
10	ReLU	0,01	ADAM	(15,20)	0,8545
11	ReLU	0,001	ADAM	(25,10)	0,8484
12	ReLU	0,001	ADAM	(25,15)	0,8390
13	Sigmoide	0,0001	ADAM	(25,15)	0,8503
14	ReLU	0,0001	SGD	(25,15)	0,8430
15	ReLU	0,0001	L-BFGS	(25,15)	0,8421
16	ReLU	0,001	ADAM	(100,100)	0,8445
17	ReLU	0,0001	ADAM	(500,25)	0,8556
18	ReLU	0,001	ADAM	(1000,1000)	0,8543
19	TanH	0,001	ADAM	(22,10)	0,8599
20	Sigmoide	0,1	ADAM	(19,11)	0,8587

Para as redes neurais artificiais de classificação para os modelos de ataque e defesa foram obtidos, respectivamente valores ótimos de 85,51% e 86,17% de acurácia do modelo em relação aos valores reais. A utilização da validação cruzada em 5 camadas foi utilizada novamente, semelhante aos casos anteriores analisados.

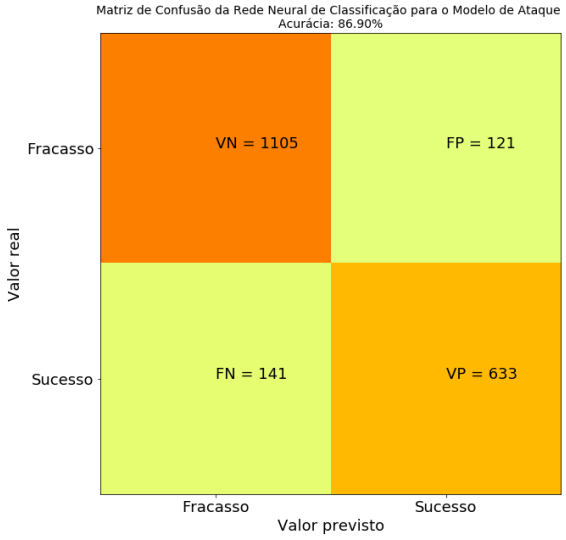
Analogamente ao estudo de caso anterior, foram calculadas ainda as matrizes de confusão das redes neurais artificiais de classificação para os modelos de ataque e defesa com as 5 divisões dos conjuntos de dados utilizados na validação cruzada *k-fold*. As definições dadas no caso anterior para as matrizes de confusão também são aplicadas a esse estudo de caso. As Figuras 4.6 e 4.7 demonstram as matrizes de confusão calculadas para os modelos de ataque e defesa no caso do míssil atingindo a distância de 10.000 metros.



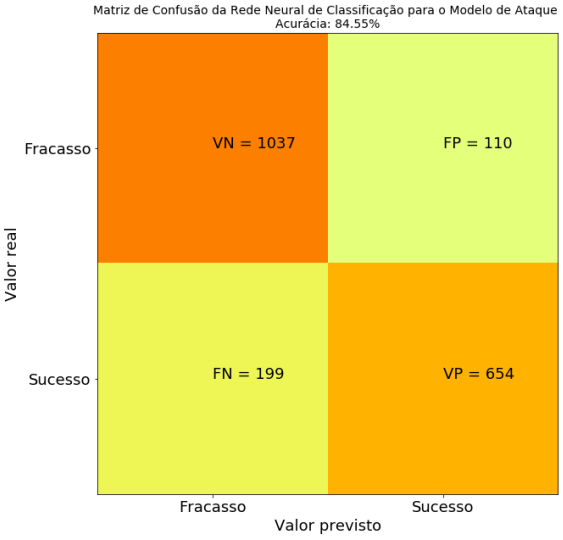
(a) 1ª amostragem



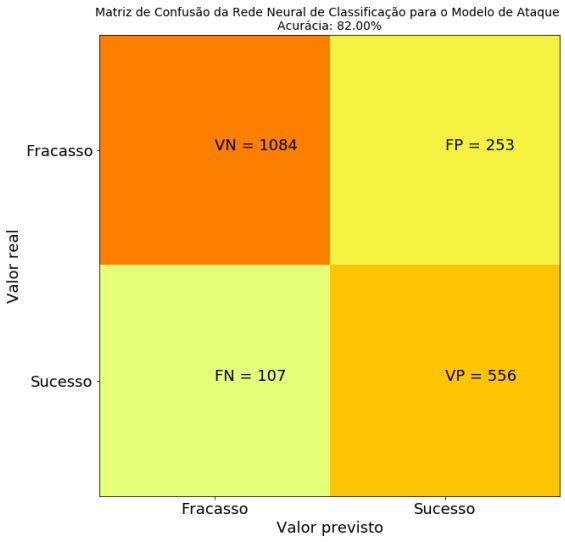
(b) 2ª amostragem



(c) 3ª amostragem

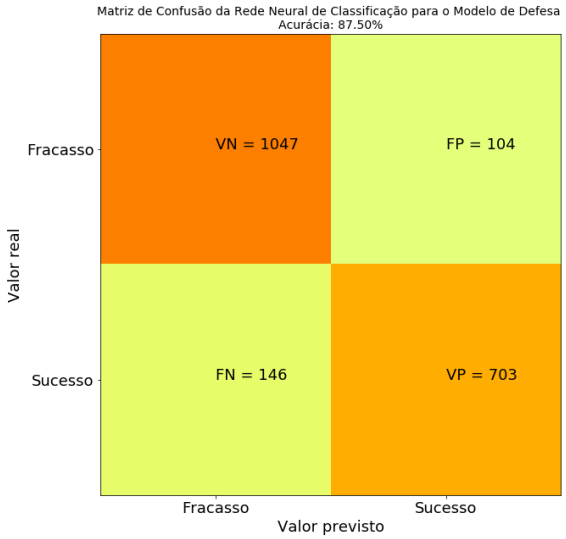


(d) 4ª amostragem

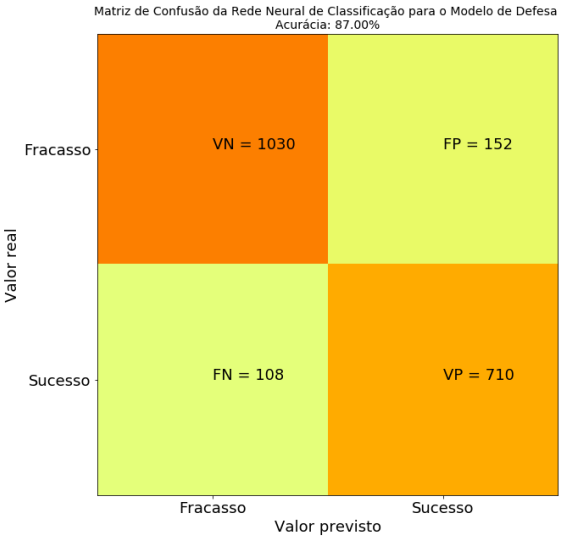


(e) 5ª amostragem

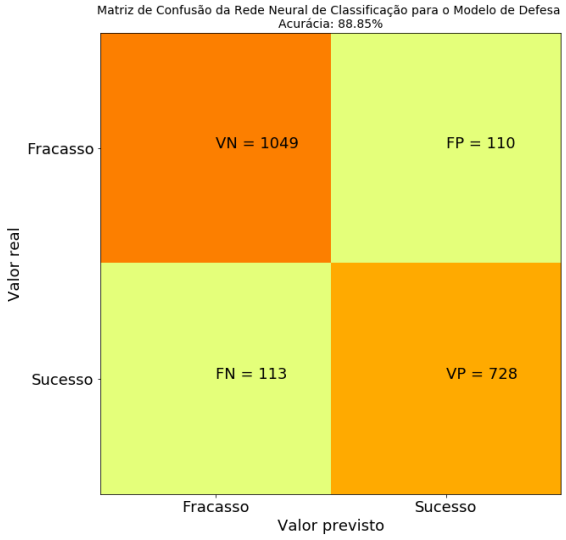
FIGURA 4.6 – Matrizes de confusão de redes neurais artificiais de ataque chegando a 10.000 metros.



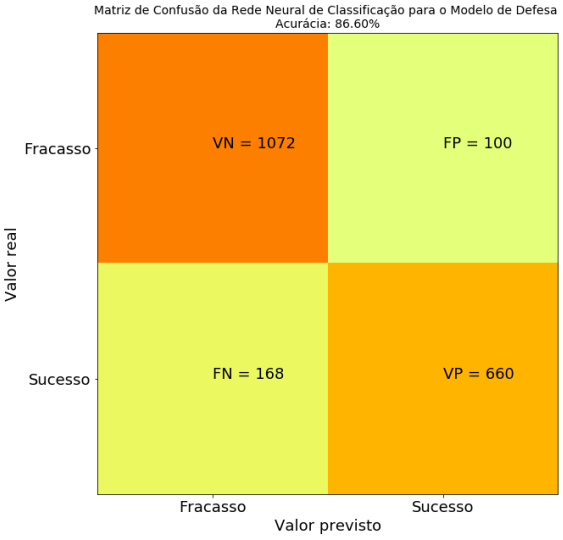
(a) 1ª amostragem



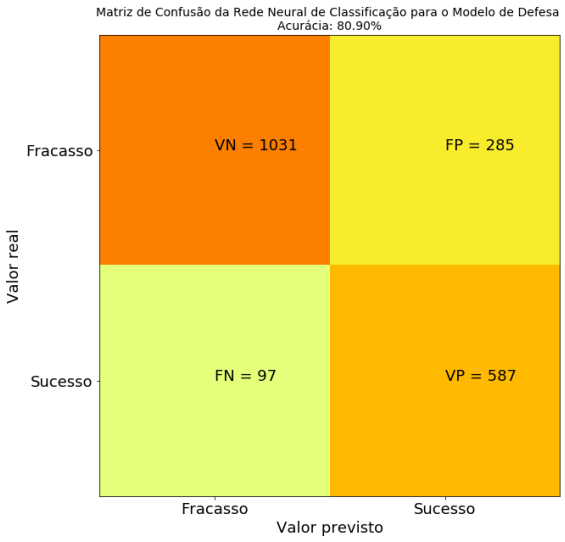
(b) 2ª amostragem



(c) 3ª amostragem



(d) 4ª amostragem



(e) 5ª amostragem

FIGURA 4.7 – Matrizes de confusão de redes neurais artificiais de defesa chegando a 10.000 metros.

4.2.3 Modelo de redes neurais artificiais de regressão

A modelagem do combate aéreo além do alcance visual por meio de redes neurais artificiais de regressão permite uma maior autonomia para definição de estudo de caso que se deseja analisar. Na subseção anterior foram vistos estudos de caso para o míssil atingindo 10 e 10.000 metros de distância tanto em termos de modelos de ataque como defesa. Nesta subseção, propõe-se a utilização de RNA's de regressão, ou seja, que permitem uma saída numérica da distância mínima em relação ao alvo atingida pelo míssil em cenários ofensivos e defensivos. As Tabelas 4.12 e 4.13 demonstram as arquiteturas propostas de redes neurais artificiais de regressão para os casos de ataque e defesa, sempre tomando como referência a aeronave azul, e foram escolhidas como métricas de desempenho o RMSE e o Coeficiente de Determinação (R^2).

TABELA 4.12 – Otimização das redes neurais artificiais de regressão de ataque.

ID	F. de ativação	T. de aprendizagem inicial	Alg. de otimização	Nº neurônios das camadas ocultas	RMSE	R^2
1	Sigmoide	0,01	L-BFGS	(15,5)	0,1301	0,6379
2	Sigmoide	0,1	SGD	(5,5)	0,1563	0,4826
3	Sigmoide	0,01	ADAM	(10,5)	0,1286	0,6441
4	Sigmoide	0,001	ADAM	(10,10)	0,1439	0,5575
5	Sigmoide	0,0001	ADAM	(30,30)	0,1577	0,4671
6	TanH	0,1	L-BFGS	(10,5)	0,1437	0,5231
7	TanH	0,001	SGD	(3,2)	0,1497	0,5000
8	TanH	0,01	ADAM	(9,5)	0,1419	0,5559
9	TanH	0,01	ADAM	(14,3)	0,1481	0,6759
10	TanH	0,001	ADAM	(36,10)	0,1359	0,5949
11	ReLU	0,001	L-BFGS	(5,5)	0,1455	0,5260
12	ReLU	0,01	SGD	(10,5)	0,1516	0,4970
13	ReLU	0,01	ADAM	(15,5)	0,1439	0,5701
14	ReLU	0,001	ADAM	(10,4)	0,1498	0,4904
15	ReLU	0,001	ADAM	(50,10)	0,1290	0,6364
16	ReLU	0,001	SGD	(100,50)	0,1502	0,5132
17	TanH	0,001	ADAM	(150,20)	0,1380	0,5819
18	ReLU	0,0001	ADAM	(14,3)	0,1497	0,5344
19	ReLU	0,001	ADAM	(50,5)	0,1479	0,5212
20	**ReLU**	**0,01**	**ADAM**	**(45,25)**	**0,1184**	**0,6929**

TABELA 4.13 – Otimização das redes neurais artificiais de regressão de defesa.

ID	F. de ativação	T. de aprendizagem inicial	Alg. de otimização	Nº neurônios das camadas ocultas	RMSE	R^2
1	Sigmoide	0,01	L-BFGS	(15,5)	0,1403	0,6406
2	Sigmoide	0,1	SGD	(5,5)	0,1730	0,4812
3	Sigmoide	0,005	ADAM	(10,5)	0,1374	0,6630
4	Sigmoide	0,001	ADAM	(10,10)	0,1626	0,5399
5	Sigmoide	0,0001	ADAM	(30,30)	0,1765	0,4381
6	TanH	0,1	L-BFGS	(10,5)	0,1281	0,7116
7	TanH	0,001	SGD	(3,2)	0,1763	0,4738
8	TanH	0,005	ADAM	(9,5)	0,1590	0,5602
9	TanH	0,01	ADAM	(14,3)	0,1643	0,5280
10	TanH	0,001	ADAM	(36,10)	0,1376	0,6721
11	ReLU	0,001	L-BFGS	(5,5)	0,1422	0,6460
12	ReLU	0,01	SGD	(10,5)	0,1717	0,4726
13	**ReLU**	**0,01**	**ADAM**	**(15,5)**	**0,1280**	**0,7163**
14	ReLU	0,001	ADAM	(10,4)	0,1587	0,5375
15	ReLU	0,001	ADAM	(50,10)	0,1518	0,5872
16	ReLU	0,001	SGD	(100,50)	0,1685	0,4977
17	TanH	0,001	ADAM	(150,20)	0,1580	0,5583
18	ReLU	0,0001	ADAM	(14,3)	0,1672	0,5167
19	ReLU	0,001	ADAM	(50,5)	0,1569	0,5743
20	ReLU	0,01	ADAM	(45,25)	0,1327	0,6903

Nas duas tabelas, referentes as redes neurais artificiais de regressão, encontram-se valores ótimos de RMSE e o Coeficiente de Determinação (R^2), que foram as métricas de desempenho utilizadas, como 0,1184 e 69,29% e 0,1280 e 71,53% respectivamente para modelos de ataque e defesa.

Para a análise das redes neurais de regressão foram utilizados a proporção de 75%, 15% e 15% para divisão dos conjuntos de dados de 10.000 amostragens em dados de treinamento, de validação e de teste. Observa-se que novamente as funções de ativação ReLU e os algoritmos de otimização ADAM se mostraram os melhores para serem usados em treinamento. Em boa parte dos casos, os números de neurônios utilizados ficaram com valores próximos das entradas e saídas, conforme descrito no Capítulo 3. Contudo, com o intuito de se observar o comportamento dos treinamentos das redes neurais em diferentes situações, os valores dos números de neurônios foram extrapolados, em certos casos, para valores diferentes do número de neurônios das entradas e saídas. Nesses casos, por vezes, resultados mais satisfatórios foram obtidos quando se analisando as métricas de desempenho escolhidas.

Poderiam ter sido encontrados valores melhores de RMSE e R^2 caso mais simulações tivessem sido utilizadas para treinamento das redes neurais de regressão. Devido a grande quantidade de variáveis de entrada e por se tratar de uma regressão, a quantidade de dados é essencial para um bom treinamento das redes neurais.O tempo necessário para realizar tais simulações no simulador de combate aéreo além do alcance visual do AEROGRAF foi um limitante para se obter mais dados.

Não obstante, a construção de redes neurais de regressão permite uma maior flexibilidade para se obter outros estudos de caso a serem analisados em cenários BVR que demonstra a versatilidade que esse tipo de algoritmo de aprendizagem consegue fornecer. Além disso, esse tipo de rede fornece uma saída numérica que torna o modelo mais preciso possibilitando análises mais profundas de todas as fases de voo em um combate aéreo além do alcance visual. A saída numérica permite verificar uma maior influência que cada variável de entrada está realizando no resultado final da simulação do cenário BVR. As redes neurais artificiais de regressão permitem que sejam adotadas outras variáveis numéricas para valores de saída que fazem com que sejam analisadas outras métricas do combate aéreo além do alcance visual, conduzindo a adoção de novas análises que norteiam o cenário operacional analisado. Além disso, mais que do investigar saídas numéricas isoladas, é possível a criação de índices que representem uma combinação de variáveis de saída, que possam descrever, de forma mais eficiente e completa, um determinado fator que deseja de observar durante o combate BVR para melhoria da tomada de decisão em voo em tempo real.

A seguir, as Figuras 4.8, 4.9, 4.10 e 4.11 demonstram, respectivamente, paras os modelos ofensivos e defensivos, os gráficos de dispersão e *boxplot* entre os valores reais e os valores

previstos através das redes neurais artificiais dos modelos de ataque e defesa que foram descritos para o cenário do combate aéreo além do alcance visual desta dissertação.

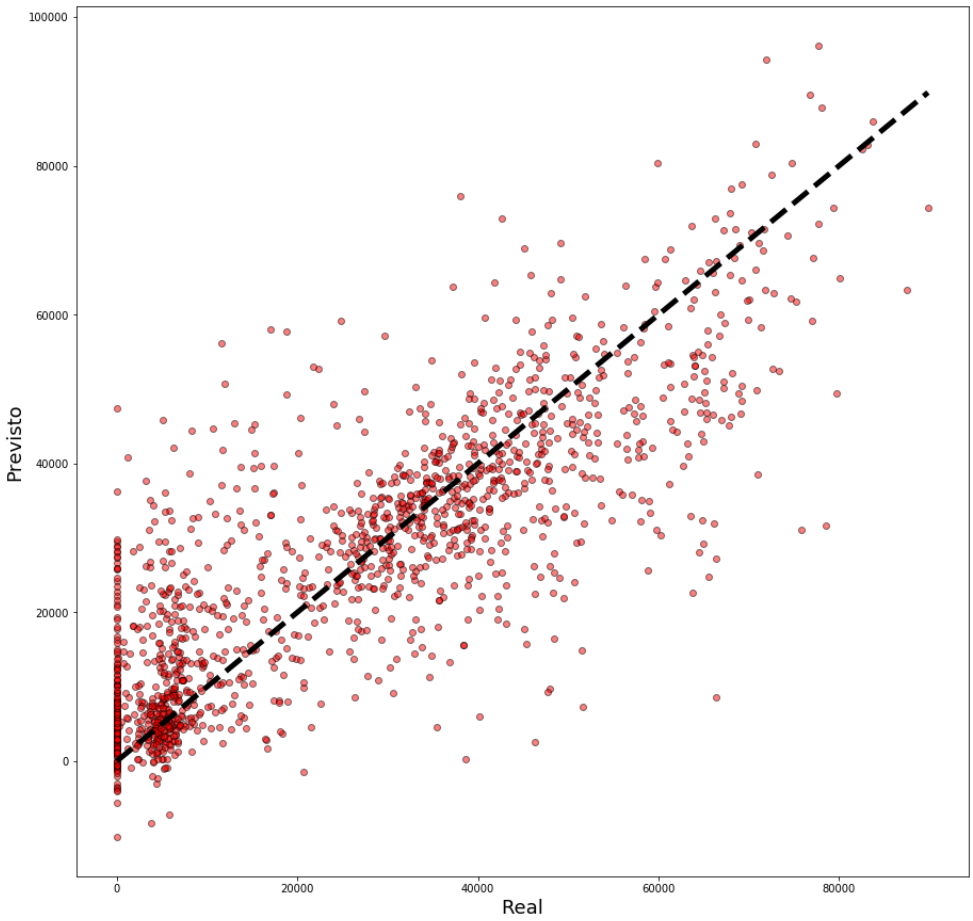


FIGURA 4.8 – Relação entre os valores previstos e reais para redes neurais artificiais de regressão para análises de modelos ofensivos.

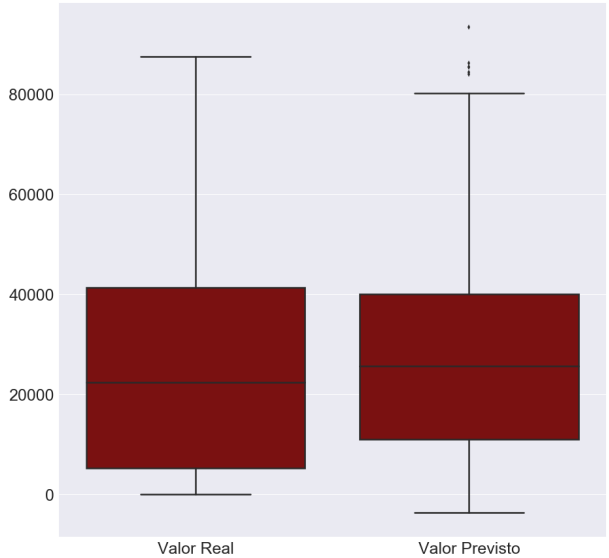


FIGURA 4.9 – Gráficos *boxplot* dos valores previstos e reais para redes neurais artificiais de regressão para análises de modelos ofensivos.

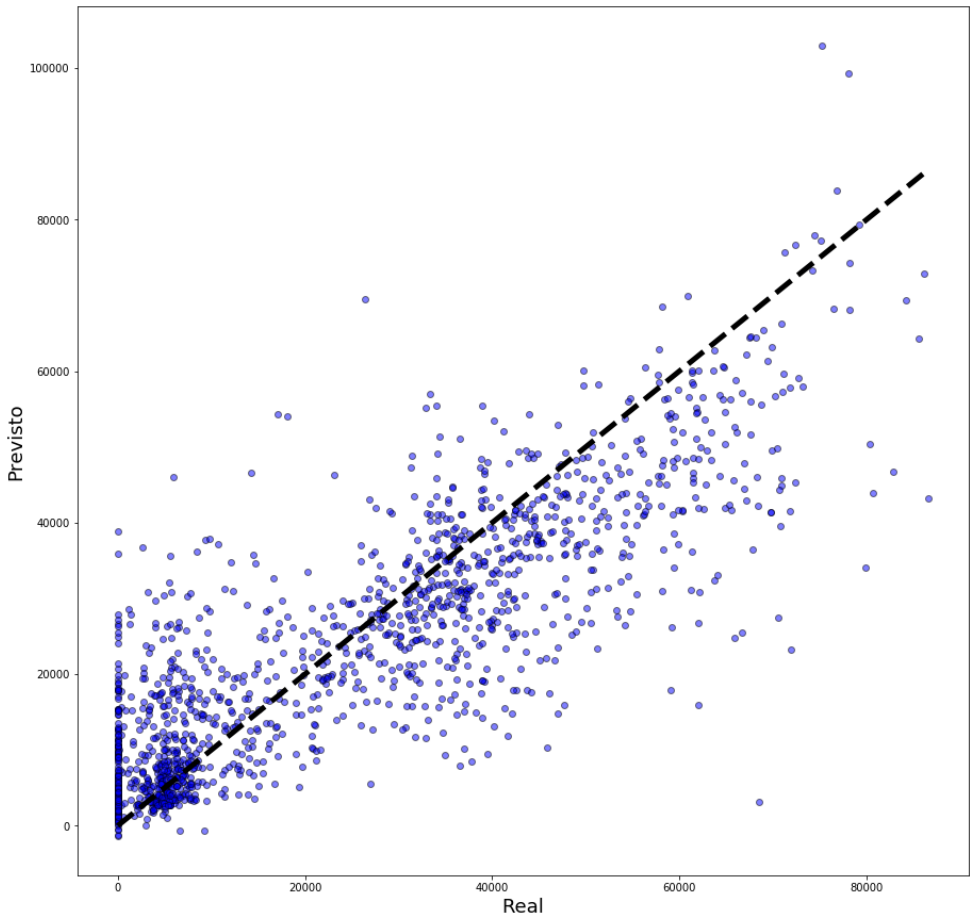


FIGURA 4.10 – Relação entre os valores previstos e reais para redes neurais artificiais de regressão para análises de modelos defensivos.

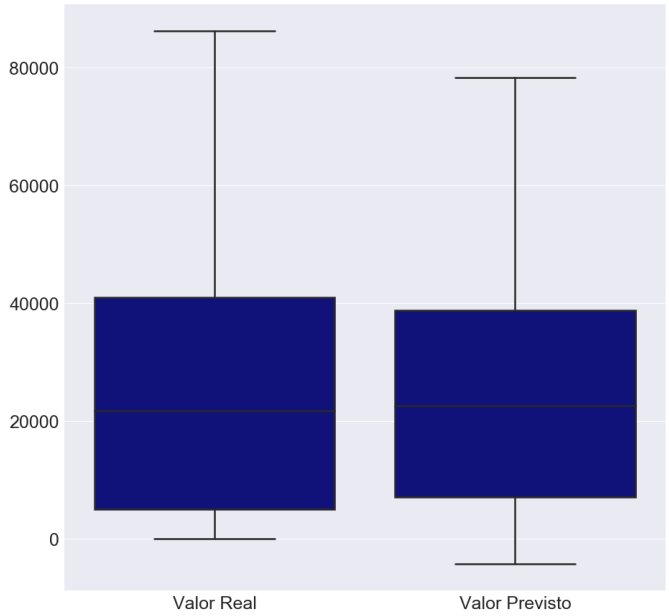


FIGURA 4.11 – Gráficos *boxplot* dos valores previstos e reais para redes neurais artificiais de regressão para análises de modelos defensivos.

4.2.4 Apoio à decisão para o combate aéreo além do alcance visual

Nesta subseção é realizada uma demonstração da proposta de apoio à decisão para o combate além do alcance visual feita neste estudo que corroboram com as análises feitas anteriormente. Dessa forma, é proposto um sistema que se baseia na concepção de um dispositivo de melhoria da consciência situacional do piloto BVR. A Figura 4.12 demonstra um esboço do que seria a interface gráfica do sistema de apoio à decisão proposto na presente dissertação.

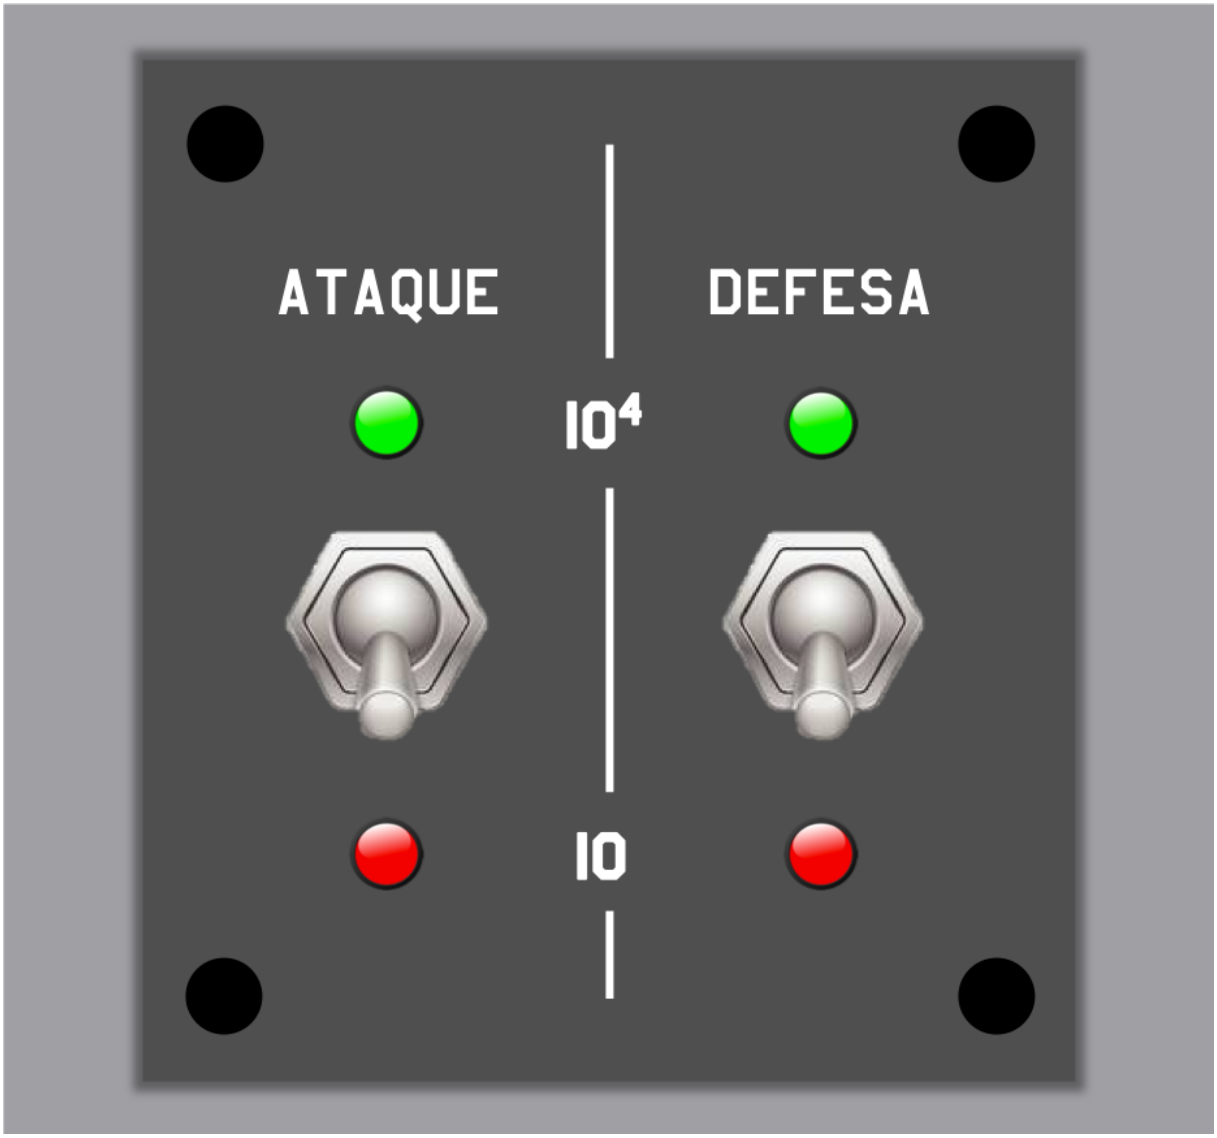


FIGURA 4.12 – Dispositivo de melhoria da consciência situacional do piloto de combate aéreo além do alcance visual.

O dispositivo é separado em duas partes: a primeira referente ao modelo de ataque, correspondente ao lado esquerdo do dispositivo, que diz respeito as análises dos mísseis utilizados da aeronave base (azul) contra a aeronave inimiga (vermelha) e a segunda

referente ao modelo de defesa, correspondente ao lado direito do dispositivo, que diz respeito as análises dos mísseis utilizados pela aeronave inimiga contra a aeronave base. Observa-se ainda a existência de duas chaves que dizem respeito a escolha do estudo de caso que se deseja configurar o dispositivo. Os estudos de caso, conforme analisado anteriormente, referem-se as distâncias atingidas pelos mísseis ao final da simulação. Foram analisadas as distâncias de 10 e 10.000 metros que dizem respeito, intrinsecamente, ao tipo de objetivo que se deseja em combate e que grau de risco que os pilotos estão dispostos a adotar.

A escolha do estudo de caso de 10 metros demonstra uma intenção de destruição da aeronave, o que é esperado na maioria dos combates. Contudo, por vezes, apenas mudar a rota da aeronave inimiga ou demonstrar um grau de ofensividade é suficiente para determinado tipo de missão, portanto, o estudo de caso para o míssil atingindo 10.000 metros poderia ser utilizado para atender esse tipo de demanda. Analisando de forma conservadora, os modelos de defesa, de forma geral, estarão definidos para 10 metros, pois não é possível determinar com certeza plena as ações das aeronaves inimigas. Em todo caso, a garantia de sobrevivência dos pilotos é algo bastante importante e deve ser levado como prioridade, por ser tratar de aeronaves tripuladas.

A construção física do sistema de apoio à decisão para o combate BVR estaria associado aos pesos sinápticos das redes neurais artificiais que obtiverem as melhores métricas de desempenho nos testes realizados nesse estudo. O dispositivo precisa estar conectado aos sensores da aeronave para extrair, em tempo real, as variáveis de entrada que foram escolhidas para o modelo de aprendizagem de máquina do estudo realizado. As luzes vermelha e verde, que indicam a situação do piloto em combate, de forma qualitativa, podem vir também acompanhadas de pequenos sinais sonoros para fornecer um suporte à tomada de decisão mais assertiva quando determinado estado se mantiver constante por um determinado período pré-estabelecido nas configurações técnicas do dispositivo.

Avalia-se que, Veículos Aéreos Não Tripulados (VANT), futuramente, poderiam ser utilizados de forma mais frequente para combates aéreos além do alcance visual e, certamente, posições de combate mais agressivas, com a ajuda de sistemas de inteligência artificial com aprendizagens mais robustas, poderiam ser utilizadas para cumprimento de diversas missões da FAB, sem riscos ao piloto. Alguns trabalhos recentes, como os de Floyd *et al.* (2017), que descrevem o *Tactical Battle Manager* (TBM), conforme descrito na Seção 2.6. Trabalhos deste tipo estão se desenvolvem cada vez mais em pesquisas recentes e tem uma grande tendência de trazer mais melhores para o combate BVR moderno.

As técnicas de inteligência artificial atuais aplicadas a cenários operacionais já permitem que as máquinas, com seus respectivos algoritmos de aprendizagem, derrotem o ser humano em um combate aéreo simulado. Mais que apenas vencer, o agente inteligente torna-se um

melhor jogador no combate aéreo virtual a cada simulação, pois a cada novo duelo a sua capacidade preditiva melhora.

O sistema de apoio à decisão desenvolvido nesta dissertação e em outros trabalhos da atualidade, conduzidos pelo aprofundamento nos estudos de *machine learning*, precedem ao estado em que a simulação construtiva poderá prever o resultado final de combates aéreos com uma acurácia bastante significativa que permita uma melhor condução das decisões tomadas pelo piloto.

5 Considerações finais

Neste capítulo, o último desta dissertação, são apresentadas as reflexões finais acerca do trabalho aqui desenvolvido. Inicialmente, na Seção 5.1, foi apresentada uma síntese do trabalho, sendo destacados os pontos metodológicos mais relevantes e, principalmente, os resultados mais pertinentes. Ao final, na Seção 5.2, foram apresentadas as principais limitações do trabalho, no que diz respeito à metodologia utilizado nesta pesquisa.

O intuito dessa discussão é orientar o leitor na leitura crítica desta dissertação, além de restringir, de maneira clara e objetiva, o contexto de aplicação aqui considerado. Adicionalmente, são sugeridos direcionamentos futuros para a pesquisa aqui desenvolvida, na esperança de que outros pesquisadores venham complementar trabalhos relacionados ao tema.

5.1 Síntese

A presente dissertação apresentou um modelo de aprendizado de máquina através de redes neurais artificiais para desenvolvimento de um dispositivo de melhoria da consciência situacional do piloto em combate aéreo além do alcance visual.

Ao se analisar a aplicação demonstrada, vê-se que o modelo proposto foi capaz de representar a dinâmica básica do combate BVR, permitindo ao analista avaliar os parâmetros que influenciam no decorrer do confronto entre as aeronaves. Além disso, é possível fornecer ao piloto uma estimativa de sua performance em se tratando de ataque ou defesa no combate BVR. Essa perspectiva de como está ocorrendo o combate e a qualidade das ações tomadas pelo piloto são informadas através desse sistema de apoio à decisão. Observa-se, contudo, que tal dispositivo não informa qual melhor atitude a ser realizada, e sim, mensura a qualidade das ações tomadas pelo piloto, através da modelagem proposta, quando observando o comportamento das simulações de combate aéreo além do alcance visual.

A modelagem considerou tanto as características da aeronave e dos armamentos possuídos, quanto as crenças a respeito da aeronave oponente. Também foi considerada

a filosofia de tiro estabelecida para a aeronave, bem como o nível de aversão ao risco do piloto. Todos estes fatores contribuíram para o desenvolvimento de uma ferramenta de grande valia para o setor operacional da FAB, bem como para pesquisadores que desejem ver os impactos de novas tecnologias no cenário BVR, já que todos os sistemas utilizados no *plugin* da plataforma AEROGRAF são parametrizados, possibilitando a rápida inserção de melhorias tecnológicas.

A modelagem das redes neurais artificiais foi realizada para a situação do míssil atingindo as distâncias mínimas de 10 e 10.000 metros do alvo, conforme detalhado no Capítulo 4. Foi realizado uma análise inicial por meio de regressão logística, que se trata de uma rede neural de apenas uma camada interna e função de ativação sigmoidal, e se demostrou com resultados satisfatórios para a modelagem proposta que obteve, em alguns casos analisados, valores de acurácia superiores a 90% e 80% para os estudos de caso do míssil atingindo 10 e 10.000 metros, respectivamente. Esses valores foram alcançados através de técnicas de validação cruzada *k-fold*.

Em seguida, foram realizadas as modelagens de redes neurais artificiais de classificação com duas camadas ocultas, que dessa forma se comportam como um aproximador universal de funções. Os números de amostras utilizadas, funções de ativação, número de neurônios e os algoritmos de otimização foram avaliados e sua performance medida por meio da acurácia e das matrizes de confusão. As melhores redes de ataque e defesa para os dois estudos de caso analisados foram escolhidas para serem incorporadas no dispositivo de melhoria da consciência situacional.

A seguir, realizou-se a construção das redes neurais artificiais de regressão para análises mais robustas com outros possíveis estudos de caso que sejam de interesse no cenário BVR. Obteve-se valores próximos de 70% para os coeficientes de determinação com valores baixos de RMSE associados (entre $0,11$ e $0,12$). Mesmo com poucas amostras utilizadas para as análises, foi possível a construção de um modelo satisfatório de regressão que poderia representar o simulador de maneira coerente, fornecendo respostas rápidas dos resultados finais das simulações de combate aéreo além do alcance visual que podem fornecer ao piloto uma melhora de sua consciência situacional em tempo real.

Dessa forma, foi possível, através de dados obtidos por meio de simulações, contribuir para melhoria da qualidade do voo em um combate aéreo do tipo BVR. Esse tipo de contribuição ajuda na efetividade das missões de ataque, de modo que armamentos não sejam utilizados de forma errônea e descuidada, e contribui para missões de defesa, em que a sobrevivência do piloto é um fator determinante e, nesse caso, diminui o número de aeronaves abatidas em combates reais.

5.2 Limitações e pesquisas futuras

Os modelos matemáticos propostos na construção do simulador de combate BVR, apesar de já terem se aproximado da realidade vista em missões reais de combate aéreo além do alcance visual, são, em grande parte, determinísticos, o que gera menor variabilidade para a simulação. Propõe-se, como extensão deste trabalho, utilizar modelos mais estocásticos para a definição dos limites apresentados, bem como nos critérios de sucesso do míssil. Isso pode ser também feito por aplicação de lógica *fuzzy*, ou lógica difusa (ZADEH, 1965), possibilitando um julgamento mais próximo ao observado nos seres humanos.

A lógica difusa pode ser utilizada para tornar os valores limites dos estudos de caso analisados, o míssil atingindo no mínimo 10 e 10.000 metros, não apenas variáveis booleanas (0 ou 1). Ou seja, ao invés de acima ou abaixo do valor limite escolhido, os valores das saídas adotarem 0 ou 1, ou ainda, fracasso ou sucesso, poderia ser utilizada a lógica *fuzzy* para ter sucessos ou fracassos parciais. Isso tornaria o modelo mais verdadeiro com a realidade.

Além disso, para uma melhor percepção das ações da aeronave inimiga poderia ter sido utilizada a teoria dos jogos de forma profunda para análises do comportamento esperado do oponente. No combate aéreo as percepções que são mostradas pelo piloto e aquelas que o adversário demonstra podem influenciar até mesmo os pilotos mais experientes. Trata-se, portanto, de um jogo em que fazer transparecer uma ação, por vezes, pode significar muito mais do que uma ação propriamente dita. Um exemplo de tais ações seria realizar uma manobra evasiva *cranking* mesmo sem ter realizado, efetivamente, o lançamento de um míssil contra o oponente. Isso poderia induzir o alvo a tomar mais cautela, pois, possivelmente, um míssil inimigo foi disparado em sua direção.

Adicionalmente, sugere-se a aplicação do modelo a cenários com múltiplas aeronaves com possibilidade de carregamento de vários mísseis, realizando as alterações necessárias, que incluem elementos de coordenação entre os pilotos simulados e com mais mísseis disponíveis. A coordenação entre as aeronaves tornaria a previsão mais complexa, contudo, o modelo seria mais realista e poderia ser melhor utilizado para previsões de resultados de combates aéreos. No modelo adotado na presente dissertação cada aeronave tinha a mesma performance, carregando um único míssil e agindo de forma independente sem outra aeronave próxima para fornecer algum suporte.

O estudo desenvolvido guarda importantes limitações referente ao desenvolvimento da arquitetura e treinamento das redes neurais artificiais. As técnicas de *deep learning*, que estão em grandes desenvolvimentos no presente século, tratam problemas complexos de múltiplas variáveis de maneira mais assertiva e eficiente. Sugere-se, portanto, como trabalhos futuros uma abordagem do tema do estudo por meio de aprendizado profundo

para solução de modelos mais complexos de simulação de combate aéreo além do alcance visual.

Outra limitação desse estudo é o uso de amostras de somente 100, 1.000 e 10.000 simulações. Observou-se, e como já esperado, que quanto maior a quantidade de dados coletados para realização de treinamento, validação e teste, melhor a qualidade do modelo escolhido de aprendizado de máquina supervisionado. Um limitante do trabalho foi o tempo para realização das simulações de combate BVR, de forma, que o valor máximo viável possível de se obter nesse estudo foi de um pouco mais de 10.000 simulações, contando-se a soma dos três conjuntos de dados. Em trabalhos futuros, sugere-se obter uma maior eficiência de resposta do simulador BVR para que os dados de simulação possam ser coletados mais rapidamente, ou ainda, a utilização de máquinas com maior processamento para aumentar a quantidade de dados coletados para análise.

Reconhece-se também como limitação desse trabalho a utilização de redes de classificação baseado em casos específicos de acordo com o tipo de missão de combate que se deseja realizar e de redes neurais de regressão limitadas. Caso fosse possível adquirir mais dados de simulação e técnicas mais avançadas de aprendizado de máquina fossem utilizadas, seria possível construir redes neurais artificiais de regressão mais robustas que representassem melhor o combate BVR e, portanto, obter qualquer tipo de estudo de caso que fosse desejável. Ou seja, para quaisquer valores de entrada adotados nas 36 variáveis de entrada escolhidas, seria obter duas saídas numéricas com as distâncias máximas atingidas pelos mísseis relativas as missões de ataque e defesa, diferentemente do que ocorre em redes de classificação que se obtêm uma variável categórica.

O método de construção das redes neurais artificiais na presente dissertação ocorreu por experimentação, ou seja, os valores dos hiper-parâmetros das RNA's foram testados em inúmeros casos até que fossem encontrados valores otimizados das métricas de desempenho, e assim, encontrar as redes neurais com melhores configurações de representação. Em trabalhos futuros, o uso de heurísticas e meta-heurísticas para definir a quantidade ótima de camadas ocultas e neurônios em cada camada oculta irá otimizar o processo de escolha desse hiper-parâmetros importantes na arquitetura de redes neurais artificiais.

No estudo realizado nesse trabalho foram utilizadas métricas de desempenho para redes neurais artificiais de classificação e de regressão. A escolha de outras métricas poderia aprofundar as análises do desempenho dos modelos adotados. Uma maior complexidade das redes neurais para representar problemas mais robustos poderia prever a escolha de outras métricas para analisar de forma mais assertiva o modelo de aprendizado de máquina proposto.

A determinação das variáveis de entrada (*features*) foi feita baseada no conhecimento especializado dos pilotos de combate aéreo além do alcance visual e na verificação de

outras modelagens já propostas na literatura. Contudo, no modelo proposto, podem existir variáveis que não tenham uma influência relevante no resultado final do modelo de aprendizado de máquina. A eliminação dessas variáveis torna o processo de aprendizado mais simples e eficiente. Sugere-se, portanto, para trabalhos futuros a detecção das variáveis mais relevantes do combate BVR com a inclusão de outras *features* ou a exclusão das que foram propostas nesse estudo por meio de técnicas como *Design of Experiments* (DOE) que permite que vários fatores de entrada sejam manipulados, determinando seu efeito em uma saída (resposta) desejada. Ao manipular várias entradas ao mesmo tempo, o DOE pode identificar interações importantes que podem ser perdidas ao experimentar um fator por vez.

Outra sugestão de futuro direcionamento seria adotar outras métricas de saída dos valores de simulação para serem analisados. Nesse trabalho foram observadas as distâncias que os mísseis lançados contra o alvo e o do alvo contra a aeronave adotada como referência, azul, atingiram no momento final da simulação. Recomenda-se, portanto, o desenvolvimento de estratégias que permitissem a escolha de outras variáveis de saída para obter informações importantes do combate além do alcance visual. Além disso, poderia ser utilizado a combinação de diversas variáveis, formando índices, que demonstram, de forma mais completa, uma determinada característica do cenário BVR que devesse ser analisado para melhorar a consciência situacional do piloto em voo.

Destaca-se ainda que, no presente trabalho de dissertação, foram adotadas várias redes neurais para diferentes saídas escolhidas, tratando dessa forma de um dispositivo de melhoria da consciência situacional em termos de ataque e defesa. Contudo, com técnicas mais avançadas de redes neurais artificiais ou até a associação de diferentes técnicas de aprendizado de máquina, seria possível utilizar uma só rede neural e modelar todo o comportamento do combate aéreo além do alcance visual. A vantagem de se realizar isso é a interação entre as diversas saídas do processo de aprendizado que estariam mais correlacionadas entre si, o que condiz com o combate aéreo real. A conexão entre as redes iria descrever o cenário BVR e prever as possíveis interações entre as diversas variáveis da modelagem deste sistema complexo.

Por fim, destaca-se como maior limitação desta dissertação, o fato do sistema de apoio à decisão não auxiliar o piloto nas tomadas de decisão de forma mais assertiva através da sugestão de ações que devem ser tomadas baseadas em probabilidades de sucesso. Em trabalhos futuros, com o desenvolvimento do modelo utilizado, seria possível além de melhorar a consciência situacional do piloto durante o combate BVR, sugerir as melhores ações a serem tomadas de forma mais específica possível, por exemplo, fornecendo coordenadas de velocidade, angulação e altitude ou até uma própria inteligência artificial que pilote a aeronave de forma autônoma, de modo que o piloto pudesse influenciar apenas quando necessário, por meio do seu instinto e sua experiência como piloto de combate,

as ações a serem adotadas em todas as fases do combate aéreo além do alcance visual. Essa IA, através do processo de aprendizado de máquina, poderia ser treinada através de uma série muito maior de simulações computacionais ou até por algumas manobras de treinamento reais que, dessa forma, poderia extrair, tanto através da modelagem matemática do problema como da experiência operacional do piloto, as melhores ações a serem tomadas em um combate aéreo baseado no cenário específico, modelado por aeronaves amigas e inimigas, que possa representar de forma verossímil o combate aéreo além do alcance visual.

Referências

AERONÁUTICA, C. **MCA 55-52 Manual de combate aéreo com apoio de OCOAM (BVR)**. [S.l.], 2014.

AHLAWAT, N.; GAUTAM, A.; SHARMA, N. Use of Logic Gates to Make Edge Avoider Robot. **International Journal of Information & Computation Technology**, v. 4, n. 6, p. 629–632, 2014.

AKABARI, S.; MENHAJ, M. B.; NIKRAVESH, S. K. **Fuzzy Modeling of Offensive Maneuvers in an Air-to-Air Combat**. [S.l.: s.n.], 2005. 171–172 p.

ANAC. Regulamento brasileiro da aviação civil nº 1, emenda 2. p. 1–22, 2011.

AUSTIN, F.; CARBONE, G.; HINZ, H.; LEWIS, M.; FALCO, M. Game theory for automated maneuvering during air-to-air combat. **Journal of Guidance Control and Dynamics**, 1990.

BABINI, M. **Reconhecimento de padrões lexicais por meio de redes neurais**. Dissertação (Mestrado) — Universidade Estadual Paulista (UNESP), 2006.

BARBOSA, A. T. R. **Mecanismo de Adaptação Baseado Em Redes Neurais Artificiais Para Sistemas Hipermídia Adaptativos**. 123 p. Tese (Doutorado) — Universidade Federal de Santa Catarina, 2004.

BARRETO, J. **Inteligência artificial no limiar do século XXI**. [s.n.], 2001. ISBN 9788590038252. Disponível em: <https://books.google.com.br/books?id=htd0kQEACAAJ>.

BARRON, A. R. Universal Approximation Bounds for Superposition of a Sigmoid Function. **IEEE Transactions on Information Theory**, v. 39, n. 3, p. 930–945, 1993. ISSN 09205691.

BENGIO, Y. Learning Deep Architectures for AI. **Foundations and Trends® in Machine Learning**, v. 2, n. 1, p. 1–127, 2009. ISSN 1935-8237. Disponível em: <http://www.nowpublishers.com/article/Details/MAL-006>.

BIRKMIRE, B. **Weapon Engagement Zone Maximum Launch Range Approximation using a Multilayer Perceptron**. Dissertação (Mestrado) — Wright State University, 2011.

BITTENCOURT, G. **Inteligência artificial: ferramentas e teorias**. Editora da UFSC, 1998. (Série didática). ISBN 9788532801388. Disponível em: <https://books.google.com.br/books?id=AhbhQwAACAAJ>.

BLAKELOCK, J. **Automatic control of aircraft and missiles**. Wiley, 1965. Disponível em: <https://books.google.com.br/books?id=FXFTAAAAMAAJ>.

BORCK, H.; KARNEEB, J.; ALFORD, R.; AHA, D. W. Case-based behavior recognition in beyond visual range air combat. **Proceedings of the Twenty-Eighth Florida Artificial Intelligence Research Society Conference**, n. Article 9, p. 379–384, 2015.

BORGES, A. Desenvolvendo argumentos teóricos a partir de estudos de caso: o debate recente em torno da pesquisa histórico-comparativa. **XXIV Simpósio Nacional De História**, p. 9, 2007.

BRAGA, A. P. **Redes neurais artificiais: teoria e aplicações**. LTC Editora, 2007. ISBN 9788521615644. Disponível em: <https://books.google.com.br/books?id=R-p1GwAACAAJ>.

BROADSTON, R. D. **A method of increasing the kinematic boundary of air-to-air missiles using an optimal control approach**. Dissertação (Mestrado) — Naval Postgraduate School, 2011.

BROOMHEAD, D. S.; LOWE, D. Multivariable Functional Interpolation and Adaptive Networks. **Complex Systems**, v. 2, p. 321– 355, 1988. ISSN 0036-8075.

BUCKLAND, M. **AI Techniques for Game Programming**. Premier Press, 2002. (The Premier Press game development series). Disponível em: <https://books.google.com.br/books?id=DbIsvgAACAAJ>.

CÂMARA, G.; ASSIS, L. F.; RIBEIRO, G.; FERREIRA, K. R.; LLAPA, E.; VINHAS, L. Big earth observation data analytics. **Proceedings of the 5th ACM SIGSPATIAL International Workshop on Analytics for Big Geospatial Data - BigSpatial '16**, n. October, p. 1–6, 2016. Disponível em: <http://dl.acm.org/citation.cfm?doid=3006386.3006393>.

CAWLEY, G. C.; TALBOT, N. L. On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. **Journal of Machine Learning Research**, v. 11, p. 2079–2107, 2010. ISSN 1532-4435.

CERQUEIRA, E. O.; ANDRADE, J. C. de; POPPI, R. J.; MELLO, C. Redes neurais e suas aplicações em calibração multivariada. **Química Nova**, v. 24, n. 6, p. 864–873, 2001. ISSN 0100-4042.

CLEVERT, D.-A.; UNTERTHINER, T.; HOCHREITER, S. Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs). p. 1–14, 2015. ISSN 09226389.

COHEN, M. A.; GROSSBERG, S. Absolute stability of global pattern formation and parallel memory storage by competitive neural networks. **IEEE Transactions on Systems, Man, and Cybernetics**, SMC-13, n. 5, p. 815–826, Sept 1983. ISSN 0018-9472.

COSTA, A. N.; MEDEIROS, F. L. L.; GERALDO, D.; MARQUES, H. C. Modelagem de Comportamentos para Simulação de Combate BVR. **Revista Spectrum, n. 20, Comando de Preparo**, Setembro 2017.

COX, A. D. R.; JOURNAL, S.; STATISTICAL, R.; SERIES, S. The Regression Analysis of Binary Sequences Published by : Wiley for the Royal Statistical Society Stable URL : http://www.jstor.org/stable/2983890. **Journal of the Royal Statistical Society**, v. 20, n. 2, p. 215–242, 1958. ISSN 18684238.

CYBENKO, G. Approximation by Superpositions of a Sigmoidal Function. **Mathematics of Control, Signals, and Systems**, v. 2, p. 303–314, 1989. Disponível em: <https://link.springer.com/content/pdf/10.1007\%2FBF02551274.>.

DANTAS, J. P. A. Teoria dos Jogos Aplicada ao Combate BVR. **Revista Spectrum, n. 20, Comando de Preparo**, Setembro 2017.

DAVIDOVITZ, A.; SHINAR, J. Two-target game model of an air combat with fire-and-forget all-aspect missiles. **Journal of Optimization Theory and Applications**, v. 63, n. 2, p. 133–165, 1989. ISSN 00223239.

DEMKIN, M. A.; TISHCHENKO, Y. E.; FEDUNOV, B. E. Basic onboard real-time advisory system for a duel situation of distant air fight. **Journal of Computer & Systems Sciences International**, v. 47, n. 4, p. 552–569, 2008. ISSN 10642307.

DEMUTH, H. **Neural Network Toolbox 6 User's Guide**. [S.l.: s.n.], 2000. 259–265 p. ISSN 09410643. ISBN 0971732108.

DIETRICH, D.; HELLER, B.; YANG, B. **Data Science & Big Data Analytics: discovering, analyzing, visualizing and presenting data**. [S.l.: s.n.], 2015. 420 p. ISBN 9781118876138.

DOD, U. S. Department of Defense Modeling and Simulation Master Plan, 5000.59-P. October 1995.

DOMINGOS, P. A few useful things to know about machine learning. **Communications of the ACM**, v. 55, n. 10, p. 78, 2012. ISSN 00010782. Disponível em: <http://dl.acm.org/citation.cfm?doid=2347736.2347755>.

DTIC, U. S. Air Armament Center: Precision Strike: Enabler for Force Domination. n. June, p. 56, 2008.

DU, K.-L.; SWAMY, M. N. S. **Neural Networks and Statistical Learning**. [s.n.], 2014. 15–66 p. ISBN 978-1-4471-5570-6. Disponível em: <http://link.springer.com/10.1007/978-1-4471-5571-3>.

DU, P.; LIU, H. Study on air combat tactics decision-making based on bayesian networks. p. 252–256, April 2010.

EDUARDO, S.; GOUVÊA, S. L. M. P. de; MARINS, J. T. M. Amostragem descritiva no apreçamento de opções européias através de simulação Monte Carlo: o efeito da dimensionalidade e da probabilidade de exercício no ganho de precisão. **Pesquisa Operacional**, p. 1–13, 2007. ISSN 01017438.

ENDSLEY, M. R. **A Survey of Situation Awareness Requirements in Air-to-Air Combat Fighters**. 1993. 157–168 p.

ENDSLEY, M. R. Toward a Theory of Situation Awareness in Dynamic Systems. **Human Factors: The Journal of the Human Factors and Ergonomics Society**, v. 37, n. 1, p. 32–64, 1995. ISSN 0018-7208. Disponível em: <http://journals.sagepub.com/doi/10.1518/001872095779049543>.

ENDSLEY, M. R.; TECHNOLOGIES, S. A.; VIEW, H.-a. I.; ENDSLEY, M. R. A taxonomy of situation awareness errors , human factors in aviation operations. n. January 1995, 1995.

ERLANDSSON, T.; NIKLASSON, L. An air-to-ground combat survivability model. **Journal of Defense Modeling and Simulation**, v. 12, n. 3, p. 273–287, 2015. ISSN 1557380X.

FEIGIN, P. D.; PINKAS, O.; SHINAR, J. A simple markov model for the analysis of multiple air combat. **Naval Research Logistics Quarterly**, v. 31, n. 3, p. 413–429, 1984. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1002/nav.3800310308>.

FLOYD, M. W.; KARNEEB, J.; MOORE, P.; AHA, D. W. A goal reasoning agent for controlling UAVs in beyond-visual-range air combat. **IJCAI International Joint Conference on Artificial Intelligence**, p. 4714–4721, 2017. ISSN 10450823.

FREUND, J. E. **Estatística aplicada: economia, administração e contabilidade**. 11a. ed. Porto Alegre: Bookman, 2006. ISBN 9788536306674 853630667X. Disponível em: <http://gen.lib.rus.ec/book/index.php?md5=d944f0664f93c9df6a88d60f8c48063b>.

GERALDO, D. Relatório de avaliação numérica do Plugin Weapon Engagement Zone. **Instituto de Estudos Avançados (IEAV)**, 2015.

GLOROT, X.; BENGIO, Y. Understanding the difficulty of training deep feedforward neural networks. **Pmlr**, v. 9, p. 249–256, 2010. ISSN 15324435. Disponível em: <http://machinelearning.wustl.edu/mlpapers/paper_files/AISTATS2010_GlorotB>.

GOMES, L. **Modelagem de variáveis qualitativas por meio de redes neurais artificiais: Avaliação do uso de Análise de Correspondência como técnica de codificação**. Dissertação (Mestrado) — Universidade Federal de Juiz de Fora (UFJF), 2012.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. `http://www.deeplearningbook.org`.

GRUS, J. **Data Science from Scratch: First Principles with Python**. [S.l.]: O'Reilly Media, Inc., 2015.

HA, J.-S.; CHAE, H.-J.; CHOI, H.-L. A stochastic game-theoretic approach for analysis of multiple cooperative air combat. v. 2015, p. 3728–3733, July 2015.

HAYKIN, S. S. **Redes neurais: princípios e prática**. 2. ed. Porto Alegre: Bookman Companhia Ed, 2001.

HEBB, D. O. The Organization of Behavior. New York: Wiley, 1949.

HEINZE, C.; SMITH, B.; CROSS, M. Thinking quickly: Agents for modeling air warfare. **Advanced Topics in Artificial Intelligence**, p. 47–58, 1998. ISSN 16113349. Disponível em: <http://www.springerlink.com/index/X52T97M92811015N.pdf>.

HELTON, J. C.; DAVIS, F. J. Latin hypercube sampling and the propagation of uncertainty in analyses of complex systems. **Reliability Engineering and System Safety**, v. 81, n. 1, p. 23–69, 2003. ISSN 09518320.

HERRMANN, J. Air-to-air missile engagement analysis using the USAF Trajectory Analysis Program (TRAP). **Flight Simulation Technologies Conference**, p. 148–158, 1996. Disponível em: <http://arc.aiaa.org/doi/abs/10.2514/6.1996-3489>.

HINTON, G. E.; OSINDERO, S.; TEH, Y. W. A fast learning algorithm for deep belief nets. **Neural Computation**, v. 18, n. 7, p. 1527–1554, 2006. ISSN 08997667.

HIPPERT, H. S.; PEDREIRA, C. E.; SOUZA, R. C. Neural networks for short-term load forecasting: a review and evaluation. **IEEE Transactions on Power Systems**, v. 16, n. 1, p. 44–55, Feb 2001. ISSN 0885-8950.

HODSON, D. D. Performance analysis of live-virtual-constructive and distributed virtual simulations: Defining requirements in terms of temporal consistency. **ProQuest Dissertations and Theses**, p. 122, 2009. Disponível em: <https://afit.idm.oclc.org/login?url=http://search.proquest.com/docview-/304840728?accountid=26185\%5Cnhttp://resolver.ebscohost.com/openurl?D>.

HODSON, D. D.; HILL, R. R. The art and science of live, virtual, and constructive simulation for test and analysis. **Journal of Defense Modeling and Simulation**, v. 11, n. 2, p. 77–89, 2014. ISSN 1557380X.

HOGG, O. **Artillery: Its origin, heyday, and decline**. Archon Books, 1970. Disponível em: <https://books.google.com.br/books?id=uY_fAAAAMAAJ>.

HOPFIELD, J. J. Neural networks and physical systems with emergent collective computational abilities. **Proceedings of the National Academy of Sciences of the United States of America**, v. 79, n. 8, p. 2554–2558, abr. 1982. ISSN 0027-8424. Disponível em: <http://view.ncbi.nlm.nih.gov/pubmed/6953413]>.

HORNIK, K. Approximation Capabilities of Multilayer Neural Network. v. 4, p. 251–257, 1991.

HOYLE, C. UK report exposes fresh cost increase to Nimrod MRA4, delay on Meteor missile. London, December 2008.

HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. v. 22, p. 679–688, 2006.

IMAN, R. L. Uncertainty and sensitivity analysis for computer modeling applications. n. August, 1992.

JANE'S, I. Journal, **White Paper Fast Jet Cost Per Flight Hour (Cpfh)**. [S.l.]: IHS Global Ltd [Coulsdon, Surrey], 2012. 1–14 p.

JARMARK, B. A missile duel between two aircraft. **Journal of Guidance, Control, and Dynamics**, v. 8, n. 4, p. 508–513, 1985. ISSN 0731-5090.

JONES, D.; ENDSLEY, M. R. Sources of Situation Awareness Errors in Aviation Domain. **Aviation Space and Environmental Medicine**, v. 67, n. 6, 1996. ISSN 00956562.

JÚNIOR, H. V. **Selecting the system most likely to be the best in the presence of an infinite number of alternatives**. Tese (Doutorado) — Intituto Tecnológico de Aeronáutica (ITA), 2011.

JÚNIOR, H. V.; KIENITZ, K. H.; BELDERRAIN, M. C. N. Simulação computacional de combate aéreo além do alcance visual: uma ferramenta de melhoria operacional para a força aérea. **XV SPOLM - Simpósio de Pesquisa Operacional da Marinha**, Agosto 2012.

KALAI, E. Game theory: Analysis of conflict. **Games and Economic Behavior**, Harvard Univ. Press, n. 1944, p. 387–391, 1991.

KARELAHTI, J.; VIRTANEN, K.; RAIVIO, T. Game Optimal Support Time of a Medium Range Air-to-Air Missile. **Journal of Guidance, Control, and Dynamics**, v. 29, n. 5, p. 1061–1069, 2006. ISSN 0731-5090. Disponível em: <http://arc.aiaa.org/doi/10.2514/1.17910>.

KARELAHTI, J.; VIRTANEN, K.; RAIVIO, T. Near-Optimal Missile Avoidance Trajectories via Receding Horizon Control. **Journal of Guidance, Control, and Dynamics**, v. 30, n. 5, p. 1287–1298, 2007. ISSN 0731-5090. Disponível em: <http://arc.aiaa.org/doi/10.2514/1.26024>.

KINGMA, D. P.; BA, J. Adam: A Method for Stochastic Optimization. **ArXiv e-prints**, Dec. 2014.

KOHONEN, T. Self-Organized Formation of Topologically Correct Feature Maps. v. 69, p. 59–69, 1982.

KOHONEN, T.; LEHTIö, P.; ROVAMO, J.; HYVäRINEN, J.; BRY, K.; VAINIO, L. A principle of neural associative memory. **Neuroscience**, v. 2, n. 6, p. 1065 – 1076, 1977. ISSN 0306-4522.

KOVACS, Z. **Redes neurais artificiais: fundamentos e aplicações, um texto básico**. Academica, 1996. Disponível em: <https://books.google.com.br/books?id=gB2nswEACAAJ>.

LAW, A. M. **Simulation modeling and analysis**. [S.l.: s.n.], 1991. 155 p. ISSN 10493301. ISBN 0070592926.

LIN, Z.; MINQ'AN, T.; WEI, Z.; SHCNQUUN, Z. Sequential maneuvering decisions based on multi-stage influence diagram in air combat. **Journal of Systems Engineering and Electronics**, v. 18, n. 3, p. 551–555, September 2007. ISSN 1004-4132.

LU, H.; ZHANG, H.; ZHANG, X.; HAN, R. An improved genetic algorithm for target assignment optimization of naval fleet air defense. **Proceedings of the World Congress on Intelligent Control and Automation (WCICA)**, IEEE, v. 1, n. 2, p. 3401–3405, 2006.

LUO, D.-L.; SHEN, C.-L.; WANG, B.; WU, W.-H. Air combat decision-making for cooperative multiple target attack using heuristic adaptive genetic algorithm. **2005 International Conference on Machine Learning and Cybernetics, ICMLC 2005**, n. August, p. 18–21, 2005.

MAAS, A. L.; HANNUN, A. Y.; NG, A. Y. Rectifier Nonlinearities Improve Neural Network Acoustic Models. **Proceedings of the 30 th International Conference on Machine Learning**, v. 28, p. 6, 2013.

MACÊDO, L. H. **Alocação Coordenada de Múltiplos Alvos Aéreos Utilizando Heurística Especializada**. Dissertação (Mestrado) — Instituto Tecnológico de Aeronáutica (ITA), 2017.

MAGALHÃES, J. M. As 7 Ferramentas Básicas da Qualidade. 1996. Disponível em: <http://www.aprendersempre.org.br/arqs/9 - 7_ferramentas_qualida>.

MALINVERNI, M. d. S. Sistema Hipermídia Sobre Câncer De Colo De Útero Com Interface Adaptativa Usando Redes Neurais Artificiais Mlp E Sistema Especialista. 2006.

MALOUF, R. A comparison of algorithms for maximum entropy parameter estimation. **Proceedings of the Sixth Conference on Natural Language Learning**, v. 20, p. 49–55, 08 2002.

MARQUES, H. C.; GERALDO, D.; MACÊDO, L. H. Arcabouço de Combate BVR - Plataforma de Apoio à Decisão e ao Treinamento de Pilotos. **Revista Spectrum, n. 19, Comando-Geral de Operações Aéreas**, Setembro 2015.

MARTINS, P. S. Aprendizado de Máquina para Otimização de Parâmetros em Sistemas Baseados em Conhecimento. 2003.

MASON, S. J.; HILL, R. R.; MÖNCH, L.; ROSE, O.; JEFFERSON, T.; FOWLER, J. W.; FU, M. C.; SMITH, R. H.; CHEN, C.-h. Proceedings of the 2008 Winter Simulation Conference S. J. Mason, R. R. Hill, L. Mönch, O. Rose, T. Jefferson, J. W. Fowler eds. p. 27–38, 2008.

MCCARTHY, J.; MINSKY, M.; SHANNON, C.; ROCHESTER, N.; COLLEGE, D. **A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence**. [s.n.], 1955. Disponível em: <https://books.google.com.br/books?id=n1SDQwAACAAJ>.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The Bulletin of Mathematical Biophysics**, v. 5, n. 4, p. 115–133, 1943. ISSN 00074985.

MCKAY, M.; BECKMAN, R.; CANOVER, W. A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output From a A Comparison of Three Methods for Selecting Values of Input Variables in the Analysis of Output From a Computer Code. **Technometrics**, v. 21, n. 2, p. 239–245, 1979.

MEI, S.; MONTANARI, A.; NGUYEN, P.-M. A Mean Field View of the Landscape of Two-Layers Neural Networks. v. 115, n. 33, 2018. ISSN 0027-8424. Disponível em: <http://arxiv.org/abs/1804.06561>.

MILONE, G. **Estatística: geral e aplicada**. Pioneira Thomson Learning, 2004. ISBN 9788522103393. Disponível em: <https://books.google.com.br/books?id=qVfAAAAACAAJ>.

MINSKY, M.; PAPERT, S. **Perceptrons: An Introduction to Computational Geometry**. Cambridge, MA, USA: MIT Press, 1969.

MITCHELL, T. M. The Discipline of Machine Learning. **Machine Learning**, v. 17, n. July, p. 1–7, 2006. ISSN 0264-0414. Disponível em: <http://www-cgi.cs.cmu.edu/~tom/pubs/MachineLearningTR.p>.

MONTGOMERY, D. C.; WILEY, J. **Design and Analysis of Experiments**. 8.ed.. ed. [s.n.], 2013. ISBN 9781118146927. Disponível em: <www.wiley.com/go/permissions.>.

MORETTIN, P.; BUSSAB, W. de O. **Estatística básica**. Saraiva, 2012. ISBN 9788502136915. Disponível em: <https://books.google.com.br/books?id=8mUrywAACAAJ>.

MORITZ, K.; POLIS, R.; WELL, K. H. Pursuit-evasion in medium-range air-combat scenarios. **Computer and Mathematics with Applications**, v. 13, n. 1–3, p. 167–180, 1987.

MUKAI, H.; TANIKAWA, A.; TUNAY, I.; OZCAN, I. A.; KATZ, I. N.; SCHÄTTLER, H.; RINALDI, P.; WANG, G. J.; YANG, L.; SAWADA, Y. Sequential linear-quadratic method for differential games with air combat applications. **Computational Optimization and Applications**, v. 25, n. 1-3, p. 193–222, 2003. ISSN 09266003.

MULGUND, S.; HARPER, K.; KRISHNAKUMAR, K.; ZACHARIAS, G. Air combat tactics optimization using stochastic genetic algorithms. v. 4, p. 3136–3141 vol.4, Oct 1998. ISSN 1062-922X.

NASCIMENTO, P. Aplicação de Sistemas Inteligentes no Controle de um Sistema Atuado por Material SMA. n. September, 2015.

NASH, J. Non-cooperative games. **Annal of Mathematics**, Mathematics Department Princeton University, v. 54, p. 286–295, September 1951.

NASSER, A.; AHMED, F.; MOUSTAFA, K. H.; ELSHABRAWY, A. Recent advancements in proximity fuzes technology. **International Journal of Engineering Research & Technology (IJERT)**, V4, April 2015.

NEUMANN, J. v.; MORGENSTERN, O.; KUHN, H. W.; RUBINSTEIN, A. **Theory of Games and Economic Behavior (60th Anniversary Commemorative Edition)**. [S.l.]: Princeton University Press, 1944. ISBN 9780691130613.

NOCEDAL, J.; WRIGHT, S. **Numerical Optimization**. Springer New York, 2006. (Springer Series in Operations Research and Financial Engineering). ISBN 9780387400655. Disponível em: <https://books.google.com.br/books?id=VbHYoSyelFcC>.

OLSSON, A.; SANDBERG, G.; DAHLBLOM, O. On latin hypercube sampling for structural reliability analysis. **Structural Safety**, Elsevier, v. 25, p. 47–68, 2003. ISSN 0167-4730.

PEREIRA, F. d. B. L. D. Proposta de método para otimização no uso de informações recebidas via datalink na aeronave F-5M, mediante instabilidades na rede de dados, visando evitar fratricídios. 2017.

PEREIRA, F. d. B. L. D. Uso De Lógica Datalink Para Evitar Fratricídios. **Revista Preparo, n. 1, Comando de Preparo**, Setembro 2018.

PERSING, T. R.; DUBE, T.; SLUTZ, G. J. Impact of Aircraft Flight Dynamics Modeling Technique on Weapon System Beyond-Visual-Range Combat Effectiveness. **AIAA Modeling and Simulation Technologies Conference and Exhibit**, August 2003. Disponível em: <http://arc.aiaa.org/doi/10.2514/6.2003-5689>.

PETERSEN, J. F.; AQUINO, M. R. C.; SALLES, R. N. Plataforma AEROGRAF: um SIG voltado para a Força Aérea. **Revista Spectrum, n. 11, Comando-Geral de Operações Aéreas**, Setembro 2008.

POROPUDAS, J.; VIRTANEN, K. Analyzing air combat simulation results with dynamic bayesian networks. **2007 Winter Simulation Conference**, p. 1370–1377, 2007.

PRASAD, U. R.; GRIMM, W.; BERGER, E. A feedback guidance for pre-launch maneuvering in medium range air combat with missiles. DFVLR Institute for Flight Systems Dynamics, 1989.

RAO, C. R. **Linear Statistical Inference and its Applications**. [S.l.]: Wiley, 1973.

RÄTSCH, G. A brief introduction into machine learning. **21st Chaos Communication Congress**, p. 1–6, 2004. Disponível em: <http://www.mva.me/educational/hci/read/ML_reading.>

ROBBINS, H.; MONRO, S. A stochastic approximation method. **Annals of Mathematical Statistics**, v. 22, p. 400–407, 1951.

ROSENBLATT, F. **Principles of neurodynamics: perceptrons and the theory of brain mechanisms**. Spartan Books, 1962. (Report (Cornell Aeronautical Laboratory)). Disponível em: <https://books.google.com.br/books?id=7FhRAAAAMAAJ>.

RUMELHART, D.; HINTON, G.; WILLIAMS, R.; CALIFORNIA, S. D. I. f. C. S. University of. **Learning Internal Representations by Error Propagation**. Institute for Cognitive Science, University of California, San Diego, 1985. (ICS report). Disponível em: <https://books.google.com.br/books?id=Ff9iHAAACAAJ>.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Neurocomputing: Foundations of research. MIT Press, Cambridge, MA, USA, p. 696–699, 1988. Disponível em: <http://dl.acm.org/citation.cfm?id=65669.104451>.

SCHMOELLER, F.; CAMPONOGARA, E. Aprendizagem de máquina para apoio à tomada de decisão em vendas do varejo utilizando registros de vendas. 2016.

SHIELDS, M. D.; ZHANG, J. The generalization of Latin hypercube sampling. **Reliability Engineering and System Safety**, Elsevier, v. 148, n. December, p. 96–108, 2016. ISSN 09518320. Disponível em: <http://dx.doi.org/10.1016/j.ress.2015.12.002>.

SILVA, I. N. D.; SPATTI, D. H.; FLAUZINO, R. A. **Redes neurais: princípios e prática**. 1.ed.. ed. São Paulo: Artliber, 2010.

SMITH, L. N. Cyclical learning rates for training neural networks. 2015. Cite arxiv:1506.01186Comment: Presented at WACV 2017; see https://github.com/bckenstler/CLR for instructions to implement CLR in Keras. Disponível em: <http://arxiv.org/abs/1506.01186>.

SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. **Journal of Machine Learning Research**, v. 15, p. 1929–1958, 2014. ISSN 15337928.

TAFNER, M.; XEREZ, M. de; FILHO, E. **Redes neurais artificiais: introdução e princípios de neurocomputação**. Eko, 1995. ISBN 9788571140509. Disponível em: <https://books.google.com.br/books?id=aPtAAAAACAAJ>.

TRAN, C.; JAIN, L.; ABRAHAM, A. Adaptation of Mamdani Fuzzy Inference System Using Neuro - Genetic Approach for Tactical Air Combat Decision Support System. **Proceedings of 15th Australian Joint Conference on Artificial Intelligence (AI'02)**, p. 672–679, 2002. ISSN 03029743.

TURING, A. M. Computing machinery and intelligence. **Mind**, [Oxford University Press, Mind Association], v. 59, n. 236, p. 433–460, 1950. ISSN 00264423, 14602113. Disponível em: <http://www.jstor.org/stable/2251299>.

VAPNIK, V. N. **The Nature of Statistical Learning Theory**. Berlin, Heidelberg: Springer-Verlag, 1995. ISBN 0-387-94559-8.

WAGNER, M.; LLORT, G.; MERCADAL, E.; GIMÉNEZ, J.; LABARTA, J. Performance Analysis of Parallel Python Applications. **Procedia Computer Science**, v. 108, p. 2171–2179, 2017. ISSN 18770509.

WERBOS, P. Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences. **Foundations**, PhD thesis, n. January 1974, 1974. Disponível em: <http://www.citeulike.org/group/1938/article/1055600>.

WIDROW, B.; HOFF, M. E. Adaptive switching circuits. IRE, New York, p. 96–104, 1960.

WILLMOTT, C. J.; MATSUURA, K. On the use of dimensioned measures of error to evaluate the performance of spatial interpolators. **International Journal of Geographical Information Science**, v. 20, n. 1, p. 89–102, 2006. ISSN 13658816.

XU, B.; WANG, N.; CHEN, T.; LI, M. Empirical Evaluation of Rectified Activations in Convolutional Network. 2015.

YANUSHEVSKY, R. **Modern Missile Guidance**. CRC PressINC, 2008. ISBN 9780815384861. Disponível em: <https://books.google.com.br/books?id=BA4WtAEACAAJ>.

ZADEH, L. Fuzzy sets. **Information Control**, v. 8, p. 338–353, 1965.

ZARCHAN, P. **Tactical and Strategic Missile Guidance**. American Institute of Aeronautics and Astronautics, 1997. (AIAA tactical missile series, v. 176,pt. 1). ISBN 9781563472541. Disponível em: <https://books.google.com.br/books?id=YJMSnQAACAAJ>.

FOLHA DE REGISTRO DO DOCUMENTO

1. CLASSIFICAÇÃO/TIPO	2. DATA	3. DOCUMENTO Nº	4. Nº DE PÁGINAS
DM	28 de janeiro de 2019	DCTA/ITA/DM-133/2018	144

5. TÍTULO E SUBTÍTULO:

Apoio à decisão para o combate aéreo além do alcance visual: uma abordagem por redes neurais artificiais

6. AUTOR(ES):

João Paulo de Andrade Dantas

7. INSTITUIÇÃO(ÕES)/ÓRGÃO(S) INTERNO(S)/DIVISÃO(ÕES):

Instituto Tecnológico de Aeronáutica – ITA

8. PALAVRAS-CHAVE SUGERIDAS PELO AUTOR:

Combate aéreo além do alcance visual; Consciência situacional; Redes neurais artificiais.

9. PALAVRAS-CHAVE RESULTANTES DE INDEXAÇÃO:

Combate BVR; Consciência situacional; Redes neurais; Sistemas de apoio à decisão; Computação.

10. APRESENTAÇÃO: (**X**) **Nacional** ( ) **Internacional**

ITA, São José dos Campos. Curso de Mestrado. Programa de Pós-Graduação em Engenharia Eletrônica e Computação. Área de Sistemas e Controle. Orientador: Prof. Dr. Takashi Yoneyama. Defesa em 14/12/2018. Publicada em 2018.

11. RESUMO:

A presente dissertação apresenta o desenvolvimento de um modelo de inteligência artificial baseado em redes neurais artificiais que permite fornecer parâmetros de melhoria da consciência situacional de um piloto de combate aéreo além do alcance visual. Tal modalidade de combate tem como característica a necessidade de se tomar decisões baseando-se em informações oriundas de sensores, principalmente radares. Além disso, como as informações relativas aos sistemas da aeronave inimiga são, por vezes, desconhecidas, muitas das atitudes tomadas pelos pilotos se baseiam em crenças e estimativas com relação ao oponente. O modelo apresentado se propõe a lidar com tais características, gerando comportamentos para entidades representadas num ambiente de simulação construtiva. Um simulador de combate aéreo além do alcance visual foi utilizado para criação de cenários de combate entre duas aeronaves, com apenas um míssil cada uma, que possuem comportamentos semelhantes que podem ser diferenciados com mudanças nos parâmetros de entrada da simulação. A partir da variação de trinta e seis informações de entradas foram geradas cem, mil e dez mil simulações de combate para realização das análises. Com esses dados foi possível criar um modelo de aprendizado de máquina supervisionado por meio das redes neurais artificiais que permitiram uma pronta resposta da situação do piloto em um combate aéreo além do alcance visual no que diz respeito a ofensividade e defensividade por meio de um dispositivo embarcado de melhoria da consciência situacional do piloto que auxilia o processo de tomada de decisão em voo.

12. GRAU DE SIGILO:

(**X**) **OSTENSIVO** ( ) **RESERVADO** ( ) **SECRETO**